

论文解构报告

DeepSeek-V4: Towards Highly Efficient Million-Token Context Intelligence

DeepSeek-AI

2026

大语言模型

混合专家模型

长上下文

混合注意力机制

DeepSeek-V4

源文件: <https://arxiv.org/pdf/2606.19348>

arXiv: <https://arxiv.org/abs/2606.19348>

代码: <https://huggingface.co/collections/deepseek-ai/deepseek-v4>

生成时间: 2026-07-30

目录

摘要翻译	3
1. 一句话总览	3
2. 阅读范围与证据状态	3
3. 根问题：论文究竟要解决什么	3
4. 旧方法为何不够	4
5. 核心洞见与假设	4
6. 方法：从洞见到可执行系统	5
7. 为什么它可能有效	10
8. 实验与指标：证据是否支撑主张	10
9. 图表解读与论证关系	12
10. 完整因果推理树	20
11. 结论、贡献与边界	21
12. 术语与第一性原理学习路径	21

摘要翻译

我们推出了 DeepSeek-V4 系列的预览版本，其中包括两款强劲的混合专家（MoE）语言模型——拥有 1.6T 总参数（49B 激活）的 DeepSeek-V4-Pro 和拥有 284B 总参数（13B 激活）的 DeepSeek-V4-Flash，两者均支持 100 万 token 的上下文长度。DeepSeek-V4 系列在架构和优化方面融合了多项关键升级：（1）结合了压缩稀疏注意力（CSA）与重度压缩注意力（HCA）的混合注意力架构，以提升长上下文效率；（2）增强传统残差连接的流形约束超连接（mHC）；（3）用于加快收敛速度并提高训练稳定性的 Muon 优化器。我们在超过 32T 多样化且高质量的 token 上对这两款模型进行了预训练，随后通过一套全面的后训练流程释放并进一步提升了它们的能力。DeepSeek-V4-Pro Max 作为 DeepSeek-V4-Pro 的最高推理努力模式，重新定义了开源模型的最高水平，在核心任务上的表现超越了前代模型。同时，DeepSeek-V4 系列在长上下文场景中展现出极高的效率。在 100 万 token 上下文的设定下，与 DeepSeek-V3.2 相比，DeepSeek-V4-Pro 仅需 27% 的单 token 推理 FLOPs 和 10% 的 KV 缓存。这使得我们能够常规化地支持 100 万 token 上下文，从而使长跨度任务和进一步的测试时扩展更加可行。模型权重已发布于 <https://huggingface.co/collections/deepseek-ai/deepseek-v4>。

1. 一句话总览

论文元数据

字段	内容
标题	DeepSeek-V4: Towards Highly Efficient Million-Token Context Intelligence
作者	DeepSeek-AI
发表场所 / 年份	2026
研究领域	自然语言处理
关键词	大语言模型, 混合专家模型, 长上下文, 混合注意力机制, DeepSeek-V4

资源链接

- 原始文件：本地上传文件
- arXiv: <https://arxiv.org/abs/2606.19348>
- DOI: 文中未说明
- 代码 / 数据集: <https://huggingface.co/collections/deepseek-ai/deepseek-v4>

标签（5 个）：大语言模型 · 混合专家模型 · 长上下文 · 混合注意力机制 · DeepSeek-V4

作者明确陈述 DeepSeek-V4 系列（包含 1.6T 参数/49B 激活的 DeepSeek-V4-Pro 与 284B 参数/13B 激活的 DeepSeek-V4-Flash）通过提出压缩稀疏注意力（CSA）与重度压缩注意力（HCA）构成的混合注意力架构、流形约束超连接（mHC）以及 Muon 优化器，在预训练 32T~33T Token 并配合领域专家 RL 与全词表在线策略蒸馏后，实现了原生支持 100 万 Token（1M Tokens）超长上下文的高效推理与长程智能，并在 1M 上下文中将单 Token 推理 FLOPs 降至 27%（Pro）及 KV Cache 显存降至 10%（Pro）。

2. 阅读范围与证据状态

- **作者明确陈述** 本报告基于论文全文文本及包含 6 批图表的证据分析进行解构，覆盖预训练架构设计（CSA, HCA, mHC, Muon）、底层算子与并行系统（MegaMoE², Batch-Invariant Kernels, State Cache）、后训练流水线（GRM, OPD, Interleaved Thinking）以及 7 个核心 Benchmark、MRCR 8-needle 检索、Lean 4 形式化证明、TerminalBench 2.0 与白领办公实操评估。
- **作者明确陈述** 文中部分具体实现细节（如集群硬件拓扑规模、数据过滤具体参数）未作完全披露，在对应部分已明确注明为“文中未说明”。
- **背景知识** 大语言模型长上下文注意力计算复杂度与显存管理属于通用 NLP 背景知识，文中未陈述的外部背景已明确标注。

3. 根问题：论文究竟要解决什么

- **问题定义：** **作者明确陈述** 大语言模型在处理 100 万 Token（1M Tokens）超长上下文时，传统自注意力机制的二次方计算复杂度与 KV Cache 显存膨胀会导致硬件显存溢出（OOM）与单 Token 推理 FLOPs 飙升，瓶颈极其严重。
- **应用与研究价值：** **基于文中逻辑的推断** 解决超长上下文的计算与显存效率墙，是解锁下一代 LLM 测试时扩展（Test-Time Scaling）、长程复杂 Agent 多轮思考留存（Interleaved Thinking）以及深度推理的基础设施前提；缺乏高效的长上下文架构，长序列应用将停留在高成本且无法落地的实验阶段。

- **困难来源：** **作者明确陈述** 既要大比例压缩 KV Cache 与降低计算 FLOPs，又要保证局部精细语义检索与全局高层概要能力不衰退；同时在深层 MoE 网络堆叠与超大规模并行训练中，面临数值不稳定 (Numerical Instability)、通信开销掩盖以及多专家能力蒸馏融合震荡等工程难题。
- **成功标准：** **实验支持** 在原生支持 1M Token 上下文的前提下，实现相比前代 DeepSeek-V3.2 数量级级的 FLOPs 与 KV Cache 削减，并在知识、编程、数学形式化证明与 Agentic 任务上达到开源 SOTA。
- **本文的 story：** 旧路线 (标准 Vaswani 注意力及 DeepSeek-V3.2 稠密/稀疏方案) 因未对 KV 依赖按“局部精细 + 全局概要”分级压缩，在 1M 上下文下显存与算力彻底失效；本文通过 CSA+HCA 混合压缩注意力改变依赖表示，结合 mHC 保证深层数值稳定，软硬协同突破长上下文与测试时扩展屏障。

4. 旧方法为何不够

1. 标准 Vaswani 自注意力机制：

- 原本解决：捕获序列全对全注意力。
- 限制：计算与存储复杂度对序列长度敏感 ($O(n^2)$ 或与 n 成正比)，在 1M 上下文下导致算力瓶颈与显存溢出。
- 本文回应：提出 CSA + HCA 混合压缩注意力架构。
- 检验实验：Figure 1 Panel 2/3 FLOPs 与 KV Cache 对比实验。

2. DeepSeek-V3 / DeepSeek-V3.2 架构：

- 原本解决：MoE 稀疏激活与 MTP 多 Token 预测。
- 限制：在 1M 极长上下文下单 Token 推理 FLOPs 和 KV Cache 需求依然偏高；多轮 Agent 中新 Turn 清空思考痕迹导致重复推理。
- 本文回应：引入 CSA+HCA 压缩与 Interleaved Thinking 跨 Turn 思考留存。
- 检验实验：Figure 1 效率对比与 TerminalBench 2.0 / Figure 7 思考留存对比。

3. 朴素超连接 (Naive Hyper-Connections, HC)：

- 原本解决：扩展残差流宽度提升表达力。
- 限制：深层堆叠时频繁遭遇数值不稳定 (Numerical Instability)。
- 本文回应：提出流形约束超连接 (mHC)，将残差映射约束在双随机矩阵流形 $\mathcal{M}$ 上。
- 检验实验：2.2 节与 3.4.2 节稳定性陈述。

4. 粗粒度专家并行 (如 Comet)：

- 原本解决：EP 重叠 Dispatch 与 Combine 通信。
- 限制：重叠粒度较粗，在小 Batch (如 RL Rollout 长尾场景) 下通信延迟无法被计算完全掩盖。
- 本文回应：提出 MegaMoE² 细粒度 Expert Wave 重叠 EP 方案。
- 检验实验：Figure 5 EP 方案对比与 $1.50 \sim 1.73 \times / 1.96 \times$ 加速比。

5. 传统 PagedAttention / Jenga / Hymba：

- 原本解决：通用页式 KV 缓存管理。
- 限制：无法统一处理 CSA/HCA 异构压缩率 ($m = 4, m' = 128$) 与未满窗口尾 Token 状态。
- 本文回应：设计 State Cache 与 Classical KV Cache 解耦管理及 $\text{lcm}(m, m')$ 块大小对齐布局。
- 检验实验：3.5.1 节与 Figure 6 布局示意。

6. Token 级 KL 散度估计 OPD：

- 原本解决：多教师蒸馏降低显存开销。
- 限制：梯度估计方差极高，导致训练剧烈震荡。
- 本文回应：采用全词表 Logit On-Policy Distillation (缓存最后一层 Hidden State 重建 Logit)。
- 检验实验：5.1.2 节与 5.2.2 节。

5. 核心洞见与假设

· 混合压缩注意力机制 (CSA + HCA)：

- **基于文中逻辑的推断 核心洞见：** 长上下文中的信息依赖兼具局部连续性、全局稀疏性与重度概要性，无需对所有历史 Token 维持无损高分辨率存储。
- **作者明确陈述 假设与方案：** 将 KV 按 $m = 4$ 进行局部重叠压缩并配合 DSA 稀疏选择 (CSA)，同时按 $m' = 128$ 进行大比例重度压缩并保持稠密注意力 (HCA)，两者交替交织可在保留精细检索的同时，将 1M 上下文 KV Cache 与 FLOPs 降低一个数量级。

· 流形约束超连接 (mHC)：

- **作者明确陈述 核心洞见：** 残差流映射矩阵的谱范数若无约束，深层传播中信号与梯度易发生爆炸或衰减。
- **作者明确陈述 假设与方案：** 利用 Sinkhorn-Knopp 算法将残差映射矩阵 B_l 约束在双随机矩阵流形 (Birkhoff 多面体 $\mathcal{M}$) 上，保证 $\|B_l\| \leq 1$ ，使残差变换具备非膨胀性，保障深层网络绝对数值稳定性。

· Muon 优化器正交化更新：²

- **作者明确陈述 核心洞见：** 二维矩阵参数通过 Newton-Schulz 迭代近似正交化更新，比 Element-wise AdamW 具更高的收敛效率与稳定性。

· 细粒度 Expert Wave 重叠 EP：

- ▶ **基于文中逻辑的推断 核心洞见**：MoE 层内计算量大于通信量，通信延迟具备被计算完全隐蔽的空间。将专家切分为 Waves 并三轨流水线重叠。

- **Post-Training 范式 (GRM + OPD + Interleaved Thinking)** :

- ▶ **作者明确陈述 核心洞见**：Actor 兼任 GRM 配合 Rubric 优化解决难验证任务；多领域专家通过全词表 OPD 无损融合；工具调用场景跨 Turn 完整保留思考痕迹提升 Agent 智力与效率。

6. 方法：从洞见到可执行系统

- **系统总览**：数据自输入 Token 嵌入后，经过堆叠的 Transformer Block（交替包含 mHC 宽残差流、CSA/HCA 混合注意力与 DeepSeekMoE），最终经 Prediction Head 与 MTP 模块输出预测。
- **1. CSA（压缩稀疏注意力）**：
 - ▶ **动机**：以高分辨率保留局部与稀疏全局关键信息。
 - ▶ **步骤**：输入隐藏状态 H 。按 $m = 4$ 将每 4 个 Token 压缩为 1 个 KV 入口 C^{Comp} ；利用 Lightning Indexer 计算得分并挑选 Top- k 入口；结合 128-token 滑动窗口（SWA）拼接后送入 Shared KV MQA。
 - ▶ **输出**：经过分组输出投影后的注意力向量 $\hat{o}_t$ 。
- **2. HCA（重度压缩注意力）**：
 - ▶ **动机**：提供全序列重度概要稠密覆盖。
 - ▶ **步骤**：按无重叠大比例 $m' = 128$ 将 128 个 Token 压缩为 1 个 KV 入口；不经 Top- k 筛选，直接对全量压缩入口及 SWA 进行稠密 Shared KV MQA 计算。
- **3. mHC（流形约束超连接）**：
 - ▶ **动机**：消除宽残差流在深层堆叠时的数值不稳定。
 - ▶ **步骤**：将残差状态 $X_l \in \mathbb{R}^{n_{\text{hc}} \times d}$ ($n_{\text{hc}} = 4$) 展平，通过 Sigmoid 生成 A_l, C_l ，对 $\bar{B}_l$ 执行 20 次 Sinkhorn-Knopp 迭代归一化投影至双随机矩阵流形 $\mathcal{M}$ 得到 B_l 。按 $X_{l+1} = B_l X_l + C_l \mathcal{F}_l(A_l X_l)$ 更新。
- **4. EP 通信重叠与底层算子 (MegaMoE² & State Cache)**：
 - ▶ **动机**：消除 EP 通信瓶颈与异构 KV 内存碎片。
 - ▶ **步骤**：MegaMoE² 采用单 fused mega-kernel 将专家划分为 Waves，重叠 Dispatch、GEMM 与 Combine；State Cache 集中管理 SWA 与未满尾 Token，Classical KV Cache 采用 $\text{lcm}(m, m')$ 块对齐组织。




Figure 2 | Overall architecture of DeepSeek-V4 series. We use hybrid CSA (Compressed Sparse Attention) and HCA (Heavily Compressed Attention) for attention layers, DeepSeekMoE for feed-forward layers, and strengthen conventional residual connections with mHC.

图组解读

- **图组结论**: 展现 Transformer Block 内 mHC 宽残差流与 CSA/HCA 混合注意力、DeepSeekMoE 的自下而上堆叠拓扑。
- **论证关系**: 直观提供方法流水线证据，解释 mHC 的 Pre/Post-Block Mixing 与 CSA/HCA 的位置安排。
- **适用范围**: 高层架构拓扑示意，未展示 Sinkhorn-Knopp 的具体数学细节。




Figure 3 | Core architectures of CSA. It compresses the number of KV entries to times, and then applies DeepSeek Sparse Attention for further acceleration. Additionally, a small set of sliding window KV entries is combined with the selected compressed KV entries to enhance local fine-grained dependencies.

图组解读

- **图组结论：** CSA 显式包含 $m = 4$ 压缩、Lightning Indexer Top- k 选择与滑动窗口。
- **论证关系：** 解释 CSA 高分辨率稀疏检索在结构上的分工与计算缩减来源。
- **适用范围：** 模块设计数据流图，不能单独证明硬件端到端实测加速比。




Figure 4 | Core architectures of HCA. It performs heavier compression, where the KV entries of tokens will be consolidated into one. Also, we additionally introduce a small set of sliding window KV entries to enhance local fine-grained dependencies.

图组解读

- **图组结论：** HCA 采用 $m' = 128$ 重度压缩全量稠密注意力与滑动窗口。
- **论证关系：** 解释 HCA 全局重度概要在结构上的分工与计算缩减来源。
- **适用范围：** 模块设计数据流图，无法单独证明大比例压缩是否导致细粒度语义丢失。




Figure 5 | Illustration of our EP scheme with related works. Comet (Zhang et al., 2025b) overlaps Dispatch with Linear-1, and Linear-2 with Combine, separately. Our EP scheme achieves a finer-grained overlapping by splitting and scheduling experts into waves. The theoretical speedup is evaluated in the configuration of the DeepSeek-V4-Flash architecture.

图组解读

- **图组结论**：将专家切分为 3 个 Expert Wave 并实现三轨流水线重叠，理论加速比提升至 1.92 $\times$ 。
- **论证关系**：提供机制证据，证明细粒度重叠能够完全隐蔽 EP 中的通信延迟。
- **适用范围**：Flash 配置下理论分析图，实测需结合不同硬件拓扑。




Figure 6 | Illustration of the KV cache Layout for DeepSeek-V4. The KV cache is organized into two primary components: a classical KV cache for CSA/HCA, and a state cache for SWA and unready-for-compression tokens in CSA/HCA. In the state cache, each request is assigned a fixed-size cache block. Within this block, the SWA segment stores the KV entries corresponding to the most recent tokens, while the CSA/HCA segment stores uncompressed tail states that are not yet ready for compression. In the classical KV cache, we allocate multiple blocks per request. Each cache block covers $\text{lcm}()$ original tokens, producing CSA compressed tokens and HCA compressed tokens.

图组解读

- **图组结论**：State Cache 管理 SWA 与未满足 Token，Classical KV Cache 采用 $\text{lcm}(m, m')$ 块大小消除内存碎片。
- **论证关系**：验证解决 CSA/HCA 异构 KV Cache 管理瓶颈的解耦与对齐设计。
- **适用范围**：推理框架内存结构设计图，不包含具体显存吞吐率实测。




Figure 7 | Thinking management of DeepSeek-V4 series.

图组解读

- **图组结论**：在工具调用场景跨 Turn 完整保留 Thinking 痕迹，通用对话场景清空思考痕迹。
- **论证关系**：解释模型在长程 Agent 任务中维持思考连贯性与降低重算开销的机制。
- **适用范围**：逻辑规则示意图，无法提供定量的 Token 节省比例。

7. 为什么它可能有效

1. **基于文中逻辑的推断 局部与概要分级压缩机制**：通过 $m = 4$ 的 Top- k 稀疏检索（CSA）保证精确细粒度查找，同时通过 $m' = 128$ 的全量稠密注意力（HCA）维护全局背景语意，既消除了二次方冗余，又规避了纯稀疏注意力的信息丢失风险。
2. **基于文中逻辑的推断 谱范数界定与非膨胀传输**：mHC 强制将残差映射矩阵限制在双随机流形上，使其谱范数满足 $\|B_l\| \leq 1$ 。从线性代数约束来看，信号在多层传递中范数不会发生指数级累积，从而从根源上消除了深层堆叠引发的梯度爆炸与数值晃动。
3. **基于文中逻辑的推断 细粒度流水线掩盖延迟**：MegaMoE² 将原本粗粒度的 EP 过程切分为微小波次，使单卡在进行硬件矩阵计算的同时后台 DMA/RDMA 传输下一波次数据，彻底打破了通信带宽对 MoE 推理/训练扩展的硬性限制。

8. 实验与指标：证据是否支撑主张

8.1 实验问题与判定标准

- **长上下文效率与显存**：在 1M 上下文下，能否大幅降低单 Token 推理 FLOPs 和 KV Cache 占用？判定标准为对比 DeepSeek-V3.2 的相对降幅。
- **通用与前沿智能水平**：在知识、推理、编程与 Agentic 基准上能否达到开源/闭源 SOTA？判定标准为 SimpleQA Verified、Codeforces Rating、SWE Verified 等得分。
- **长程检索与形式化证明**：在 1M 序列检索与 Lean 4 证明中表现如何？判定标准为 MRCL 8-needle MMR 曲线与 PutnamBench 成功率。

8.2 数据、任务、对比与运行设置

- **预训练设置**：DeepSeek-V4-Flash 预训练语料 32T Tokens，DeepSeek-V4-Pro 预训练语料 33T Tokens。
- **对比基线**：DeepSeek-V3.2, GPT-5.4-xHigh, Claude-Opus-4.6-Max, Gemini-3.1-Pro-High, Seed-2.0-Pro 等。
- **推理与计算设置**：原生支持 1M Token 上下文；包含 Non-think, Think High, Think Max 三种推理模式。集群硬件拓扑细节文中未说明。

8.3 指标字典与对应公式 (1) 1M 上下文单 Token 推理 FLOPs 相对比例

- **指标与方向**：1M 上下文单 Token 推理 FLOPs 相对 DeepSeek-V3.2 的比例（%），越小越好。
- **定义与公式**：**基于文中逻辑的推断** 推理依据：以 DeepSeek-V3.2 1M 单 Token FLOPs 为分母，DeepSeek-V4 FLOPs 为分子得到的百分比。
- **来源层级**：推导关系（非原文公式）【基于文中逻辑的推断】，文中未给出 Eq. 编号。
- **实验用途**：评估长上下文计算效率。
- **读数与边界**：DeepSeek-V4-Pro 为 27%（降低 3.7 倍），Flash 为 10%（降低 9.8 倍）。

(2) 1M 上下文 KV Cache 占用相对比例

- **指标与方向**：1M 上下文 KV Cache 体积相对 DeepSeek-V3.2 的比例（%），越小越好。

- **定义与公式：** **基于文中逻辑的推断** 推理依据：以 DeepSeek-V3.2 1M KV Cache 尺寸为分母，DeepSeek-V4 尺寸为分子得到的百分比。
- **来源层级：** 推导关系（非原文公式） [基于文中逻辑的推断]，文中未给出 Eq. 编号。
- **实验用途：** 评估长上下文显存节省。
- **读数与边界：** DeepSeek-V4-Pro 为 10%（约 5.2 GB，小 9.5 倍），Flash 为 7%（约 3.6 GB，小 13.7 倍）。

(3) mHC 双随机矩阵约束 (Doubly Stochastic Constraint)

- **指标与方向：** 残差映射矩阵 B_l 的约束流形 $\mathcal{M}$ 。
- **定义与公式：**

$$B_l \in \mathcal{M} := \{M \in \mathbb{R}^{n \times n} \mid M\mathbf{1}_n = \mathbf{1}_n, \mathbf{1}_n^T M = \mathbf{1}_n^T, M \geq 0\}$$

- **来源层级：** 原文公式，2.2 节。
- **实验用途：** 保证深层网络信号传输的非膨胀性与稳定性。
- **读数与边界：** 每行每列和均为 1，有效消除数值爆炸。

(4) Sinkhorn-Knopp 归一化迭代

- **指标与方向：** 流形投影迭代算子。
- **定义与公式：**

$$M^{(0)} = \exp(\tilde{B}_l), \quad M^{(t)} = \mathcal{T}_r(\mathcal{T}_c(M^{(t-1)}))$$

- **来源层级：** 原文公式，2.2 节 ($t_{\max} = 20$)。
- **实验用途：** 动态将无约束参数映射为双随机矩阵。
- **读数与边界：** 迭代 20 次即可精准逼近流形。

(5) 混合 Newton-Schulz 迭代 (Muon 优化器)

- **指标与方向：** 动量矩阵正交更新算子。
- **定义与公式：**

$$M_k = aM_{k-1} + b(M_{k-1}M_{k-1}^T)M_{k-1} + c(M_{k-1}M_{k-1}^T)^2M_{k-1}$$

- **来源层级：** 原文公式，算法 1 及 2.4 节。
- **实验用途：** 矩阵参数正交化加速收敛。
- **读数与边界：** 前 8 步与后 2 步采用不同系数。

(6) 专家并行计算通信平衡临界比

- **指标与方向：** 硬件算力与带宽比值 C/B (FLOPs/Byte)。
- **定义与公式：**

$$\frac{C}{B} \leq 2d = 6144 \text{ FLOPs/Byte}$$

- **来源层级：** 原文公式，3.1 节。
- **实验用途：** 确定 EP 重叠无瓶颈的理论硬件算力带宽阈值。
- **读数与边界：** 对 SwiGLU 专家维度 $d = 3072$ 成立。

(7) 在线策略蒸馏目标损失 (OPD Loss)

- **指标与方向：** 多教师逆 KL 蒸馏损失，越小越好。
- **定义与公式：**

$$\mathcal{L}_{\text{OPD}}(\theta) = \sum_{i=1}^N w_i \cdot D_{\text{KL}}(\pi_{\theta} \parallel \pi_{E_i})$$

- **来源层级：** 原文公式，5.1.2 节。
- **实验用途：** 在学生模型上融合 $N > 10$ 个领域专家能力。
- **读数与边界：** 结合全词表 Logits 实现无震荡蒸馏。

(8) Codeforces 期望 Rating 分数

- **指标与方向：** 竞技编程综合评分，越大越好。
- **定义与公式：** **基于文中逻辑的推断** 推理依据：无放回采样 10 个解题序列，结合人类失败扣分映射 Rank 并转化为 Codeforces Rating 求期望。
- **来源层级：** 推导关系（非原文公式） [基于文中逻辑的推断]，5.3.1 节。
- **实验用途：** 评价顶尖编程推理能力。
- **读数与边界：** DeepSeek-V4-Pro-Max 达到 3206。

8.4 主结果、消融与证据边界 比较工作与被批判限制的呼应

比较工作 / 基线方法	核心限制或失效条件	本文对应模块	直接实验与仍未验证的边界
DeepSeek-V3.2	1M 上下文 FLOPs/KV 占用高；多轮 Agent 清空思考痕迹。	CSA+HCA 混合注意力、Interleaved Thinking	Figure 1 FLOPs/KV 实验；TerminalBench 2.0 (46.5% vs 67.9%)。
朴素超连接 (Naive HC)	深层堆叠遭遇数值不稳定。	流形约束超连接 (mHC)	预训练稳定性陈述与 Sinkhorn-Knopp 约束。
粗粒度 EP (Comet)	小 Batch 长尾通信无法完全掩盖。	MegaMoE ² 细粒度 Expert Wave 重叠	理论加速比 $1.92\times$ vs $1.42\times$ ，端到端实测 $1.50\sim 1.96\times$ 。
Token 级 KL OPD	蒸馏方差极高，训练剧烈震荡。	全词表 Logit On-Policy Distillation	5.1.2 节多专家无损融合结果。

主张地图与证据表

主张	直接证据（实验/表图）	证据强度与边界
作者明确陈述 1M 上下文下大幅降低 FLOPs 与 KV Cache 占用	Figure 1 Panel 2/3 折线图与读数	强 ：Pro 单 Token FLOPs 降至 27%，KV Cache 降至 10%。
作者明确陈述 核心基准达到开源 SOTA 及对标顶尖闭源	Figure 1 Panel 1 柱状图、表 1/表 6	强 ：SimpleQA 57.9%，Codeforces 3206, SWE-Verified 80.6%。
作者明确陈述 形式化数学证明突破前沿上限	Figure 8 (Putnam-200 / Putnam-2025)	强 ：Putnam-200 得分 81.00 ($2.28\times$ 基线)，Putnam-2025 达 120/120 满分。
基于文中逻辑的推断 测试时扩展展现单调上升 Scaling 特性	Figure 10 (HLE / TerminalBench 2.0)	中 ：Pass@1 随思考 Token 增加单调上升；边界在于具体思考长度上限受上下文约束。

- **关键实验解释**：实验表明 DeepSeek-V4-Pro-Max 在基础知识与 Agentic 任务上全面超越前代与开源同类，且在 1M 序列下保持显著的开销优势；但在纯指令遵循（Instruction Following: 87.76 vs 88.88）和复杂视觉排版美学上微弱落后于 Opus-4.6-Max。

9. 图表解读与论证关系

Figure 1 consists of three panels. Panel 1 is a bar chart titled 'Knowledge & Reasoning' and 'Agentic Capabilities' comparing accuracy/length (%) of DeepSeek-V4-Pro-Max, Claude-Opus 4.6-Max, GPT-5.4-High, and Gemini-3.1-Pro-High across various benchmarks. Panel 2 is a line chart titled 'Single-Token FLOPs (T)' showing inference FLOPs for DeepSeek-V3.2, DeepSeek-V4-Pro, and DeepSeek-V4-Flash up to 1024K token positions. Panel 3 is a line chart titled 'Accumulated KV Cache (GB)' showing KV cache size for the same models up to 1024K sequence length.

Benchmark	DeepSeek-V4-Pro-Max	Claude-Opus 4.6-Max	GPT-5.4-High	Gemini-3.1-Pro-High
SimpleQA	57.9	57.9	57.9	57.9
Codeforces	3206	3206	3206	3206
SWE-Verified	80.6	80.6	80.6	80.6
TerminalBench 2.0	46.5	67.9	67.9	67.9

Token Position (K)	DeepSeek-V3.2	DeepSeek-V4-Pro	DeepSeek-V4-Flash
0	0.0	0.0	0.0
256	0.2	0.03	0.03
512	0.4	0.06	0.06
768	0.6	0.09	0.09
1024	0.8	0.12	0.12

Sequence Length (K)	DeepSeek-V3.2	DeepSeek-V4-Pro	DeepSeek-V4-Flash
0	0	0	0
256	10	1.1	1.1
512	20	2.2	2.2
768	30	3.3	3.3
1024	40	4.4	4.4

图组解读 实验结论 呼应：第 8 节：通用与前沿智能水平

- **图组结论**：DeepSeek-V4-Pro-Max 在 7 项核心基准上表现顶尖；在 1M 上下文下，V4-Pro 单 Token 推理 FLOPs 降低 3.7 倍，KV Cache 降至 5.2 GB（小 9.5 倍）。
- **论证关系**：支撑“1M 超长上下文高效推理”与“通用能力树立开源 SOTA”两大核心主张。
- **适用范围**：覆盖 0~1024K 序列长度分析及 7 项评测基准。

Figure 1 | Left: benchmark performance of DeepSeek-V4-Pro-Max and its counterparts. Right: inference FLOPs and KV cache size of DeepSeek-V4 series and DeepSeek-V3.2.




Figure 9 | DeepSeek-V4 series performance on the MRCR task.

图组解读 **实验结论** 呼应：第 8 节：长程检索与形式化证明

- **图组结论**：8k~128k 上下文内召回率在 0.85~0.94；扩展至 1M 时 Pro-Max 保持 0.59，Flash-Max 保持 0.49。
- **论证关系**：定量界定混合注意力在超长序列下的多针检索效能与衰减边界。
- **适用范围**：MRCR 8-needle 8k~1024k 评估。




Figure 8 | Formal reasoning under practical and frontier regimes. Left: Putnam-200 Pass@8 evaluates a fixed random subset of PutnamBench (Tsoukalas et al., 2024) following the setup introduced by Seed-Prover; all models are tested on the same problem set. We follow the Seed-Prover protocol but replace proprietary search tools with the open-source LeanExplore (Asher, 2025), yielding a lightweight setting with minimal agent tools and bounded sampling. Right: Putnam-2025 probes the frontier of mathematical reasoning in a scaled hybrid formal-informal regime, where informal reasoning is combined with formal verification to expose gaps and improve rigor; DeepSeek-V4 reaches a proof-perfect 120/120.

图组解读 **实验结论** 呼应：第 8 节：长程检索与形式化证明

- **图组结论**：Flash-Max 在 Putnam-200 Pass@8 达 81.00 分 ($2.28 \times$ 基线)；Putnam-2025 达到 120/120 满分。
- **论证关系**：支撑模型在前沿形式化数学推理与测试时扩展上的效果主张。
- **适用范围**：Lean 4.28 形式化证明环境。




Figure 10 | HLE and Terminal Bench 2.0 performance by reasoning effort. "None" indicates Non-think mode, and "Speciale" indicates DeepSeek-V3.2-Speciale model.

图组解读 **实验结论** 呼应：第 8 节：通用与前沿智能水平

- **图组结论**：Pass@1 随思考 Token 增加呈单调上升趋势，Pro Max 模式在 HLE 达 37.8%，TerminalBench 2.0 达 67.9%。
- **论证关系**：验证 Post-Training RL 导出的 Reasoning Effort 模式的测试时扩展有效性。
- **适用范围**：HLE 与 TerminalBench 2.0 评测。




Figure 12 | Detailed dimension scores including Task Completion, Content Quality, Formatting Aesthetics, and Instruction Following.

图组解读 **实验结论** 呼应：第8节：通用与前沿智能水平

- **图组结论:** DeepSeek-V4-Pro-Max 在任务完成度 (98.32) 与内容质量 (83.32) 上超越 Opus-4.6-Max, 在指令遵循上 (87.76 vs 88.88) 微弱落后。
- **论证关系:** 提供真实白领 Agent 场景下的定量效果证据, 界定能力优势与特定局限。
- **适用范围:** 30 项白领办公实操评测集。



Figure 13 | Example output of a task which requires drafting a joint marketing proposal for a popular bubble tea brand and the Beijing Subway.

图组解读 **实验结论** 呼应：第8节：通用与前沿智能水平

- **图组结论：**生成包含完整商业策划框架与多达 25 页的结构化方案，展示了极长 Output 生成力。
- **论证关系：**提供复杂 Agent 场景下的定性样例文证，直观印证长上下文与格式化写作能力。
- **适用范围：**奶茶品牌与北京地铁联合营销策划案生成样例。

表格证据: Table 1 | Comparison among DeepSeek-V3.2-Base, DeepSeek-V4-Flash-Base, and DeepSeek-V4-Pro-Base. All models are evalu... 对比基线 呼应: 第 8 节: 数据、任务、对比与运行设置

- **图组结论:** DeepSeek-V4 Base 模型在绝大多数基础能力评测上全面超越前代 DeepSeek-V3.2-Base。
- **论证关系:** 验证 Base 模型架构升级 (CSA/HCA/mHC) 带来的基础智能提升。
- **适用范围:** 内部评估框架下的基座模型综合评测。

Benchmark (Metric)		# Shots	DeepSeek-V3.2 Base	DeepSeek-V4-Flash Base	DeepSeek-V4-Pro Base
Architecture		-	MoE	MoE	MoE
# Activated Params		-	37B	13B	49B
# Total Params		-	671B	284B	1.6T
World Knowl.	AGIEval (EM)	0-shot	80.1	82.6	83.1
	MMLU (EM)	5-shot	87.8	88.7	90.1
	MMLU-Redux (EM)	5-shot	87.5	89.4	90.8
	MMLU-Pro (EM)	5-shot	65.5	68.3	73.5
	MMMLU (EM)	5-shot	87.9	88.8	90.3
	C-Eval (EM)	5-shot	90.4	92.1	93.1
	CMMLU (EM)	5-shot	88.9	90.4	90.8
	MultiLoKo (EM)	5-shot	38.7	42.2	51.1
	Simple-QA verified (EM)	25-shot	28.3	30.1	55.2
	SuperGPQA (EM)	5-shot	45.0	46.5	53.9
	FACTS Parametric (EM)	25-shot	27.1	33.9	62.6
	TriviaQA (EM)	5-shot	83.3	82.8	85.6
Lang. & Reas.	BBH (EM)	3-shot	87.6	86.9	87.5
	DROP (F1)	1-shot	88.2	88.6	88.7
	HellaSwag (EM)	0-shot	86.4	85.7	88.0
	WinoGrande (EM)	0-shot	78.9	79.5	81.5
	CLUEWSC (EM)	5-shot	83.5	82.2	85.2

表格证据: Table 2 | Comparison of three reasoning modes 消融验证 呼应: 第 8 节: 数据、任务、对比与运行设置

- **图组结论:** Non-think、Think High 与 Think Max 三种推理模式展现出清晰的性能与算力阶梯。
- **论证关系:** 支撑测试时扩展与多推理模式设计的有效性。
- **适用范围:** DeepSeek-V4 序列推理模式对比。

Reasoning Mode	Characteristics	Typical Use Cases	Response Format
Non-think	Fast, intuitive responses based on habits or simple rules.	Routine daily tasks, emergency reactions, low-risk decisions.	</think> summary
Think High	Conscious logical analysis, slower but more accurate.	Complex problem-solving, planning, medium-risk decisions.	<think> thinking tokens </think> summary
Think Max	Push reasoning to its fullest extent. Slow but powerful.	Exploring the boundary of model reasoning capability.	1. A special system prompt at the beginning. 2. <think> thinking tokens </think> summary

表格证据：Table 5 | Quick Instruction special tokens for auxiliary tasks. 方法流水线 呼应：第 6 节：Post-Training

范式（GRM + OPD + Interleaved Thinking）

- **图组结论**：定义了快捷指令与辅助任务对应的专用特殊 Token 集合。
- **论证关系**：展示后训练阶段控制模型行为与任务调配的机制规范。
- **适用范围**：模型辅助任务指令接口设计。

Special Token	Description	Format
< action >	Determines whether the user prompt requires a web search or can be answered directly.	...< User >{prompt}< Assistant ><think>< action >
< title >	Generates a concise conversation title after the first assistant response.	...< Assistant >{response}< end_of_sentence >< title >
< query >	Generates search queries for the user prompt.	...< User >{prompt}< query >
< authority >	Classifies the user prompt's demand for source authoritativeness.	...< User >{prompt}< authority >
< domain >	Identifies the domain of the user prompt.	...< User >{prompt}< domain >
< extracted_url >	Determines whether each < read_url >	...< User >{prompt}< extracted_url >< read_url >

表格证据：Table 6 | Comparison between DeepSeek-V4-Pro-Max and closed/open source models. “Max” , “xHigh” , and “High” denote rea... 实验结论 呼应：第 8 节：通用与前沿智能水平

- **图组结论**：DeepSeek-V4-Pro-Max 在知识、编程与数学等多项前沿 Benchmark 上超越主流开源及闭源顶尖模型。
- **论证关系**：支撑模型达到开源 SOTA 及对标顶级闭源模型的核心主张。
- **适用范围**：通用与前沿智能综合评测集。

Benchmark (Metric)		Opus-4.6 GPT-5.4 Gemini-3.1-Pro			K2.6 Thinking	GLM-5.1 Thinking	DS-V4-Pro Max
		Max	xHigh	High			
Knowledge & Reasoning	MMLU-Pro (EM)	89.1	87.5	91.0	87.1	86.0	87.5
	SimpleQA-Verified (Pass@1)	46.2	45.3	75.6	36.9	38.1	57.9
	Chinese-SimpleQA (Pass@1)	76.4	76.8	85.9	75.9	75.0	84.4
	GPQA Diamond (Pass@1)	91.3	93.0	94.3	90.5	86.2	90.1
	HLE (Pass@1)	40.0	39.8	44.4	36.4	34.7	37.7
	LiveCodeBench (Pass@1)	88.8	-	91.7	89.6	-	93.5
	Codeforces (Rating)	-	3168	3052	-	-	3206
	HMMT 2026 Feb (Pass@1)	96.2	97.7	94.7	92.7	89.4	95.2
	IMOAnswerBench (Pass@1)	75.3	91.4	81.0	86.0	83.8	89.8
	Apex (Pass@1)	34.5	54.1	60.9	24.0	11.5	38.3
	Apex Shortlist (Pass@1)	85.9	78.1	89.1	75.5	72.4	90.2
Long	MRRCR 1M (MMR)	92.9	-	76.3	-	-	83.5
	CorpusQA 1M (ACC)	71.7	-	53.8	-	-	62.0
Agentic	Terminal Bench 2.0 (Acc)	65.4	75.1	68.5	66.7	63.5	67.9
	SWE Verified (Resolved)	80.8	-	80.6	80.2	-	80.6
	SWE Pro (Resolved)	57.3	57.7	54.2	58.6	58.4	55.4
	SWE Multilingual (Resolved)	77.5	-	-	76.7	73.3	76.2
	BrowseComp (Pass@1)	83.7	82.7	85.9	83.2	79.3	83.4
	HLE w/ tools (Pass@1)	53.1	52.0	51.6	54.0	50.4	48.2
	GDPval-AA (Elo)	1619	1674	1314	1482	1535	1554
	MCPAtlas Public(Pass@1)	73.8	67.2	69.2	66.6	71.8	73.6
	Toolathlon (Pass@1)	47.2	54.6	48.8	50.0	40.7	51.8

表格证据: Table 7 | Comparison among different sizes and modes of DeepSeek-V4 series. “Non-Think”, “High”, and “Max” denote rea... 实验结论 呼应：第 8 节：通用与前沿智能水平

- **图组结论**：详细给出了 Pro 与 Flash 在不同思考模式（Non-Think、High、Max）下的完整 Benchmark 成绩。
- **论证关系**：全面展现 DeepSeek-V4 系列模型在不同尺寸与推理算力分配下的性能全貌。
- **适用范围**：DeepSeek-V4 全系全模式能力评估。

Benchmark (Metric)		DeepSeek-V4-Flash			DeepSeek-V4-Pro		
		Non-Think	High	Max	Non-Think	High	Max
Knowledge & Reasoning	MMLU-Pro (EM)	83.0	86.4	86.2	82.9	87.1	87.5
	SimpleQA-Verified (Pass@1)	23.1	28.9	34.1	45.0	46.2	57.9
	Chinese-SimpleQA (Pass@1)	71.5	73.2	78.9	75.8	77.7	84.4
	GPQA Diamond (Pass@1)	71.2	87.4	88.1	72.9	89.1	90.1
	HLE (Pass@1)	8.1	29.4	34.8	7.7	34.5	37.7
	LiveCodeBench (Pass@1-COT)	55.2	88.4	91.6	56.8	89.8	93.5
	Codeforces (Rating)	-	2816	3052	-	2919	3206
	HMMT 2026 Feb (Pass@1)	40.8	91.9	94.8	31.7	94.0	95.2
	IMOAnswerBench (Pass@1)	41.9	85.1	88.4	35.3	88.0	89.8
	Apex (Pass@1)	1.0	19.1	33.0	0.4	27.4	38.3
	Apex Shortlist (Pass@1)	9.3	72.1	85.7	9.2	85.5	90.2
Long	MRCR 1M(MMR)	37.5	76.9	78.7	44.7	83.3	83.5
	CorpusQA 1M(ACC)	15.5	59.3	60.5	35.6	56.5	62.0
Agentic	Terminal Bench 2.0 (Acc)	49.1	56.6	56.9	59.1	63.3	67.9
	SWE Verified (Resolved)	73.7	78.6	79.0	73.6	79.4	80.6
	SWE Pro (Resolved)	49.1	52.3	52.6	52.1	54.4	55.4
	SWE Multilingual (Resolved)	69.7	70.2	73.3	69.8	74.1	76.2
	BrowseComp (Pass@1)	-	53.5	73.2	-	80.4	83.4
	HLE w / tools (Pass@1)	-	40.3	45.1	-	44.7	48.2
	MCPAtlas Public (Pass@1)	64.0	67.4	69.0	69.4	74.2	73.6
	GDPval-AA (Elo)	-	-	1395	-	-	1554
	Toolathlon (Pass@1)	40.7	43.5	47.8	46.3	49.0	51.8

表格证据: Table 8 | Comparison on R&D Coding Benchmark (external models included strictly for evaluation purposes). 实验结论 呼应：第 8 节：通用与前沿智能水平

- **图组结论**：DeepSeek-V4-Pro 在研发编程基准（SWE Verified 等）上取得领先表现。
- **论证关系**：验证模型在真实软件工程与研发代码生成任务上的前沿能力。
- **适用范围**：研发编程基准评测。

Model	Haiku 4.5	Sonnet 4.5	DeepSeek-V4-Pro-Max	Opus 4.5	Opus 4.5 Thinking	Opus 4.6 Thinking
Pass Rate (%)	13	47	67	70	73	80

表格证据: Table 9 | Agentic Search vs. Retrieval Augmented Search for DeepSeek-V4-Pro. 消融验证 呼应：第 8 节：通用与前沿智能水平

- **图组结论**：Agentic Search 相较于传统的 Retrieval Augmented Search 显著提高了复杂搜索问答准确率。
- **论证关系**：验证动态 Agent 工具调用搜索策略优于被动检索增强范式。
- **适用范围**：复杂搜索问答评估集。

Hard	Objective Q&A (客观问答)	168	102	33	33	60.7	19.6	19.6
	Subjective Q&A (主观问答)	184	126	27	31	68.5	14.7	16.8

表格证据: Table 10 | Cost Comparison: Agentic Search vs. Retrieval Augmented Search (Mean) for DeepSeek-V4-Pro. Most of the too... 实验结论 呼应: 第 8 节: 通用与前沿智能水平

- **图组结论:** Agentic Search 通过并行工具调用保持了合理的开销与时延。
- **论证关系:** 证明主动 Agent 搜索在带来准确率提升的同时具备工程可行性与开销优势。
- **适用范围:** 搜索问答任务开销与延迟分析。

Version	Tool Calls	Prefill (tokens)	Output (tokens)
V4 Agentic Search	16.2	13649	1526
V4 Retrieval Augmented Search	—	10453	1308

表格证据: Table 11 | Comparative Evaluation of DeepSeek-V4-Pro and DeepSeek-V3.2 on Search Q&A Tasks.

对比基线 呼应: 第 8 节: 通用与前沿智能水平

- **图组结论:** DeepSeek-V4-Pro 在搜索问答任务上的综合得分与准确度显著超越前代 DeepSeek-V3.2。
- **论证关系:** 验证架构与后训练升级对信息检索与综合理解能力的迭代提升。
- **适用范围:** 搜索问答基准对比。

Category	Subcategory	#	Internal Evaluation (内部综合评估)					
			V4 win	V3.2 win	tie	V4%	V3.2%	tie%
Objective Q&A (客观问答)	Single-value Search (单值信息查找)	95	36	10	49	37.9	10.5	51.6
	Entity Search (实体信息查找)	99	24	7	68	24.2	7.1	68.7
	Enumerative Search (枚举型信息查找)	95	19	8	68	20.0	8.4	71.6
	Subtotal (小计)	289	79	25	185	27.3	8.7	64.0
Subjective Q&A (主观问答)	Causal Analysis (原因分析)	100	28	5	67	28.0	5.0	67.0
	Comparison (对比)	96	28	20	48	29.2	20.8	50.0
	Advice Seeking (寻求建议)	92	23	8	61	25.0	8.7	66.3
	Recommendation (推荐)	95	26	19	50	27.4	20.0	52.6
	Planning & Strategy (攻略计划)	92	32	11	49	34.8	12.0	53.3
	Opinion & Evaluation (评价看法)	96	30	8	58	31.2	8.3	60.4
	Trend Analysis (趋势分析)	96	23	3	70	24.0	3.1	72.9
	Subtotal (小计)	667	190	74	403	28.5	11.1	60.4
TOTAL (总计)		956	269	99	588	28.1	10.4	61.5

表格证据：Table 12 | Comparative Analysis of DeepSeek-V4-Pro and Gemini-3.1-Pro in Chinese Functional Writing. **实验结论** 呼应：第 8 节：通用与前沿智能水平

- **图组结论**：DeepSeek-V4-Pro 在中文实用功能写作（公文、报告等）中相比 Gemini-3.1-Pro 表现出更高质量。
- **论证关系**：支撑模型在中文长文本与复杂实用写作任务中的领先优势。
- **适用范围**：中文实用功能写作评测。

Category	Subcategory	#	Internal Evaluation (内部综合评估)					
			DS win	Gem win	Tie	DS%	Gem%	Tie%
Business Writing (办公文本)	Report (报告)	527	350	162	15	66.41	30.74	2.85
	Proposal (方案策划)	291	181	103	7	62.20	35.40	2.41
	Education (教育培训)	159	100	56	3	62.89	35.22	1.89
	Email & Letter (邮件书信)	146	107	37	2	73.29	25.34	1.37
	Notice (通知公告)	72	43	24	5	59.72	33.33	6.94
	Professional (专业文本)	63	34	27	2	53.97	42.86	3.17
	Recruitment (招聘求职)	42	27	15	0	64.29	35.71	0.00
	Technical (技术文本)	29	22	7	0	75.86	24.14	0.00
	Review (介绍评价)	20	15	5	0	75.00	25.00	0.00
	Subtotal (小计)	1349	879	436	34	65.16	32.32	2.52
Media Writing (媒体文本)	Social Media (社交媒体文案)	267	156	101	10	58.43	37.83	3.75
	Ad Copy (广告商品文案)	214	109	98	7	50.93	45.79	3.27
	Long-form Content (内容平台长文)	99	71	25	3	71.72	25.25	3.03
	News Report (新闻报道)	51	27	22	2	52.94	43.14	3.92
	Advertorial (营销软文)	17	12	4	1	70.59	23.53	5.88
	Headline (标题)	11	7	4	0	63.64	36.36	0.00
	Narration Script (口播文案)	4	2	1	1	50.00	25.00	25.00
	Comment (评论)	3	2	1	0	66.67	33.33	0.00
	Subtotal (小计)	666	386	256	24	57.96	38.44	3.60
Everyday Writing (生活文本)	Congratulatory (祝贺文本)	101	54	41	6	53.47	40.59	5.94
	Communication (沟通回复)	100	71	26	3	71.00	26.00	3.00
	Reflection (心得感想)	90	68	17	5	75.56	18.89	5.56
	Review (介绍评价)	55	44	9	2	80.00	16.36	3.64
	Comment (评论)	44	34	8	2	77.27	18.18	4.55
	Subtotal (小计)	390	271	101	18	69.49	25.90	4.62
Oral Writing (口头文本)	Speech (发言稿)	226	135	85	6	59.73	37.61	2.65
	Narration Script (口播文案)	51	25	23	3	49.02	45.10	5.88
	Sales Script (话术)	31	22	6	3	70.97	19.35	9.68
	Dialogue (对话文本)	10	4	6	0	40.00	60.00	0.00
	Congratulatory (祝贺文本)	1	1	0	0	100.00	0.00	0.00
	Subtotal (小计)	319	187	120	12	58.62	37.62	3.76
Official Document (公文文本)	Administrative Doc (事务文书)	117	60	53	4	51.28	45.30	3.42
	Personal Doc (个人文书)	73	45	27	1	61.64	36.99	1.37
	Government Doc (行政公文)	34	19	14	1	55.88	41.18	2.94
	Speech (发言稿)	3	1	2	0	33.33	66.67	0.00
	Essay Writing (申论写作)	3	1	1	1	33.33	33.33	33.33
	Subtotal (小计)	230	126	97	7	54.78	42.17	3.04
Academic Writing (学术文本)	Research Paper (学术论文)	104	67	32	5	64.42	30.77	4.81
	Coursework (课程作业)	90	53	35	2	58.89	38.89	2.22
	Academic Support (学术辅助)	15	11	3	1	73.33	20.00	6.67
	Science Outreach (专业科普)	7	6	1	0	85.71	14.29	0.00
	Subtotal (小计)	216	137	71	8	63.43	32.87	3.70
Total (总计)		3170	1986	1081	103	62.65	34.10	3.25

表格证据: Table 13 | Comparative Analysis of DeepSeek-V4-Pro and Gemini-3.1-Pro in Chinese Creative

Writing. 实验结论 呼应: 第 8 节: 通用与前沿智能水平

- **图组结论:** DeepSeek-V4-Pro 在中文创意写作（故事、文案等）中展现出优异的文采与文脉连贯性。
- **论证关系:** 验证模型在长程创作与表达丰富度上的优越性能。
- **适用范围:** 中文创意写作评测。

Subcategory (文体)	#	Instruction Following(指令遵循)						Writing Quality (写作质量)					
		DS	Gem	Tie	DS%	Gem%	Tie%	DS	Gem	Tie	DS%	Gem%	Tie%
Fiction (小说故事)	836	504	323	5	60.58	38.82	0.60	672	157	3	80.77	18.87	0.36
General Fiction (泛小说故事)	662	368	290	3	55.67	43.87	0.45	467	194	0	70.65	29.35	0.00
Fan Fiction (同人文)	410	253	150	3	62.32	36.95	0.74	338	67	1	83.25	16.50	0.25
General Fan Fic. (泛同人文)	202	111	90	1	54.95	44.55	0.50	161	40	1	79.70	19.80	0.50
Narrative (记叙文)	171	115	54	2	67.25	31.58	1.17	141	30	0	82.46	17.54	0.00
General Prose (泛散文)	124	83	40	1	66.94	32.26	0.81	88	36	0	70.97	29.03	0.00
Prose (散文)	112	74	38	0	66.07	33.93	0.00	92	20	0	82.14	17.86	0.00
Writing Style (文笔)	112	81	31	0	72.32	27.68	0.00	86	26	0	76.79	23.21	0.00
Classical Poetry (古诗文)	48	24	24	0	50.00	50.00	0.00	39	9	0	81.25	18.75	0.00
Modern Poetry (现代诗)	43	23	20	0	53.49	46.51	0.00	32	11	0	74.42	25.58	0.00
Lyrics (歌词)	30	8	22	0	26.67	73.33	0.00	16	14	0	53.33	46.67	0.00
Literary Appreciation (赏析)	27	20	7	0	74.07	25.93	0.00	18	9	0	66.67	33.33	0.00
General Argument. (泛议论文)	24	15	9	0	62.50	37.50	0.00	17	7	0	70.83	29.17	0.00
General Narrative (泛记叙文)	23	11	12	0	47.83	52.17	0.00	15	8	0	65.22	34.78	0.00
General Classical (泛古文诗歌)	9	5	4	0	55.56	44.44	0.00	5	4	0	55.56	44.44	0.00
Creative Writing (创意写作)	6	2	4	0	33.33	66.67	0.00	4	2	0	66.67	33.33	0.00
Argumentative (议论文)	5	5	0	0	100.00	0.00	0.00	5	0	0	100.00	0.00	0.00
General Mod. Poetry (泛现代诗)	2	1	1	0	50.00	50.00	0.00	2	0	0	100.00	0.00	0.00
Total (总计)	2837	1703	1119	15	60.03	39.44	0.53	2198	634	5	77.48	22.35	0.18

表格证据: Table 14 | DeepSeek-V4-Pro vs. Claude-Opus-4.5 on Complex Instruction Following and Multi-Turn

Writing. 适用边界 呼应: 第 8 节: 通用与前沿智能水平

- **图组结论:** DeepSeek-V4-Pro 在多轮长写作中优势明显，但在部分极端复杂的严格指令遵循上与顶尖闭源模型互有胜负。
- **论证关系:** 客观界定模型在复杂指令遵循与多轮写作上的能力定位与适用边界。
- **适用范围:** 复杂指令遵循与多轮长写作评测。

Category	#	Internal Evaluation (内部综合评估)					
		DS	Opus	Tie	DS%	Opus%	Tie%
Complex Inst. Following (复杂指令跟随)	49	23	26	0	46.9%	53.1%	0.0%
Multi-Turn Writing (多轮写作)	147	67	76	4	45.6%	51.7%	2.7%
Total (总计)	196	90	102	4	45.9%	52.0%	2.0%

10. 完整因果推理树

- 根问题: 1M 超长上下文下的巨额计算 FLOPs 与 KV Cache 显存墙及测试时扩展受阻
 - ▶ 旧方法限制: 标准 Vaswani 注意力二次方爆炸; DeepSeek-V3.2 在 1M 下开销仍大且多轮 Agent 清空思考; 朴素 HC 数值不稳定; 粗粒度 EP 通信无法隐蔽
 - ▶ 核心洞见/假设: 长上下文依赖具备“局部精细+全局概要”层次分工; 残差映射谱范数需界定在双随机流形上; 细粒度 Wave 重叠可完全掩盖 EP 通信
 - 方法模块: CSA ($m = 4$ 压缩稀疏)、HCA ($m' = 128$ 重度压缩稠密)、mHC (Sinkhorn-Knopp 双随机投影)、MegaMoE² (细粒度 Wave EP)、OPD (全词表逆 KL 蒸馏) 与 Interleaved Thinking
 - 可验证预测: 1M 上下文 FLOPs 与 KV Cache 大幅下降; 深层训练不发生梯度爆炸; EP 得到 $1.5\times$ 端到端加速; 形式化证明与 Agent 任务显著超越基线
 - ▶ 指标与实验: 1M 单 Token FLOPs/KV Cache 百分比; Codeforces/SimpleQA/SWE-Verified/Putnam 成绩; TerminalBench 2.0 准确率
 - 图表证据: Figure 1 (FLOPs/KV 折线与能力柱状图)、Figure 5 (MegaMoE² 流水线)、Figure 8 (MRCR 检索)、Figure 9 (Putnam 证明)、Figure 10 (Reasoning Effort 扩展)

· 结论与适用边界: 验证了 1M 上下文高效推理与开源 SOTA 能力; 适用边界为 128k 后 MRCC 召回有自然衰减, 严格指令遵循与视觉排版美学仍有微小改进空间。

11. 结论、贡献与边界

- **贡献总结:** **作者明确陈述** 提出 CSA+HCA 混合注意力架构、流形约束超连接 (mHC)、Muon 优化器规模化实践、MegaMoE² 细粒度 EP 重叠算子、全词表 OPD 多教师蒸馏范式, 并成功训练并开源了原生支持 1M 上下文的 DeepSeek-V4 系列模型。
- **证据充分的结论:** **实验支持** 1M 上下文下 DeepSeek-V4-Pro 单 Token 推理 FLOPs 降至 27%, KV Cache 降至 10%; 在 Codeforces (3206)、Putnam-2025 (120/120)、SWE-Verified (80.6%) 等基准上树立了开源前沿 SOTA。
- **尚属推断的意义:** **基于文中逻辑的推断** 混合压缩注意力与 mHC 流形约束的技术路线, 为未来极长上下文 Agent 的实时测试时扩展 (Test-Time Scaling) 与在线学习奠定了通用基础设施范式。
- **适用条件与局限:** 1M 多针检索在 128k 序列之后存在表现衰减; 在纯严格指令遵循和部分 PPT Visual Formatting 视觉艺术美学上微弱落后于顶尖闭源模型。
- **审稿式风险检查:**
 - ▶ 贡献新意: **无明显风险**。CSA+HCA 与 mHC 流形约束构成了显著的技术创新。
 - ▶ 写作/可复现性: **低风险**。模型权重已公开发布, 但在集群硬件拓扑等部分工程设置上写为文中未说明。
 - ▶ 效果大小: **无明显风险**。1M 效率提升 3.7~9.8 倍, 多项 Benchmarks 达到 SOTA。
 - ▶ 实验覆盖: **无明显风险**。覆盖从基础知识、编程、数学形式化证明到白领 Agent 的全面评估。
 - ▶ 方法设计: **低风险**。mHC 数学推导严谨, Sinkhorn-Knopp 迭代保障了稳定性。

12. 术语与第一性原理学习路径

12.1 核心术语

- **压缩稀疏注意力 (Compressed Sparse Attention, CSA):**
 - ▶ 最小定义: 将每 $m = 4$ 个 Token 隐状态压缩为 1 个入口, 并利用 Lightning Indexer 进行 Top- k 稀疏检索的注意力模块。
 - ▶ 第一性原理角色: 在受限显存带宽与算力约束下, 通过牺牲无用历史 Token 的高分辨率存储, 连接高分辨率局部依赖与高精度全局稀疏检索。
 - ▶ 本文位置: DeepSeek-V4 混合注意力架构的核心交替组件之一。
- **重度压缩注意力 (Heavily Compressed Attention, HCA):**
 - ▶ 最小定义: 按 $m' = 128$ 大比例将 Token 压缩为 1 个入口并进行全量稠密 MQA 计算的注意力模块。
 - ▶ 第一性原理角色: 在零稀疏索引开销的约束下, 用极小存储空间连接全局背景语意与高层概要表示。
 - ▶ 本文位置: 与 CSA 交替堆叠构成混合注意力。
- **流形约束超连接 (Manifold-Constrained Hyper-Connections, mHC):**
 - ▶ 最小定义: 将宽残差流映射矩阵通过 Sinkhorn-Knopp 算法强行投影至双随机矩阵流形的残差连接技术。
 - ▶ 第一性原理角色: 受到谱范数 $\|B_l\| \leq 1$ 的数学非膨胀约束, 确保深层信号传播不发生爆炸或衰减。
 - ▶ 本文位置: 替代标准残差连接, 贯穿整个 Transformer Block。
- **Muon 优化器:**
 - ▶ 最小定义: 利用 Newton-Schulz 迭代对矩阵参数进行逼近正交化更新的二阶性质优化器。
 - ▶ 第一性原理角色: 约束参数更新流形正交性, 连接高维矩阵梯度与极速稳定收敛。
 - ▶ 本文位置: 用于预训练与后训练阶段大权重矩阵的参数更新。
- **全词表 On-Policy 蒸馏 (OPD):**
 - ▶ 最小定义: 在学生模型产生的轨迹上, 通过缓存最后一层 Hidden State 重建全词表 Logits, 计算多教师逆 KL 散度的蒸馏范式。
 - ▶ 第一性原理角色: 在极低显存缓存约束下, 无损平滑地连接多领域专家教师能力与单一学生模型。
 - ▶ 本文位置: Post-Training 阶段融合领域专家的核心算法。

12.2 学习路径

1. **基本对象: 注意力机制中的 KV Cache 与算力/显存墙**
 - 通俗解释: 理解大语言模型在生成文本时为什么要保存历史 Key 和 Value 向量, 以及为什么序列变长会导致显存溢出。
2. **约束: 矩阵谱范数与深层网络训练稳定性**
 - 通俗解释: 理解线性代数中矩阵谱范数如何决定向量乘法的缩放, 以及为什么残差连接矩阵范数大于 1 会导致深层网络梯度爆炸。
3. **机制: 双随机矩阵 (Doubly Stochastic Matrix) 与 Sinkhorn-Knopp 算法**
 - 通俗解释: 学习如何通过按行按列交替归一化, 将任意正矩阵转化为每行每列和均为 1 的概率矩阵, 从而实现能量守恒映射。
4. **系统与指标: 计算通信重叠 (Wave Overlapping) 与 1M 上下文推理 FLOPs**
 - 通俗解释: 理解 GPU 算力与通信带宽的瓶颈临界比, 以及如何通过流水线分波段掩盖传输延迟。