

论文解构报告

Frontier: Towards Comprehensive and Accurate LLM Inference Simulation

Yicheng Feng, Xin Tan, Yangtao Deng, Yimin Jiang, Yibo Zhu, Hong Xu

2026

LLM 推理模拟

分离式服务架构

离散事件仿真

性能建模

MoE 并行

代码: <https://github.com/NetX-lab/Frontier>

生成时间: 2026-07-28

目录

摘要翻译	3
1. 一句话总览	3
2. 阅读范围与证据状态	3
3. 根问题：论文究竟要解决什么	3
4. 旧方法为何不够	6
5. 核心洞见与假设	7
6. 方法：从洞见到可执行系统	7
7. 为什么它可能有效	10
8. 实验与指标：证据是否支撑主张	10
9. 图表解读与论证关系	11
10. 完整因果推理树	13
11. 结论、贡献与边界	13
12. 术语与第一性原理学习路径	14

摘要翻译

现代大语言模型 (LLM) 服务已不再是同质化或单体式的。生产系统如今融合了分离式执行、复杂的并行策略、运行时优化技术，以及推理、智能体和强化学习 (RL) rollout 等有状态工作负载。仿真是探索这一不断扩展的设计空间的有效手段，但现有仿真器缺乏其所要求的架构完整性和决策级精度。它们的单体副本抽象难以适配分离式服务架构，而基于平均情形的分析代理模型可能扭曲 SLA 预测，甚至颠倒优化结论。本文提出 Frontier，一个面向现代 LLM 推理服务的离散事件仿真器。Frontier 采用分离式抽象，通过为共置、Prefill-Decode 分离 (PDD) 和 Attention-FFN 分离 (AFD) 架构建模角色专属的集群工作节点，捕捉现代服务系统的结构与动态特性；在调度器-批处理-引擎循环中集成关键运行时优化技术（如 CUDA Graph、推测解码）；并支持面向新兴工作负载的有状态请求。此外，Frontier 还能在具有复杂工作负载组合的多样化服务场景中，提供准确且可泛化的计算、通信与内存开销预测。在 16 卡 H800 GPU 测试平台上，Frontier 的平均吞吐量误差低于 4%。与最先进的仿真器相比，它将端到端延迟误差在共置场景下从 44.9% 降至 6.4%，在分离式场景下从 51.7% 降至 2.6%。Frontier 可在普通 CPU 上扩展至超过 1000 块 GPU 的规模，并支持诸如 SLA 相关的帕累托前沿探索、异构分离式资源分配、智能体推理调度验证以及 RL 后训练重配置等新应用场景。Frontier 已在 <https://github.com/NetX-lab/Frontier> 开源。

1. 一句话总览

论文元数据

字段	内容
标题	Frontier: Towards Comprehensive and Accurate LLM Inference Simulation
作者	Yicheng Feng, Xin Tan, Yangtao Deng, Yimin Jiang, Yibo Zhu, Hong Xu
发表场所 / 年份	文中未说明 / 2026
研究领域	LLM 推理系统、性能仿真
关键词	LLM 推理模拟, 分离式服务架构, 离散事件仿真, 性能建模, MoE 并行

资源链接

- 原始文件：本地上传文件
- arXiv：文中未说明
- DOI：文中未说明
- 代码 / 数据集：<https://github.com/NetX-lab/Frontier>

标签 (3-5 个)： LLM 推理仿真 · 分离式服务架构 PDD-AFD · 离散事件仿真 · MoE 并行性能建模 · KV-cache 容量预测

论文提出离散事件仿真器 Frontier，用"控制面/保真面分离+角色专属集群 worker+运行时适配器"解决现有仿真器架构不完整、精度粗糙两大问题，在 16×H800 实测下平均吞吐误差低于 4%，端到端延迟误差从 44.9%/51.7% 降至 6.4%/2.6% [实验支持]。

2. 阅读范围与证据状态

OCR 覆盖论文第 1-13 页正文及 6 组图表证据（部分为 Table/Figure 混排图片），涵盖摘要、动机、方法、实验（§ 5）与四个使用案例（§ 6）。存在的限制：部分图片柱顶数字因分辨率原因无法逐位核实（如 Table 5 最后一位小数）[无法从当前 OCR 内容确认]；论文原始编号的 Eq. 只有 Eq.1 明确出现，其余公式无编号 [作者明确陈述]；另有 10 张图片超过分析上限未做视觉分析。论文事实与背景知识已在下文逐条标注区分。

3. 根问题：论文究竟要解决什么

问题定义：现代 LLM 推理服务架构（共置→PDD→AFD）、并行策略（TP/PP/DP/EP）、运行时优化（连续批处理、CUDA Graph、投机解码等）与工作负载（MoE、推理链、agent、RL rollout）同时快速演化，使生产部署"极难建模、推理和优化" [作者明确陈述]。

为什么重要：真实硬件扫描代价极高——在 64×H100 上扫描 100 种配置需 12,800-25,600 GPU-小时、最多耗资 18 万美元，导致团队放弃调优、退回保守配置、损失 3-5× 吞吐 [作者明确陈述]。仿真是廉价替代手段，但现有仿真器不满足决策精度要求。

难点来源：一是解耦式架构下不同 GPU 池承担不同角色、需显式跨集群同步，二是运行时优化会改变调度器可见状态而非只是加速系数，三是服务系统是闭环系统（执行成本→内存状态→准入→排队→未来批组成），微小误差会被放大 [作者明确陈述]。

成功标准：仿真预测需在算子/内存/端到端多层面与真实硬件对齐，且不能颠倒优化结论。

本文 story: 旧路线在"单体副本抽象"与"平均情形代理模型"这两个技术选择上失效——前者无法表达 PDD/AFD 的跨集群依赖，后者会低估长度/路由异质性造成的误差，进而在闭环系统中放大为决策错误。本文的转折是把仿真器拆成"控制面（拓扑与调度）"和"保真面（硬件感知预测）"两层分离架构，用校准的算子/内存预测器替代解析代理 [作者明确陈述]。

前排论文大图 问题严重性 呼应：第 3 节：运行时优化会改变调度器可见状态而非只是加速系数





Figure 1. Measured vLLM TPOT with and without CUDA Graph under different workloads (64 requests per workload, mean ISL/OSL, tested on 8×A800-SXM GPUs). Left: co-location. Right: PDD. Percentages show reduction.

图组解读

- **图组结论:** 共置与 PDD 四种工作负载下开启 CUDA Graph 后 TPOT 均下降，降幅随工作负载而异
- **论证关系:** 印证运行时优化须一等公民建模，与同页 Table 2 的填充开销数据互补
- **适用范围:** 仅展示 vLLM 实测净效果，不单独证明填充侧的负面效应

前排论文大图 问题严重性 呼应：第 3 节：单体副本抽象无法表达跨集群依赖导致的架构不完整问题




Panel 1

Panel 2


Figure 2. Existing simulators vs. vLLM CUDA Graph. Percentages represent error.

图组解读


- **图组结论:** Vidur 全部偏高 (+34.6%~+61.0%)，AIConfigurator 全部偏低 (-31.8%~-46.4%)，PDD 面板 Vidur 柱缺失
- **论证关系:** 证明忽略 CUDA Graph 会产生结构性双向误差，柱缺失与 Table 1 中 PDD 标 X 互证架构不完整
- **适用范围:** 不能证明 Frontier 自身精度，需结合 Figure 1、9 佐证



Panel 1



Panel 2



Panel 3

Figure 4. Fidelity gaps caused by simplified modeling. Left: Relying on coarse proxies (total token count) fails to capture batch heterogeneity, yielding coarse-grained performance estimates. Right: Analytical KV-cache modeling overestimates effective memory budget, leading to a cascade of errors from admission control to over-optimistic throughput projection.

图组解读

- **图组结论**: token 代理对 Attention/GroupedGEMM 误差远高于 Linear 算子; 解析 KV 模型高估预算 8.1%/27.2%、吞吐 23.6%/32.4%
- **论证关系**: 为序列/路由依赖随机森林预测器与 dummy profile 内存模型提供必要性依据
- **适用范围**: 仅证明旧方法误差存在, 不证明 Frontier 自身精度




Figure 5. Decision drift from fidelity gaps on Llama-3.1-8B over 16 H800 GPUs (co-location). The simulator-selected best configuration lies inside the frozen SLA region, but the corresponding vLLM ground-truth point moves outside the SLA because overly optimistic comp-op and KV-cache budget predictions underestimate request latency. Note that we maintain feature parity in this evaluation by disabling vLLM optimizations unsupported by APEX.

图组解读

- **图组结论**: APEX 选中的最优配置在真实 vLLM 上违反 SLA, $\Delta\text{TTFT}=+17.54\text{ms}$, $\Delta\text{TPOT}=+8.53\text{ms}$
- **论证关系**: 可视化决策漂移机制, 是 Fidelity Plane 设计动机的反面案例
- **适用范围**: 仅为 APEX 单一基线的单一案例, 不代表 Frontier 自身表现

4. 旧方法为何不够

比较对象	原本要解决什么	依赖前提/遗留限制	本文批判的具体 limit	本文回应模块	检验实验
Vidur	提供 DES 基础, Frontier 复用其模块 [作者明确陈述]	单体副本、token-only 算子代理	不支持 MoE/解耦; attention 误差 p50/p95 55.4%/376.1% [作者明确陈述]	三类算子预测器 +角色专属 worker	Figure 7、Figure 11
APEX	搜索最优计划的仿真器	不支持解耦架构, EP 支持有限 [作者明确陈述]	无法表达跨集群依赖	Control Plane 两域分解	Figure 5 (决策漂移案例); 无逐基线量化对比表 [无法从当前 OCR 内容确认]
AIConfigurator	算子数据库+解析 workflow, 在 TensorRT-LLM/H200 上有效 [作者明确陈述]	缺 CUDA Graph 建模; MTP 用标量期望公式	低接受率下预测反向趋势 (27.2%-66.6% 偏差, 5 例中 4 例方向错); E2E 误差最高 170.0%/200.0% [作者明确陈述]	Runtime Adapter、投机解码状态跟踪	Figure 2、3、5、11
LLMServingSim2.0	聚焦异构硬件仿真 [作者明确陈述]	Table 1 多项功能标 X, 正文无量化批判 [无法从当前 OCR 内容确认]	同上	角色专属 worker、运行时适配器	文中未说明具体对比实验
FastServe (MLFQ 调度)	非推理场景短作业优先调度有效 [作者明确陈述]	优先级仅看当前轮次可观测大小	多轮 agentic 场景仅带来 1.45% p95 aTTFT 改善, 隐藏规划吞吐反降 2.3% [作者明确陈述]	有状态请求抽象 +阶段感知调度器	Figure 15
"总减权重"解析 KV-cache 模型	简化估算显存预算	忽略真实 profile	高估预算 8.1%/27.2%, 虚高吞吐 23.6%/32.4% [作者明确陈述]	Fidelity Plane dummy profile run	Figure 4、Table 4

5. 核心洞见与假设

核心洞见: 不同生产引擎 (vLLM、SGLang) 虽调度策略/算子后端不同, 但共享同一"控制流骨架" (准入→批处理→执行→完成), 因此仿真核心可与具体框架解耦 [作者明确陈述]。

两条设计原则 (作者明确提出): ①架构完整性——放弃单体副本, 改用角色专属集群 worker 表达 PDD/AFD, 运行时优化建模为直接更新调度器状态的"特征专属适配器", 引入有状态请求抽象承载推理/agent/RL 语义; ②决策级精度——引入"保真面", 用基于真实 CUDA kernel 行为画像的校准预测器替代粗糙代理 [作者明确陈述]。

前提与可能失效条件: 该架构假设"控制流骨架"具有跨引擎共性, 若未来引擎调度范式发生根本性改变 (如完全去中心化调度), 这一前提可能不成立 [基于文中逻辑的推断, 推理依据: 作者仅验证了 vLLM, SGLang/TensorRT-LLM 留作未来工作]。

6. 方法：从洞见到可执行系统

总览: 输入为 CLI 指定的模型/硬件/并行/运行时/工作负载配置, Control Plane 将其编译为仿真拓扑并驱动 Execution Plane 的调度器-批处理引擎循环, 逐算子/逐内存查询 Fidelity Plane 获取时延与容量预测, 输出仿真的端到端指标 [作者明确陈述]。

模块 1: 控制面 (Simulation Compiler)

- **动机:** 需把服务规格转为可运行拓扑, 显式表达跨阶段依赖, 而非把 PDD/AFD 简化为延迟项 [作者明确陈述]。

- **运行**：解析出"角色专属集群 worker+每 worker 内多 Replica Worker"拓扑；引入两域并行原语 $\#mi("pp, (tp_{\{attn\}}, dp_{\{attn\}}), (tp_{\{ffn\}}, ep_{\{ffn\}}))$ ，域一致性约束 $\#mi("tp_{\{attn\}} \cdot dp_{\{attn\}} = tp_{\{ffn\}} \cdot ep_{\{ffn\}}")$ (Eq.1)；五类跨阶段依赖（流水线、PDD KV 传输、AFD 激活传输、MoE EP 同步）具象为显式事件 [作者明确陈述]。
- **技术优势**：排队/同步可"直接从事件图导出"，避免耦合隐藏在运行时中。
- **连接**：拓扑与事件图驱动模块 2 的调度决策。

模块 2：执行面 (Scheduler + Runtime Adapters)

- **动机**：既要保留真实调度机制（如 vLLM watermark 抢占），又要让运行时优化影响调度器可见状态，而非只是加速因子 [作者明确陈述]。
- **运行**：调度器决定准入与批组成，Runtime Adapter（如 CUDA Graph Dispatcher）重塑批（批填充、MTP 的 draft→verify→commit 状态维护），重塑后的批交给 Batch Engine 查询保真面 [作者明确陈述]。
- **技术优势**：把一个优化拆成三个可组合切面（调度器状态、查询批形状、逐请求进度），可同时表达"填充增加计算量 vs 图重放去启动开销"的耦合效应，"标量加速因子无法捕捉这种耦合" [作者明确陈述]。
- **连接**：输出批形状供模块 3 预测运行时间。

模块 3：保真面 (算子库+内存容量模型)

- **动机**：批组成在线决定，无法穷尽画像，需要泛化能力 [作者明确陈述]。
- **运行**：按算子类型分三类预测器——token 数算子用线性回归/随机森林，序列依赖算子（attention）用批大小+逐请求长度分布统计量的随机森林，路由依赖算子（MoE）用负载均衡方差/最大值等统计量的随机森林；内存容量模型通过单卡 dummy profile run 得到权重内存、torch 峰值增量、非 torch 驻留三个量，总预算减去三者得到 KV-cache 块预算 [作者明确陈述]。
- **技术优势**：单卡即可获得逐 rank 足迹，千卡内存预算只需一张 GPU 求解；PP 下取最坏切片作代表 rank。
- **连接**：预测结果反馈给模块 2 的批执行时序，闭环推进仿真时钟。




Figure 6. Frontier system architecture.

图组解读

- **图组结论**: 四模块（Workload&Config、Fidelity Plane、Control Plane、Execution Plane）分层嵌套并以箭头连接
- **论证关系**: 机制性可视化，呈现控制面/保真面分离与运行时适配器“一等公民”地位
- **适用范围**: 不含精度或性能数值，无实验覆盖范围问题

7. 为什么它可能有效

- 角色专属 worker+显式跨阶段事件 → 能原生表达 PDD/AFD 的排队与传输依赖 → 前提是拓扑编译准确覆盖实际同步点 [基于文中逻辑的推断]。
- 运行时适配器把优化建模为状态变更而非标量 → 能复现耦合效应（如 CUDA Graph 填充与图重放） → 前提是适配器正确刻画所有相关切面 [基于文中逻辑的推断]。
- 序列/路由依赖算子用随机森林捕捉批内异质性 → 能降低 attention/MoE 类算子误差 → 前提是训练数据覆盖生产环境的批形状分布，这一覆盖度论文未量化验证 [基于文中逻辑的推断；无法从当前 OCR 内容确认]。
- 内存基于真实 profile 而非解析估算 → 能避免 KV-cache 预算高估进而避免吞吐虚高 → 前提是 profile 过程本身不引入侵入式开销偏差（作者已采取隔离措施） [基于文中逻辑的推断]。

8. 实验与指标：证据是否支撑主张

8.1 实验问题与判定标准

- 研究问题一（效果）：Frontier 端到端预测是否比现有仿真器更准？对应比较基线 Vidur/APEX/AIConfigurator/LLMServingSim2.0，用 32 项指标误差判定 [作者明确陈述]。
- 研究问题二（机制/必要性）：CUDA Graph、投机解码、前缀缓存等运行时优化是否需一等公民建模？对应 Figure 9/10、Table 5/6 的匹配度判定 [作者明确陈述]。
- 研究问题三（必要性）：KV-cache 预算是否需基于运行时 profile？对应 Table 4、Figure 8 判定 [作者明确陈述]。
- 研究问题四（适用范围）：仿真结论能否支撑此前无法验证的新用例（Pareto 前沿、异构分配、agentic 调度、RL 重配置）？无独立硬件复现实验，属于仿真推演层级 [无法从当前 OCR 内容确认]。

8.2 数据、任务、对比与运行设置

- 测试床：16×H800（部分 Challenge 论证用 8×A800-SXM） [作者明确陈述]。
- 引擎版本：vLLM v0.10.2（V1 引擎） [作者明确陈述]。
- 模型：Qwen3-30B MoE、Step3-316B、Llama-3.1-8B/405B、Llama-3.3-70B [作者明确陈述]。
- 工作负载：prefill-heavy/decode-heavy/balanced/SharedGPT 四种模式 [作者明确陈述]。
- 基线：Vidur、APEX、AIConfigurator、LLMServingSim2.0 [作者明确陈述]。
- 重复次数/统计方式：文中未说明。
- 超参数细节：文中未说明。

8.3 指标字典与对应公式

- **指标与方向**： $\#mi("W_R^c")$ （每副本世界大小），无量纲，描述性非优劣。**定义**：原文公式 $\#mi("W_R^c=pp\cdot tp_{\{attn\}}\cdot dp_{\{attn\}}")$ （角色 $\in\{C,P,D,A\}$ ）或 $\#mi("pp\cdot tp_{\{ffn\}}\cdot ep_{\{ffn\}}")$ （角色=F），来源层级：原文公式，无编号。**用途**：定义仿真拓扑规模。**边界**：仅描述拓扑，不涉及精度。
- **指标与方向**：域一致性约束，越大越好方向不适用（等式约束）。**定义**： $\#mi("tp_{\{attn\}}\cdot dp_{\{attn\}}=tp_{\{ffn\}}\cdot ep_{\{ffn\}}")$ ，来源层级：原文公式 Eq.1。**用途**：确保同一角色跨域设备集合一致。**边界**：仅为拓扑合法性约束。
- **指标与方向**： $\#mi("SR(g)")$ （花费比），无量纲，越大越好。**定义**：原文公式 $\#mi("SR(g)=\frac{Price(g_0)}{Price(g)}")$ ，来源层级：原文公式，无编号。**用途**：§ 6.2 判定异构分配是否比全 H800 便宜。**边界**：仅反映成本，不含性能。
- **指标与方向**： $\#mi("CE(g)")$ （成本效率），无量纲，越大越好，作者要求 >1.08 。**定义**：原文公式 $\#mi("CE(g)=\frac{T(g)}{Price(g)\{T(g_0)/Price(g_0)\}}")$ ，来源层级：原文公式，无编号。**用途**：判定候选分配单位成本产出是否更高。**边界**：依赖仿真吞吐 $\#mi("T")$ 的准确性。
- **指标与方向**：相对误差（Table 4/5/6 等各表 Δ 值），百分比，越小越好。**定义**：推导关系（非原文公式）：相对误差=(仿真值-vLLM 实测值)/vLLM 实测值 $\times 100\%$ 。**来源层级**：推导关系（非原文公式） [基于文中逻辑的推断]，推理依据：原文表格标题写“Percentages are relative errors to vLLM”。**用途**：贯穿所有算子/内存/端到端保真度对比。**边界**：以 vLLM 实测为分母，不能脱离该测试床外推。
- **指标与方向**：TTFT/TPOT/吞吐/E2E makespan，毫秒/tokens 每秒/秒，均为越小/越大方向按名称，文中未说明具体计算公式，仅报告数值，来源层级：无可核验公式。**用途**：端到端保真度评估与 SLA 判定。**边界**：无法核实其内部聚合口径。

8.4 主结果、消融与证据边界 比较工作与被批判限制的呼应（见第 4 节表格，此处不重复展开）。

主张	直接证据（实验/表图）	证据强度与边界
吞吐误差<4%	摘要数值，Figure 9 关联 [实验支持]	已验证；外推未测硬件需额外实验
单体抽象与解耦系统"根本不匹配"	Vidur/APEX 在 PDD 行标 X（Table1/ Figure11）[作者明确陈述]	属间接反证，无强行建模 PDD 的受控消融
运行时优化须一等公民建模	Figure 2、Table 5、6 [实验支持]	缺少"去掉适配器退化为解析补丁"的消融
KV-cache 须基于运行时 profile	Table 4、Figure 8 [实验支持]	已直接验证
支持 1K+ GPU/商用 CPU	摘要与 § 1 陈述 [作者明确陈述]	无运行时长/内存占用实测数字
四用例"此前无仿真器可复现"	§ 6 引言陈述 [作者明确陈述]	作者主观声明，无逐用例失败复现实验

- 共置端到端 32 项指标误差 $\leq 9.37\%$ ，PDD $\leq 10.99\%$ (29/32 $\leq 9\%$)，对比 Vidur 2.9%–45.5%、AIConfigurator 最高 170.0%/200.0% [实验支持]。
- KV-cache 初始块预算误差 $\leq 1.89\%$ vs 解析基线 14.10%–39.73% [实验支持]。
- 投机解码 p95 误差多数 $\leq 11.28\%$ ，AIConfigurator 平均 46.9% 且趋势翻转 [实验支持]。
- 所有数值均限定于 16×H800/8×A800、vLLM v0.10.2、特定模型集合，能否推广到其他硬件/框架/更大 MoE 稀疏度文中未说明。

9. 图表解读与论证关系

Figure 3. Qwen3-30B MoE MTP decode speedup (verify_tokens=4). Bars (left axis): vLLM vs. AIConfigurator. Dashed line: prediction error. Red ×: sign-mismatch (measured speedup > 1, predicted slowdown)

图组解读 对比基线 呼应：第 4 节：AIConfigurator 标量期望公式压平事件驱动的非线性加速

- **图组结论**：AR=20% 时部分 Batch Size 下 vLLM 显示加速而 AIConfigurator 预测减速，方向相反；AR=80% 时方向一致但数值差距仍存
- **论证关系**：证明标量期望式 MTP 模型会预测出错误趋势，支撑逐请求状态跟踪设计必要性
- **适用范围**：仅覆盖 AIConfigurator 一个基线，不可推广为所有仿真器通病

Table 6. Speculative decoding (MTP) fidelity on Qwen30B MoE under SharedGPT.

图组解读 实验结论 呼应：第 8 节：前缀缓存命中率精确匹配（共置 36.98% / PDD 37.11%）

- **图组结论**：vLLM 与 Frontier 曲线在共置、PDD 两种设置下高度重叠，锯齿波动同步
- **论证关系**：支撑将前缀缓存建模为 block-hash 索引足以复现真实引擎命中动态
- **适用范围**：仅验证命中率时间序列匹配，不涉及下游 TTFT/吞吐影响幅度




Figure 9. Decode throughput. +CG bars stack eager throughput with the CUDA Graph gain; top labels show total +CG/eager speedup.

图组解读 实验结论 呼应：第 8 节：CUDA Graph 解码加速匹配 vLLM，误差 1.7%（共置）/6.1%（PDD）

- **图组结论：**共置组（2.95 vs 2.90）与 PDD 组（3.05 vs 2.86）加速倍数在 vLLM 与 Frontier 间接近
- **论证关系：**支撑运行时适配器一等公民建模的必要性主张
- **适用范围：**无对应"去适配器"消融实验




Figure 8. Available KV-cache blocks over time under colocation (Qwen3-30B MoE, SharedGPT trace), with a max gap of 294 blocks (115.6 MB; MB = 0.393 B, where B is the block gap).

图组解读 实验结论 呼应：第 8 节：KV-cache 初始块预算误差 $\leq 1.89\%$

- **图组结论：**vLLM 与 Frontier 曲线在整个运行时窗口高度重叠，波动同步
- **论证关系：**支撑 KV-cache 内存模型基于运行时 profile 而非解析估算的必要性
- **适用范围：**仅覆盖单一模型/架构组合，未标注具体并行配置




Figure 7. Per-operator relative-error CDF on H800 for attention, and MoE kernels under BF16 (left) and FP8 (right). Vidur is undefined for MoE ops, and its baseline cannot be evaluated under FP8.

图组解读 实验结论 呼应：第 8 节：序列依赖算子误差数字（Frontier p50/p95 3.5%/14.2% vs Vidur 55.4%/376.1%）

- **图组结论：**Frontier Attention/MoE 曲线 BF16 下 0.2–0.3 误差内接近 CDF=1.0, Vidur 延伸至约 2.5; FP8 下无 Vidur 对照曲线
- **论证关系：**印证随机森林预测器精度提升，同时揭示 Vidur 不支持 FP8 的架构局限
- **适用范围：**仅检验"token-only 代理对批内异质性不敏感"这一具体 limit

表格证据: Table 5. Compute-participating token accounting on Qwen3-30B MoE. E: eager; CG: CUDA Graph.

Eager Frontier is +0 (0%)... 实验结论 呼应: 第 8 节: CUDA Graph 填充 token 数误差 within 2.55%

- **图组结论:** CG-vLLM 列数值普遍高于 E-vLLM 列, Δ Frontier 误差视觉上处于个位数区间
- **论证关系:** 支撑填充效应建模精度, 印证运行时适配器一等公民设计必要性
- **适用范围:** 不证明端到端延迟/吞吐整体保真度

VL	AR	TTFT (%)	TPOT (%)	Thpt. (%)	E2E (%)
2	0.3	5.48	4.37	0.77	5.01
	0.7	2.75	1.92	1.88	2.40
8	0.3	0.84	0.00	5.12	6.45
	0.7	4.43	1.26	3.53	5.57
32	0.3	4.14	6.18	4.23	9.32
	0.7	6.40	3.25	2.05	11.28




Figure 11. End-to-end fidelity on a 16-card H800 testbed for co-location and PDD across prefill-heavy, decode-heavy, balanced, and SharedGPT workloads. Panels report TTFT, TPOT, throughput, and E2E makespan for both Llama3.1-8B (dense) and Qwen3-30B MoE; dashed bars indicate simulators that do not support the serving architecture or model family. All data are normalized against the ground truth (vLLM), represented by the black line ($y=1.0$).

图组解读 实验结论 呼应: 第 8 节: 端到端延迟误差 44.9%→6.4%, 51.7%→2.6%

- **图组结论:** Frontier 柱始终最贴近 $y=1.0$; AIConfigurator/LLMservingSim2.0/Vidur 在 Thpt、E2E 频繁远离基准; APEX 多处红叉缺失
- **论证关系:** 是摘要核心量化结论的直接可视化证据, 缺失柱与 Table 1 功能表互证架构不完整
- **适用范围:** 不能单独归因某一子机制导致的误差来源, 需结合 Figure 7/8/9/10

10. 完整因果推理树

- 根问题: 现代 LLM 服务架构/并行/运行时优化/工作负载同时演化, 生产部署难以建模、推理和优化 [作者明确陈述]
 - 旧方法限制: 单体副本抽象无法表达 PDD/AFD; 平均情形代理低估异质性误差, 闭环放大为决策错误 [作者明确陈述]
 - 核心洞见/假设: 服务引擎共享"准入-批处理-执行-完成"控制流骨架, 可与调度策略/算子后端解耦 [作者明确陈述]
 - 方法模块: 控制面/保真面分离, 角色专属集群 worker, 运行时适配器, 有状态请求抽象 [作者明确陈述]
 - 可验证预测: Frontier 能以低误差复现真实系统的算子时延、内存预算、运行时优化行为、端到端延迟 [作者明确陈述]
 - 指标与实验: per-operator CDF、KV-cache 块预算误差、CUDA Graph/MTP/前缀缓存匹配度、32 项端到端指标误差 [实验支持]
 - 图表证据: Figure 7/8/9/10/11、Table 4/5/6
 - 结论与适用边界: 在 $16 \times H800$ 、vLLM v0.10.2、特定模型集合下成立; 能否推广到 SGLang/TensorRT-LLM、其他硬件、更大稀疏度 MoE 未被当前证据直接验证 [无法从当前 OCR 内容确认]

11. 结论、贡献与边界

贡献: 去单体化的控制面/保真面分离架构; 运行时优化的适配器一等公民建模范式; 有状态请求抽象; 校准的三类算子预测器与基于 profile 的 KV-cache 内存模型 [作者明确陈述]。

证据充分的结论: 吞吐误差 < 4%, 端到端延迟误差大幅低于既有仿真器 (44.9%→6.4%, 51.7%→2.6%), KV-cache 预算误差 $\leq 1.89\%$ [实验支持]。

尚属推断的意义: 四个使用案例展示的应用价值 (Pareto 前沿、异构分配、agentic 调度、RL 重配置) 均为仿真推演, 尚无真实硬件复现验证 [作者明确陈述]。

适用条件: 结论限定于 vLLM v0.10.2、16×H800/8×A800、特定模型集合 (Qwen3-30B MoE、Step3-316B、Llama 系列)。

局限: 主要围绕 vLLM 校准, SGLang/TensorRT-LLM 扩展留作未来工作; CPU 开销建模"可能仍缺乏鲁棒性" [作者明确陈述];

AFD 为离线校准, 延迟类指标置信度可能低于 PDD/共置 [作者明确陈述]。

审稿式风险检查:

- 贡献新意: 控制面/保真面分离与适配器范式有明确技术论证与对比实验支撑, 当前证据未显示该风险。
- 写作/可复现性: 代码已开源 (GitHub), 但重复次数、统计显著性、部分超参数文中未说明, 存在可复现性信息缺口。
- 效果大小: 主结果误差改善幅度大且有量化数字支撑, 当前证据未显示夸大风险。
- 实验覆盖: 四个使用案例缺乏真实硬件对照, 属于已知证据缺口而非风险掩盖; 部分基线 (LLMServingSim2.0、APEX) 缺少逐项量化对比。
- 方法设计: 核心机制缺少"去除适配器/退化为解析补丁"的消融实验, 无法单独量化"一等公民建模"相对补丁式建模的增量收益。

12. 术语与第一性原理学习路径

12.1 核心术语

- **术语:** Prefill-Decode Disaggregation (PDD) —— 把 LLM 推理的预填充和解码阶段分配到不同 GPU 池运行, 通过传输 KV-cache 衔接。**第一性原理角色:** 受"计算密集 vs 显存带宽密集"两类资源约束的分工连接。**本文位置:** Control Plane 用角色专属 worker 建模。
- **术语:** Attention-FFN Disaggregation (AFD) —— 在解码阶段进一步把注意力计算与 FFN/MoE 计算拆到不同 GPU 池。**第一性原理角色:** 受跨池激活传输带宽约束。**本文位置:** 模块 1 的角色专属 worker 建模对象。
- **术语:** CUDA Graph —— 把一串 GPU kernel 调用预先录制为可重放序列, 减少调度开销, 但重放前批大小需"凑整"到捕获桶, 产生填充浪费 [基于文中逻辑的推断]。**第一性原理角色:** 受"kernel 启动开销 vs 批对齐浪费"的权衡约束。**本文位置:** 模块 2 Runtime Adapter 核心建模对象。
- **术语:** Fidelity Plane (保真面) —— 用校准的硬件感知预测器替代粗糙代理, 给出算子/通信/内存开销预测。**第一性原理角色:** 连接"批形状/硬件配置"这一状态量与"运行时间/内存占用"这一可观测量。**本文位置:** 模块 3。
- **术语:** MoE GroupedGEMM —— MoE 层中多个专家的矩阵乘法被分组批量执行的算子。**第一性原理角色:** 受"专家级负载偏斜"这一路由依赖约束, token-count 代理会将其平均掉。**本文位置:** 路由依赖算子预测器的建模对象。
- **术语:** 投机解码/MTP —— 用小/快的草稿机制一次猜测多个后续 token, 主模型批量验证提交, 减少串行调用次数 [作者明确陈述]。**第一性原理角色:** 受"验收率"这一随机变量约束, 决定实际加速比。**本文位置:** Runtime Adapter 的逐请求 planned/verified/accepted/committed 状态跟踪。
- **术语:** 离散事件仿真 (DES) —— 系统状态只在"事件"发生时间点跳跃式更新, 用优先队列按时间戳处理事件。**第一性原理角色:** 用离散时间戳替代连续步进, 是仿真效率与保真度的基础机制。**本文位置:** Frontier 的核心仿真范式。
- **术语:** KV-cache 容量模型 —— 通过单 GPU dummy profile run 得到权重内存、峰值增量、非 torch 驻留三个量, 用总预算减去它们得到块预算。**第一性原理角色:** 受"总显存-占用项=可用预算"这一资源约束方程连接。**本文位置:** 模块 3。

12.2 学习路径

1. 先理解 Prefill/Decode 两阶段的计算特性差异 (基本对象) —— 它决定了为什么会有 PDD/AFD 这类拆分需求。
2. 再理解 TP/PP/DP/EP 并行策略 (约束) —— 它们决定了模型如何被切分到多卡, 是理解 Frontier 拓扑编译的前提。
3. 然后理解 CUDA Graph、投机解码等运行时优化的工作原理 (机制) —— 它们改变调度器可见状态, 是理解"一等公民建模"必要性的关键。
4. 最后理解 KV-cache 内存管理与仿真中的 TTFT/TPOT/吞吐等指标含义 (指标/系统行为) —— 它们是评判仿真精度与 SLA 是否满足的最终观测量。