

论文解构报告

Frontier: Towards Comprehensive and Accurate LLM Inference Simulation

Yicheng Feng, Xin Tan, Yangtao Deng, Yimin Jiang, Yibo Zhu, Hong Xu

2026

LLM 推理模拟

分离式服务架构

离散事件仿真

性能建模

MoE 并行

代码: <https://github.com/NetX-lab/Frontier>

生成时间: 2026-07-28

目录

摘要翻译	3
1. 一句话总览	3
2. 阅读范围与证据状态	3
3. 根问题：论文究竟要解决什么	3
4. 旧方法为何不够	6
5. 核心洞见与假设	7
6. 方法：从洞见到可执行系统	7
7. 为什么它可能有效	10
8. 实验与指标：证据是否支撑主张	10
9. 图表解读与论证关系	11
10. 完整因果推理树	13
11. 结论、贡献与边界	13
12. 术语与第一性原理学习路径	13

摘要翻译

现代大语言模型 (LLM) 服务已不再是同质化或单体式的。生产系统如今融合了分离式执行、复杂的并行策略、运行时优化技术，以及推理、智能体和强化学习 (RL) rollout 等有状态工作负载。仿真是探索这一不断扩展的设计空间的有效手段，但现有仿真器缺乏其所要求的架构完整性和决策级精度。它们的单体副本抽象难以适配分离式服务架构，而基于平均情形的分析代理模型可能扭曲 SLA 预测，甚至颠倒优化结论。本文提出 Frontier，一个面向现代 LLM 推理服务的离散事件仿真器。Frontier 采用分离式抽象，通过为共置、Prefill-Decode 分离 (PDD) 和 Attention-FFN 分离 (AFD) 架构建模角色专属的集群工作节点，捕捉现代服务系统的结构与动态特性；在调度器-批处理-引擎循环中集成关键运行时优化技术（如 CUDA Graph、推测解码）；并支持面向新兴工作负载的有状态请求。此外，Frontier 还能在具有复杂工作负载组合的多样化服务场景中，提供准确且可泛化的计算、通信与内存开销预测。在 16 卡 H800 GPU 测试平台上，Frontier 的平均吞吐量误差低于 4%。与最先进的仿真器相比，它将端到端延迟误差在共置场景下从 44.9% 降至 6.4%，在分离式场景下从 51.7% 降至 2.6%。Frontier 可在普通 CPU 上扩展至超过 1000 块 GPU 的规模，并支持诸如 SLA 相关的帕累托前沿探索、异构分离式资源分配、智能体推理调度验证以及 RL 后训练重配置等新应用场景。Frontier 已在 <https://github.com/NetX-lab/Frontier> 开源。

1. 一句话总览

论文元数据

字段	内容
标题	Frontier: Towards Comprehensive and Accurate LLM Inference Simulation
作者	Yicheng Feng, Xin Tan, Yangtao Deng, Yimin Jiang, Yibo Zhu, Hong Xu
发表场所 / 年份	文中未说明 / 2026
研究领域	LLM 推理系统、性能仿真
关键词	LLM 推理模拟, 分离式服务架构, 离散事件仿真, 性能建模, MoE 并行

资源链接

- 原始文件：本地上传文件
- arXiv：文中未说明
- DOI：文中未说明
- 代码 / 数据集：<https://github.com/NetX-lab/Frontier>

标签 (3-5 个)： LLM 推理仿真 · 分离式服务架构 PDD-AFD · 离散事件仿真 · MoE 并行性能建模 · KV-cache 容量预测

论文提出离散事件仿真器 Frontier，用"控制面/保真面分离+角色专属集群 worker+运行时适配器"解决现有仿真器架构不完整、精度粗糙两大问题，在 16×H800 实测下平均吞吐误差低于 4%，端到端延迟误差从 44.9%/51.7% 降至 6.4%/2.6% [实验支持]。

2. 阅读范围与证据状态

OCR 覆盖论文第 1-13 页正文及 6 组图表证据（部分为 Table/Figure 混排图片），涵盖摘要、动机、方法、实验（§ 5）与四个使用案例（§ 6）。存在的限制：部分图片柱顶数字因分辨率原因无法逐位核实（如 Table 5 最后一位小数）[无法从当前 OCR 内容确认]；论文原始编号的 Eq. 只有 Eq.1 明确出现，其余公式无编号 [作者明确陈述]；另有 10 张图片超过分析上限未做视觉分析。论文事实与背景知识已在下文逐条标注区分。

3. 根问题：论文究竟要解决什么

问题定义：现代 LLM 推理服务架构（共置→PDD→AFD）、并行策略（TP/PP/DP/EP）、运行时优化（连续批处理、CUDA Graph、投机解码等）与工作负载（MoE、推理链、agent、RL rollout）同时快速演化，使生产部署"极难建模、推理和优化" [作者明确陈述]。

为什么重要：真实硬件扫描代价极高——在 64×H100 上扫描 100 种配置需 12,800-25,600 GPU-小时、最多耗资 18 万美元，导致团队放弃调优、退回保守配置、损失 3-5× 吞吐 [作者明确陈述]。仿真是廉价替代手段，但现有仿真器不满足决策精度要求。

难点来源：一是解耦式架构下不同 GPU 池承担不同角色、需显式跨集群同步，二是运行时优化会改变调度器可见状态而非只是加速系数，三是服务系统是闭环系统（执行成本→内存状态→准入→排队→未来批组成），微小误差会被放大 [作者明确陈述]。

成功标准：仿真预测需在算子/内存/端到端多层面与真实硬件对齐，且不能颠倒优化结论。

本文 story: 旧路线在"单体副本抽象"与"平均情形代理模型"这两个技术选择上失效——前者无法表达 PDD/AFD 的跨集群依赖，后者会低估长度/路由异质性造成的误差，进而在闭环系统中放大为决策错误。本文的转折是把仿真器拆成"控制面（拓扑与调度）"和"保真面（硬件感知预测）"两层分离架构，用校准的算子/内存预测器替代解析代理 [作者明确陈述]。

前排论文大图 问题严重性 呼应：第 3 节：运行时优化会改变调度器可见状态而非只是加速系数





Figure 1. Measured vLLM TPOT with and without CUDA Graph under different workloads (64 requests per workload, mean ISL/OSL, tested on 8×A800-SXM GPUs). Left: co-location. Right: PDD. Percentages show reduction.

图组解读

- **图组结论:** 共置与 PDD 四种工作负载下开启 CUDA Graph 后 TPOT 均下降，降幅随工作负载而异
- **论证关系:** 印证运行时优化须一等公民建模，与同页 Table 2 的填充开销数据互补
- **适用范围:** 仅展示 vLLM 实测净效果，不单独证明填充侧的负面效应

前排论文大图 问题严重性 呼应：第 3 节：单体副本抽象无法表达跨集群依赖导致的架构不完整问题




Panel 1

Panel 2


Figure 2. Existing simulators vs. vLLM CUDA Graph. Percentages represent error.

图组解读


- **图组结论:** Vidur 全部偏高 (+34.6%~+61.0%)，AIConfigurator 全部偏低 (-31.8%~-46.4%)，PDD 面板 Vidur 柱缺失
- **论证关系:** 证明忽略 CUDA Graph 会产生结构性双向误差，柱缺失与 Table 1 中 PDD 标 X 互证架构不完整
- **适用范围:** 不能证明 Frontier 自身精度，需结合 Figure 1、9 佐证



Panel 1



Panel 2



Panel 3

Figure 4. Fidelity gaps caused by simplified modeling. Left: Relying on coarse proxies (total token count) fails to capture batch heterogeneity, yielding coarse-grained performance estimates. Right: Analytical KV-cache modeling overestimates effective memory budget, leading to a cascade of errors from admission control to over-optimistic throughput projection.

图组解读

- **图组结论**: token 代理对 Attention/GroupedGEMM 误差远高于 Linear 算子; 解析 KV 模型高估预算 8.1%/27.2%、吞吐 23.6%/32.4%
- **论证关系**: 为序列/路由依赖随机森林预测器与 dummy profile 内存模型提供必要性依据
- **适用范围**: 仅证明旧方法误差存在, 不证明 Frontier 自身精度

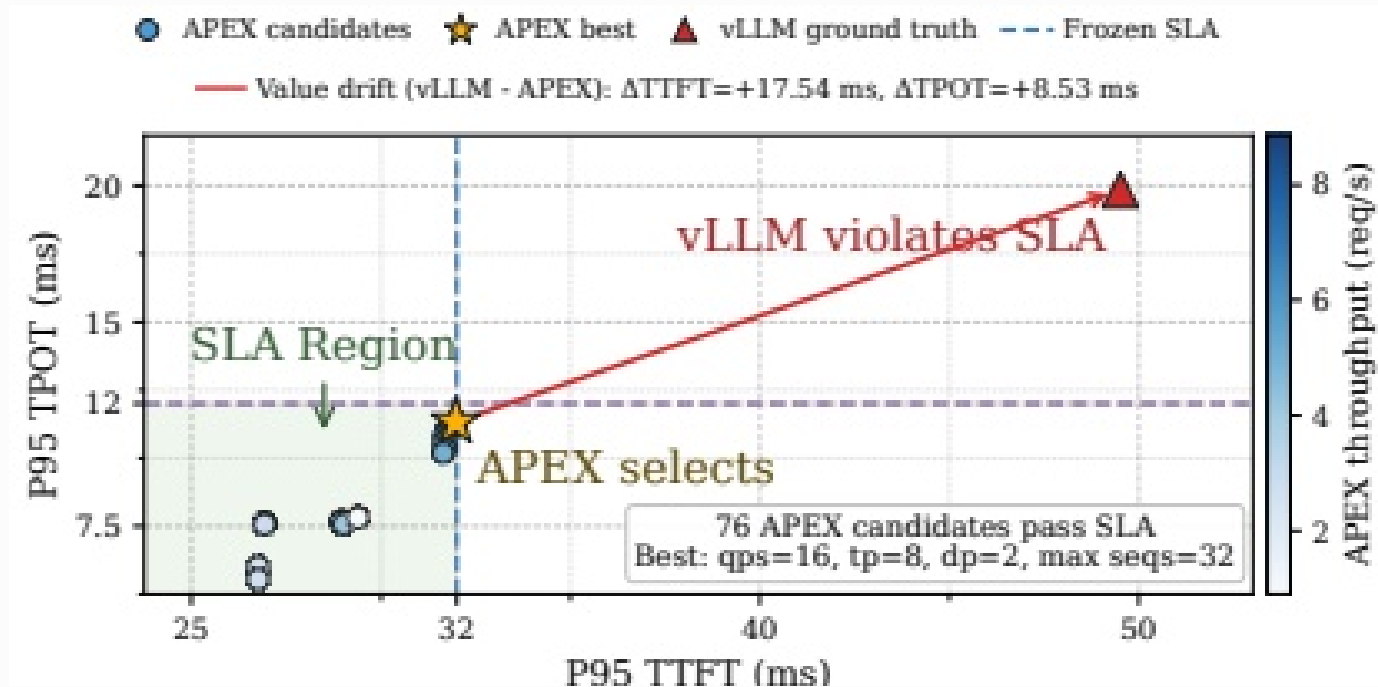


Figure 5. Decision drift from fidelity gaps on Llama-3.1-8B over 16 H800 GPUs (co-location). The simulator-selected best configuration lies inside the frozen SLA region, but the corresponding vLLM ground-truth point moves outside the SLA because overly optimistic comp-op and KV-cache budget predictions underestimate request latency. Note that we maintain feature parity in this evaluation by disabling vLLM optimizations unsupported by APEX.

图组解读

- **图组结论**：APEX 选中的最优配置在真实 vLLM 上违反 SLA， $\Delta\text{TTFT}=+17.54\text{ms}$ ， $\Delta\text{TPOT}=+8.53\text{ms}$
- **论证关系**：可视化决策漂移机制，是 Fidelity Plane 设计动机的反面案例
- **适用范围**：仅为 APEX 单一基线的单一案例，不代表 Frontier 自身表现

4. 旧方法为何不够

比较对象	原本要解决什么	依赖前提/遗留限制	本文批判的具体 limit	本文回应模块	检验实验
Vidur	提供 DES 基础, Frontier 复用其模块 [作者明确陈述]	单体副本、token-only 算子代理	不支持 MoE/解耦; attention 误差 p50/p95 55.4%/376.1% [作者明确陈述]	三类算子预测器 +角色专属 worker	Figure 7、Figure 11
APEX	搜索最优计划的仿真器	不支持解耦架构, EP 支持有限 [作者明确陈述]	无法表达跨集群依赖	Control Plane 两域分解	Figure 5 (决策漂移案例); 无逐基线量化对比表 [无法从当前 OCR 内容确认]
AIConfigurator	算子数据库+解析 workflow, 在 TensorRT-LLM/H200 上有效 [作者明确陈述]	缺 CUDA Graph 建模; MTP 用标量期望公式	低接受率下预测反向趋势 (27.2%-66.6% 偏差, 5 例中 4 例方向错); E2E 误差最高 170.0%/200.0% [作者明确陈述]	Runtime Adapter、投机解码状态跟踪	Figure 2、3、5、11
LLMServingSim2.0	聚焦异构硬件仿真 [作者明确陈述]	Table 1 多项功能标 X, 正文无量化批判 [无法从当前 OCR 内容确认]	同上	角色专属 worker、运行时适配器	文中未说明具体对比实验
FastServe (MLFQ 调度)	非推理场景短作业优先调度有效 [作者明确陈述]	优先级仅看当前轮次可观测大小	多轮 agentic 场景仅带来 1.45% p95 aTTFT 改善, 隐藏规划吞吐反降 2.3% [作者明确陈述]	有状态请求抽象 +阶段感知调度器	Figure 15
"总减权重"解析 KV-cache 模型	简化估算显存预算	忽略真实 profile	高估预算 8.1%/27.2%, 虚高吞吐 23.6%/32.4% [作者明确陈述]	Fidelity Plane dummy profile run	Figure 4、Table 4

5. 核心洞见与假设

核心洞见: 不同生产引擎 (vLLM、SGLang) 虽调度策略/算子后端不同, 但共享同一"控制流骨架" (准入→批处理→执行→完成), 因此仿真核心可与具体框架解耦 [作者明确陈述]。

两条设计原则 (作者明确提出): ①架构完整性——放弃单体副本, 改用角色专属集群 worker 表达 PDD/AFD, 运行时优化建模为直接更新调度器状态的"特征专属适配器", 引入有状态请求抽象承载推理/agent/RL 语义; ②决策级精度——引入"保真面", 用基于真实 CUDA kernel 行为画像的校准预测器替代粗糙代理 [作者明确陈述]。

前提与可能失效条件: 该架构假设"控制流骨架"具有跨引擎共性, 若未来引擎调度范式发生根本性改变 (如完全去中心化调度), 这一前提可能不成立 [基于文中逻辑的推断, 推理依据: 作者仅验证了 vLLM, SGLang/TensorRT-LLM 留作未来工作]。

6. 方法：从洞见到可执行系统

总览: 输入为 CLI 指定的模型/硬件/并行/运行时/工作负载配置, Control Plane 将其编译为仿真拓扑并驱动 Execution Plane 的调度器-批处理引擎循环, 逐算子/逐内存查询 Fidelity Plane 获取时延与容量预测, 输出仿真的端到端指标 [作者明确陈述]。

模块 1：控制面 (Simulation Compiler)

- **动机:** 需把服务规格转为可运行拓扑, 显式表达跨阶段依赖, 而非把 PDD/AFD 简化为延迟项 [作者明确陈述]。

- **运行**：解析出"角色专属集群 worker+每 worker 内多 Replica Worker"拓扑；引入两域并行原语 $pp, (tp_{attn}, dp_{attn}), (tp_{ffn}, ep_{ffn})$ ，域一致性约束 $tp_{attn} \cdot dp_{attn} = tp_{ffn} \cdot ep_{ffn}$ (Eq.1)；五类跨阶段依赖（流水线、PDD KV 传输、AFD 激活传输、MoE EP 同步）具象为显式事件 [作者明确陈述]。
- **技术优势**：排队/同步可"直接从事件图导出"，避免耦合隐藏在运行时中。
- **连接**：拓扑与事件图驱动模块 2 的调度决策。

模块 2：执行面 (Scheduler + Runtime Adapters)

- **动机**：既要保留真实调度机制（如 vLLM watermark 抢占），又要让运行时优化影响调度器可见状态，而非只是加速因子 [作者明确陈述]。
- **运行**：调度器决定准入与批组成，Runtime Adapter（如 CUDA Graph Dispatcher）重塑批（批填充、MTP 的 draft→verify→commit 状态维护），重塑后的批交给 Batch Engine 查询保真面 [作者明确陈述]。
- **技术优势**：把一个优化拆成三个可组合切面（调度器状态、查询批形状、逐请求进度），可同时表达"填充增加计算量 vs 图重放去启动开销"的耦合效应，"标量加速因子无法捕捉这种耦合" [作者明确陈述]。
- **连接**：输出批形状供模块 3 预测运行时间。

模块 3：保真面 (算子库+内存容量模型)

- **动机**：批组成在线决定，无法穷尽画像，需要泛化能力 [作者明确陈述]。
- **运行**：按算子类型分三类预测器——token 数算子用线性回归/随机森林，序列依赖算子（attention）用批大小+逐请求长度分布统计量的随机森林，路由依赖算子（MoE）用负载均衡方差/最大值等统计量的随机森林；内存容量模型通过单卡 dummy profile run 得到权重内存、torch 峰值增量、非 torch 驻留三个量，总预算减去三者得到 KV-cache 块预算 [作者明确陈述]。
- **技术优势**：单卡即可获得逐 rank 足迹，千卡内存预算只需一张 GPU 求解；PP 下取最坏切片作代表 rank。
- **连接**：预测结果反馈给模块 2 的批执行时序，闭环推进仿真时钟。




Figure 6. Frontier system architecture.

图组解读

- **图组结论：**四模块（Workload&Config、Fidelity Plane、Control Plane、Execution Plane）分层嵌套并以箭头连接
- **论证关系：**机制性可视化，呈现控制面/保真面分离与运行时适配器"一等公民"地位
- **适用范围：**不含精度或性能数值，无实验覆盖范围问题

7. 为什么它可能有效

- 角色专属 worker+显式跨阶段事件 → 能原生表达 PDD/AFD 的排队与传输依赖 → 前提是拓扑编译准确覆盖实际同步点 [基于文中逻辑的推断]。
- 运行时适配器把优化建模为状态变更而非标量 → 能复现耦合效应（如 CUDA Graph 填充与图重放） → 前提是适配器正确刻画所有相关切面 [基于文中逻辑的推断]。
- 序列/路由依赖算子用随机森林捕捉批内异质性 → 能降低 attention/MoE 类算子误差 → 前提是训练数据覆盖生产环境的批形状分布，这一覆盖度论文未量化验证 [基于文中逻辑的推断；无法从当前 OCR 内容确认]。
- 内存基于真实 profile 而非解析估算 → 能避免 KV-cache 预算高估进而避免吞吐虚高 → 前提是 profile 过程本身不引入侵入式开销偏差（作者已采取隔离措施） [基于文中逻辑的推断]。

8. 实验与指标：证据是否支撑主张

8.1 实验问题与判定标准

- 研究问题一（效果）：Frontier 端到端预测是否比现有仿真器更准？对应比较基线 Vidur/APEX/AIConfigurator/LLMServingSim2.0，用 32 项指标误差判定 [作者明确陈述]。
- 研究问题二（机制/必要性）：CUDA Graph、投机解码、前缀缓存等运行时优化是否需一等公民建模？对应 Figure 9/10、Table 5/6 的匹配度判定 [作者明确陈述]。
- 研究问题三（必要性）：KV-cache 预算是否需基于运行时 profile？对应 Table 4、Figure 8 判定 [作者明确陈述]。
- 研究问题四（适用范围）：仿真结论能否支撑此前无法验证的新用例（Pareto 前沿、异构分配、agentic 调度、RL 重配置）？无独立硬件复现实验，属于仿真推演层级 [无法从当前 OCR 内容确认]。

8.2 数据、任务、对比与运行设置

- 测试床：16×H800（部分 Challenge 论证用 8×A800-SXM） [作者明确陈述]。
- 引擎版本：vLLM v0.10.2（V1 引擎） [作者明确陈述]。
- 模型：Qwen3-30B MoE、Step3-316B、Llama-3.1-8B/405B、Llama-3.3-70B [作者明确陈述]。
- 工作负载：prefill-heavy/decode-heavy/balanced/SharedGPT 四种模式 [作者明确陈述]。
- 基线：Vidur、APEX、AIConfigurator、LLMServingSim2.0 [作者明确陈述]。
- 重复次数/统计方式：文中未说明。
- 超参数细节：文中未说明。

8.3 指标字典与对应公式

- **指标与方向**： W_R^c （每副本世界大小），无量纲，描述性非优劣。**定义**：原文公式 $W_R^c = pp \cdot tp_{attn} \cdot dp_{attn}$ （角色 $\in \{C,P,D,A\}$ ）或 $pp \cdot tp_{ffn} \cdot ep_{ffn}$ （角色=F），来源层级：原文公式，无编号。**用途**：定义仿真拓扑规模。**边界**：仅描述拓扑，不涉及精度。
- **指标与方向**：域一致性约束，越大越好方向不适用（等式约束）。**定义**： $tp_{attn} \cdot dp_{attn} = tp_{ffn} \cdot ep_{ffn}$ ，来源层级：原文公式 Eq.1。**用途**：确保同一角色跨域设备集合一致。**边界**：仅为拓扑合法性约束。
- **指标与方向**： $SR(g)$ （花费比），无量纲，越大越好。**定义**：原文公式 $SR(g) = \frac{Price(g_0)}{Price(g)}$ ，来源层级：原文公式，无编号。**用途**：§ 6.2 判定异构分配是否比全 H800 便宜。**边界**：仅反映成本，不含性能。
- **指标与方向**： $CE(g)$ （成本效率），无量纲，越大越好，作者要求 >1.08。**定义**：原文公式 $CE(g) = \frac{T(g)/Price(g)}{T(g_0)/Price(g_0)}$ ，来源层级：原文公式，无编号。**用途**：判定候选分配单位成本产出是否更高。**边界**：依赖仿真吞吐 T 的准确性。
- **指标与方向**：相对误差（Table 4/5/6 等各表 Δ 值），百分比，越小越好。**定义**：推导关系（非原文公式）：相对误差=(仿真值-vLLM 实测值)/vLLM 实测值×100%。**来源层级**：推导关系（非原文公式） [基于文中逻辑的推断]，推理依据：原文表格标题写"Percentages are relative errors to vLLM"。**用途**：贯穿所有算子/内存/端到端保真度对比。**边界**：以 vLLM 实测为分母，不能脱离该测试床外推。
- **指标与方向**：TTFT/TPOT/吞吐/E2E makespan，毫秒/tokens 每秒/秒，均为越小/越大方向按名称，文中未说明具体计算公式，仅报告数值，来源层级：无可核验公式。**用途**：端到端保真度评估与 SLA 判定。**边界**：无法核实其内部聚合口径。

8.4 主结果、消融与证据边界 比较工作与被批判限制的呼应（见第 4 节表格，此处不重复展开）。

主张	直接证据（实验/表图）	证据强度与边界
吞吐误差<4%	摘要数值，Figure 9 关联 [实验支持]	已验证；外推未测硬件需额外实验
单体抽象与解耦系统"根本不匹配"	Vidur/APEX 在 PDD 行标 ×（Table1/ Figure11） [作者明确陈述]	属间接反证，无强行建模 PDD 的受控消融
运行时优化须一等公民建模	Figure 2、Table 5、6 [实验支持]	缺少"去掉适配器退化为解析补丁"的消融
KV-cache 须基于运行时 profile	Table 4、Figure 8 [实验支持]	已直接验证
支持 1K+ GPU/商用 CPU	摘要与 § 1 陈述 [作者明确陈述]	无运行时长/内存占用实测数字
四用例"此前无仿真器可复现"	§ 6 引言陈述 [作者明确陈述]	作者主观声明，无逐用例失败复现实验

- 共置端到端 32 项指标误差 $\leq 9.37\%$, PDD $\leq 10.99\%$ ($29/32 \leq 9\%$), 对比 Vidur 2.9%–45.5%、AIConfigurator 最高 170.0%/200.0% [实验支持]。
- KV-cache 初始块预算误差 $\leq 1.89\%$ vs 解析基线 14.10%–39.73% [实验支持]。
- 投机解码 p95 误差多数 $\leq 11.28\%$, AIConfigurator 平均 46.9% 且趋势翻转 [实验支持]。
- 所有数值均限定于 $16 \times \text{H800}/8 \times \text{A800}$ 、vLLM v0.10.2、特定模型集合, 能否推广到其他硬件/框架/更大 MoE 稀疏度文中未说明。

9. 图表解读与论证关系




Figure 3. Qwen3-30B MoE MTP decode speedup (verify_tokens=4). Bars (left axis): vLLM vs. AIConfigurator. Dashed line: prediction error. Red $\times$: sign-mismatch (measured speedup > 1 , predicted slowdown)

图组解读 **对比基线** 呼应: 第 4 节: AIConfigurator 标量期望公式压平事件驱动的非线性加速

- **图组结论:** AR=20% 时部分 Batch Size 下 vLLM 显示加速而 AIConfigurator 预测减速, 方向相反; AR=80% 时方向一致但数值差距仍存
- **论证关系:** 证明标量期望式 MTP 模型会预测出错误趋势, 支撑逐请求状态跟踪设计必要性
- **适用范围:** 仅覆盖 AIConfigurator 一个基线, 不可推广为所有仿真器通病




Table 6. Speculative decoding (MTP) fidelity on Qwen30B MoE under SharedGPT.

图组解读 **实验结论** 呼应: 第 8 节: 前缀缓存命中率精确匹配 (共置 36.98% / PDD 37.11%)

- **图组结论:** vLLM 与 Frontier 曲线在共置、PDD 两种设置下高度重叠, 锯齿波动同步
- **论证关系:** 支撑将前缀缓存建模为 block-hash 索引足以复现真实引擎命中动态
- **适用范围:** 仅验证命中率时间序列匹配, 不涉及下游 TTFT/吞吐影响幅度




Figure 9. Decode throughput. +CG bars stack eager throughput with the CUDA Graph gain; top labels show total +CG/eager speedup.

图组解读 **实验结论** 呼应: 第 8 节: CUDA Graph 解码加速匹配 vLLM, 误差 1.7% (共置) / 6.1% (PDD)

- **图组结论:** 共置组 (2.95 vs 2.90) 与 PDD 组 (3.05 vs 2.86) 加速倍数在 vLLM 与 Frontier 间接近
- **论证关系:** 支撑运行时适配器一等公民建模的必要性主张
- **适用范围:** 无对应"去适配器"消融实验




Figure 8. Available KV-cache blocks over time under colocation (Qwen3-30B MoE, SharedGPT trace), with a max gap of 294 blocks (115.6 MB; MB = 0.393 B, where B is the block gap).

图组解读 **实验结论** 呼应：第 8 节：KV-cache 初始块预算误差 $\leq 1.89\%$

- **图组结论**：vLLM 与 Frontier 曲线在整个运行时窗口高度重叠，波动同步
- **论证关系**：支撑 KV-cache 内存模型基于运行时 profile 而非解析估算的必要性
- **适用范围**：仅覆盖单一模型/架构组合，未标注具体并行配置




Figure 7. Per-operator relative-error CDF on H800 for attention, and MoE kernels under BF16 (left) and FP8 (right). Vidur is undefined for MoE ops, and its baseline cannot be evaluated under FP8.

图组解读 **实验结论** 呼应：第 8 节：序列依赖算子误差数字 (Frontier p50/p95 3.5%/14.2% vs Vidur 55.4%/376.1%)

- **图组结论**：Frontier Attention/MoE 曲线 BF16 下 0.2–0.3 误差内接近 CDF=1.0, Vidur 延伸至约 2.5; FP8 下无 Vidur 对照曲线
- **论证关系**：印证随机森林预测器精度提升，同时揭示 Vidur 不支持 FP8 的架构局限
- **适用范围**：仅检验"token-only 代理对批内异质性不敏感"这一具体 limit

表格证据：Table 5. Compute-participating token accounting on Qwen3-30B MoE. E: eager; CG: CUDA Graph.

Eager Frontier is +0 (0%)... **实验结论** 呼应：第 8 节：CUDA Graph 填充 token 数误差 within 2.55%

- **图组结论**：CG-vLLM 列数值普遍高于 E-vLLM 列， Δ Frontier 误差视觉上处于个位数区间
- **论证关系**：支撑填充效应建模精度，印证运行时适配器一等公民设计必要性
- **适用范围**：不证明端到端延迟/吞吐整体保真度

VL	AR	TTFT (%)	TPOT (%)	Thpt. (%)	E2E (%)
2	0.3	5.48	4.37	0.77	5.01
	0.7	2.75	1.92	1.88	2.40
8	0.3	0.84	0.00	5.12	6.45
	0.7	4.43	1.26	3.53	5.57
32	0.3	4.14	6.18	4.23	9.32
	0.7	6.40	3.25	2.05	11.28




Figure 11. End-to-end fidelity on a 16-card H800 testbed for co-location and PDD across prefill-heavy, decode-heavy, balanced, and SharedGPT workloads. Panels report TTFT, TPOT, throughput, and E2E makespan for both Llama3.1-8B (dense) and Qwen3-30B MoE; dashed bars indicate simulators that do not support the serving architecture or model family. All data are normalized against the ground truth (vLLM), represented by the black line ($y=1.0$).

图组解读 **实验结论** 呼应：第 8 节：端到端延迟误差 44.9%→6.4%，51.7%→2.6%

- **图组结论**：Frontier 柱始终最贴近 $y=1.0$ ；AIConfigurator/LLMervingSim2.0/Vidur 在 Thpt、E2E 频繁远离基准；APEX 多处红叉缺失
- **论证关系**：是摘要核心量化结论的直接可视化证据，缺失柱与 Table 1 功能表互证架构不完整
- **适用范围**：不能单独归因某一子机制导致的误差来源，需结合 Figure 7/8/9/10

10. 完整因果推理树

- 根问题：现代 LLM 服务架构/并行/运行时优化/工作负载同时演化，生产部署难以建模、推理和优化【作者明确陈述】
 - 旧方法限制：单体副本抽象无法表达 PDD/AFD；平均情形代理低估异质性误差，闭环放大为决策错误【作者明确陈述】
 - 核心洞见/假设：服务引擎共享"准入-批处理-执行-完成"控制流骨架，可与调度策略/算子后端解耦【作者明确陈述】
 - 方法模块：控制面/保真面分离，角色专属集群 worker，运行时适配器，有状态请求抽象【作者明确陈述】
 - 可验证预测：Frontier 能以低误差复现真实系统的算子时延、内存预算、运行时优化行为、端到端延迟【作者明确陈述】
 - 指标与实验：per-operator CDF、KV-cache 块预算误差、CUDA Graph/MTP/前缀缓存匹配度、32 项端到端指标误差【实验支持】
 - 图表证据：Figure 7/8/9/10/11、Table 4/5/6
 - 结论与适用边界：在 $16\times H800$ 、vLLM v0.10.2、特定模型集合下成立；能否推广到 SGLang/TensorRT-LLM、其他硬件、更大稀疏度 MoE 未被当前证据直接验证【无法从当前 OCR 内容确认】

11. 结论、贡献与边界

贡献：去单体化的控制面/保真面分离架构；运行时优化的适配器一等公民建模范式；有状态请求抽象；校准的三类算子预测器与基于 profile 的 KV-cache 内存模型【作者明确陈述】。

证据充分的结论：吞吐误差<4%，端到端延迟误差大幅低于既有仿真器（44.9%→6.4%，51.7%→2.6%），KV-cache 预算误差≤1.89%【实验支持】。

尚属推断的意义：四个使用案例展示的应用价值（Pareto 前沿、异构分配、agentic 调度、RL 重配置）均为仿真推演，尚无真实硬件复现验证【作者明确陈述】。

适用条件：结论限定于 vLLM v0.10.2、 $16\times H800/8\times A800$ 、特定模型集合（Qwen3-30B MoE、Step3-316B、Llama 系列）。

局限：主要围绕 vLLM 校准，SGLang/TensorRT-LLM 扩展留作未来工作；CPU 开销建模"可能仍缺乏鲁棒性"【作者明确陈述】；

AFD 为离线校准，延迟类指标置信度可能低于 PDD/共置【作者明确陈述】。

审稿式风险检查：

- 贡献新意：控制面/保真面分离与适配器范式有明确技术论证与对比实验支撑，当前证据未显示该风险。
- 写作/可复现性：代码已开源（GitHub），但重复次数、统计显著性、部分超参数文中未说明，存在可复现性信息缺口。
- 效果大小：主结果误差改善幅度大且有量化数字支撑，当前证据未显示夸大风险。
- 实验覆盖：四个使用案例缺乏真实硬件对照，属于已知证据缺口而非风险掩盖；部分基线（LLMervingSim2.0、APEX）缺少逐项量化对比。
- 方法设计：核心机制缺少"去除适配器/退化为解析补丁"的消融实验，无法单独量化"一等公民建模"相对补丁式建模的增量收益。

12. 术语与第一性原理学习路径

12.1 核心术语

- **术语:** Prefill-Decode Disaggregation (PDD) ——把 LLM 推理的预填充和解码阶段分配到不同 GPU 池运行, 通过传输 KV-cache 衔接。**第一性原理角色:** 受"计算密集 vs 显存带宽密集"两类资源约束的分工连接。**本文位置:** Control Plane 用角色专属 worker 建模。
- **术语:** Attention-FFN Disaggregation (AFD) ——在解码阶段进一步把注意力计算与 FFN/MoE 计算拆到不同 GPU 池。**第一性原理角色:** 受跨池激活传输带宽约束。**本文位置:** 模块 1 的角色专属 worker 建模对象。
- **术语:** CUDA Graph——把一串 GPU kernel 调用预先录制为可重放序列, 减少调度开销, 但重放前批大小需"凑整"到捕获桶, 产生填充浪费 [基于文中逻辑的推断]。**第一性原理角色:** 受"kernel 启动开销 vs 批对齐浪费"的权衡约束。**本文位置:** 模块 2 Runtime Adapter 核心建模对象。
- **术语:** Fidelity Plane (保真面) ——用校准的硬件感知预测器替代粗糙代理, 给出算子/通信/内存开销预测。**第一性原理角色:** 连接"批形状/硬件配置"这一状态量与"运行时间/内存占用"这一可观测量。**本文位置:** 模块 3。
- **术语:** MoE GroupedGEMM——MoE 层中多个专家的矩阵乘法被分组批量执行的算子。**第一性原理角色:** 受"专家级负载偏斜"这一路由依赖约束, token-count 代理会将其平均掉。**本文位置:** 路由依赖算子预测器的建模对象。
- **术语:** 投机解码/MTP——用小/快的草稿机制一次猜测多个后续 token, 主模型批量验证提交, 减少串行调用次数 [作者明确陈述]。**第一性原理角色:** 受"验收率"这一随机变量约束, 决定实际加速比。**本文位置:** Runtime Adapter 的逐请求 planned/verified/accepted/committed 状态跟踪。
- **术语:** 离散事件仿真 (DES) ——系统状态只在"事件"发生时间点跳跃式更新, 用优先队列按时间戳处理事件。**第一性原理角色:** 用离散时间戳替代连续步进, 是仿真效率与保真度的基础机制。**本文位置:** Frontier 的核心仿真范式。
- **术语:** KV-cache 容量模型——通过单 GPU dummy profile run 得到权重内存、峰值增量、非 torch 驻留三个量, 用总预算减去它们得到块预算。**第一性原理角色:** 受"总显存-占用项=可用预算"这一资源约束方程连接。**本文位置:** 模块 3。

12.2 学习路径

1. 先理解 Prefill/Decode 两阶段的计算特性差异 (基本对象) ——它决定了为什么会有 PDD/AFD 这类拆分需求。
2. 再理解 TP/PP/DP/EP 并行策略 (约束) ——它们决定了模型如何被切分到多卡, 是理解 Frontier 拓扑编译的前提。
3. 然后理解 CUDA Graph、投机解码等运行时优化的工作原理 (机制) ——它们改变调度器可见状态, 是理解"一等公民建模"必要性的关键。
4. 最后理解 KV-cache 内存管理与仿真中的 TTFT/TPOT/吞吐等指标含义 (指标/系统行为) ——它们是评判仿真精度与 SLA 是否满足的最终观测量。