

论文解构报告

ReaLB: Real-Time Load Balancing for Multimodal MoE Inference

Yu Wang, Yi Wu, Xiangyu Wu, Junwei Cui, 蔡玮琳, Zhijiang Guo, Jiayi Huang

2026

混合专家模型 (MoE)

负载均衡

多模态大模型

推理优化

源文件：<https://arxiv.org/pdf/2604.19503>

arXiv：<https://arxiv.org/abs/2604.19503>

生成时间：2026-07-20

目录

- 摘要翻译 3
 - 1. 一句话总览 3
 - 2. 阅读范围与证据状态 3
 - 3. 根问题：论文究竟要解决什么 3
 - 4. 旧方法为何不够 4
 - 5. 核心洞见与假设 4
 - 6. 方法：从洞见到可执行系统 4
 - 7. 为什么它可能有效 5
 - 8. 实验与指标：证据是否支撑主张 5
 - 9. 图表解读与论证关系 7
 - 10. 完整因果推理树 12
 - 11. 结论、贡献与边界 13
 - 12. 面向初学者的学习路径 13

摘要翻译

混合专家（MoE）架构在现代大语言模型和多模态模型中被广泛使用。然而，不同模态之间高度动态且倾斜的专家工作负载往往限制了推理效率。在具有大批量大小的预填充（prefill）阶段，视觉 Token 经常在输入序列中占据主导地位。在专家并行（EP）下，这会导致严重的负载不均衡，即一部分设备发生过载，从而降低了整个系统的吞吐量。我们提出了 ReaLB，一种用于多模态 MoE（MMoE）推理的实时负载均衡方法，该方法引入了零调度开销。ReaLB 在运行时以每个 EP-rank 为单位动态调整 MoE 专家的计算精度。对于由视觉密集型专家主导的 rank，ReaLB 分配较低精度的计算，通过利用 FP4 Tensor Core 来提高执行效率。ReaLB 不需要冗余专家或额外的内存分配。相反，它在运行时动态执行逐层专家精度转换，并将相关开销隐藏在 MoE 计算之前的分发（dispatch）阶段中。在代表性 MMoE 模型上的实验表明，ReaLB 实现了 1.10 倍至 1.32 倍的端到端加速，同时将平均准确率下降控制在 1% 以内。

1. 一句话总览

论文元数据

字段	内容
标题	ReaLB（多模态 MoE 推理实时负载均衡方法）
作者	文中未说明
发表场所 / 年份	文中未说明
研究领域	多模态大模型、混合专家模型（MoE）
关键词	文中未说明

资源链接

- 原始文件：本地上传文件
- arXiv：文中未说明
- DOI：文中未说明
- 代码 / 数据集：文中未说明

标签（3-5 个）：多模态大模型 · 混合专家模型（MoE） · 实时负载均衡 · 动态低精度量化 · 自适应控制

[基于文中逻辑的推断] ReaLB 是一种针对多模态混合专家模型（MMoE）推理预填充阶段的实时、零调度开销负载均衡方法，它利用图像 Token 的冗余性与分布偏斜，在运行时基于 AIMD 反馈控制算法动态识别并就地图像专家主导的过载设备计算精度降为 FP4 以加速计算，在几乎不损失模型精度的前提下实现了显著的端到端吞吐量提升 [页码：1, 2]。

2. 阅读范围与证据状态

[作者明确陈述] 本报告基于对所提供论文材料的深度分析，阅读范围覆盖论文的完整文本证据分析与图像证据分析（包含第 2 页图片 1、第 4 页图片 2、第 5 页图片 1、第 7 页图片 2、第 9 页图片 1 和第 16 页图片 2） [页码：1-18]。

[基于文中逻辑的推断] 明显的证据状态局限包括：① 原 RTX 5090 真实测试环境下的 PCIe 端到端吞吐加速数据缺失，论文通过模拟 H20 的高带宽 NVLink 延迟进行了修正；② 对其他典型多模态 MoE 模型（如 CogVLM, InternVL）的兼容性与实验结果缺失；③ 未来更丰富精度配置的细节未说明；④ 其他基线方法（如 EPLB、LPLB）的微秒/毫秒级具体调度与求解延迟开销在文中未给出具体的数值数据 [页码：3, 4, 14, 15]。

3. 根问题：论文究竟要解决什么

[作者明确陈述] 本文关注的核心问题是多模态混合专家模型（MMoE，指像拥有多位不同领域专家的咨询公司，对于每次咨询只派出专业对口的一小部分专家，以节省计算成本的神经网络架构 [背景知识]）推理预填充阶段（Prefill Stage，大模型推理的第一阶段，负责一次性读取并理解所有的输入提示词，类似于考试前仔细通读整份试卷 [背景知识]）的全局同步延迟问题。在包含大量图像 Token（标记/词元，大模型处理文本或图像时的最小基本单位 [背景知识]）的多模态输入下，专家并行（EP，将 MoE 模型中的不同专家分配到不同的 GPU 设备上并行运行 [背景知识]）会导致设备间产生极度倾斜且高度动态变化的专家负载失衡，最终在全局同步的 MoE 计算中产生严重的掉队者（Stragglers，由于各设备分担工作量不均，导致耗时最长、拖慢全局同步进度的最慢设备 [背景知识]），拖慢系统整体吞吐量 [页码：1, 3]。

[背景知识] 解决该负载失衡问题的应用价值在于，专家并行已成为支撑大规模多模态 MoE 推理的标准配置。如果不能解决推理时瞬息万变的负载失衡，硬件算力将被卡间同步等待严重损耗，使低延迟、高并发的实际部署变得极其低效 [页码：1]。

[基于文中逻辑的推断] 多模态 MoE 推理负载均衡的难点在于，传统的静态分配或基于历史滑动窗口的预测调度难以跟上图像 Token 引起的极度动态且不可预测的设备负载失衡变化，且物理迁移专家会引入高昂的通信延迟与显存开销，这使得低损耗、低延迟的实时调度难以实现 [页码：3, 4]。

[基于文中逻辑的推断] 本文的 story 是：作者指出，传统的多模态 MoE 推理受制于图像 Token 引发的极度动态且难以预测的设备负载失衡问题 [页码：1]。为了打破预测式调度带来高昂通信/显存开销与预测失配的僵局，作者提出了 ReaLB 机制 [页码：2]。它利用多模态推理中图像 Token 的冗余特征，在不迁移物理专家的前提下，由轻量级的 AIMD（加性增乘性减反馈控制算法，类似于司机在路况好时缓慢加速，一有雾就立刻把速度减半以保持安全稳定 [背景知识]）控制算法在每层 MoE 执行前瞬时评估设备负载 [页码：6]。若发现某设备过载且充斥着图像 Token，就即时将该设备上的 MoE 权重和激活就地量化为 FP4（4 位浮点数精度，一种通过降低数值精度来压缩模型、加速计算的低精度格式 [背景知识]），并调用高效的 NVFP4 GEMM 进行加速以拉平计算掉队者；同时，通过将精度转换和元数据分发与 All-to-All Dispatch 物理通信重叠，完全隐藏了调度开销，实现在极低精度损耗下显著提高端到端推理吞吐量 [页码：1, 5, 6, 8]。

4. 旧方法为何不够

[作者明确陈述] 辅助平衡损失与设备约束路由路线无法直接适用于推理阶段。这类方法原本试图在训练阶段约束门控的路由选择，使专家负载尽可能在多 GPU 间均匀分布，但由于其专门面向训练设计，无法在推理阶段修改已有模型的权重与门控 [页码：1, 3]。本文通过运行时自适应调度模块回应，能够针对动态输入进行就地调度，而不修改门控逻辑 [页码：6]。

[作者明确陈述] 影子专家/专家复制方法（如 FasterMoE）存在极高的网络通信延迟和显存开销。该路线虽然在推理期间通过动态复制多份过载专家分发到各卡以缓解拥堵，但在 GPU 设备之间搬运大模型专家参数会产生与搬运大小成正比的通信延迟（ $K \cdot Bytes_{expert}$ ），且冗余副本占用了宝贵的显存，限制了推理的最大 Batch Size [页码：1, 3]。本文通过在线精度转换与流水线编排回应，由于每个专家仅在本地保留一份原权重，无需跨卡迁移或存储冗余专家参数 [页码：5, 6]。

[实验支持] 基于历史预测的负载均衡（如 EPLB / Async_EPLB）在多模态 MoE 推理下面临预测失配与高昂通信开销的限制。该路线利用过去迭代的滑动窗口历史来预测并重新分配专家，但多模态推理路由变化剧烈，热点会在短周期内瞬移（热点卡在几步内就从 Rank 4 跳变至 Rank 6），导致历史预测与实际执行发生错配，且搬运专家也产生了极大的网络传输和显存开销 [页码：3, 4]。本文通过实时模式感知负载均衡调度与流水线编排回应，利用就地 FP4 量化进行非对称加速，成功避免了物理迁移专家；实验结果显示 EPLB 反而恶化了 MoE 延迟（从 Baseline 的 1.51 ms 恶化至 2.15 ms），而本文方法则成功降低至 1.36 ms [页码：5, 6, 8, 9]。

[基于文中逻辑的推断] 线性规划负载均衡（LPLB）路线难以适应低延迟的实时调度。该路线借助线性规划模型重分配 Token 以获得更优的卡间平衡，但若为了适应实时负载而以高频触发其复杂的线性规划计算，其求解 LP 问题产生的调度计算开销将非常显著，甚至完全抵消其优化收益 [页码：3]。本文通过轻量级 AIMD 自适应调度与 LB 门控回应，采用极轻量级的阈值公式进行 O(1) 判定，且在小 Batch 下不予触发以规避开销 [页码：6, 7]。

[实验支持] 统一低精度量化（FP4-All）会引入灾难性的模型准确率退化。该路线虽然将所有的 MoE 层专家无差别地以 FP4 低精度运行能取得硬件计算性能的最大释放，但在多模态推理中不同 Token 对精度的敏感度差异巨大，无差别量化会导致全局推理准确率的大幅退化（例如在 DynaMath 上 Kimi-VL 准确率骤降 8.19%） [页码：8]。本文通过模式感知自适应精度控制回应，仅对负载极高且为图像主导的设备进行局部降级，以局部牺牲换取全局负载拉平，保护了文本等高精度敏感 Token 从而使平均准确率下降控制在 1.0% 以内 [页码：6, 8]。

5. 核心洞见与假设

[作者明确陈述] 图像 Token 在模型前向传播中表现出比文本 Token 更高的信息冗余度，且是导致负载失衡的罪魁祸首。这一发现基于分析，专家并行中的掉队 GPU 几乎都是由那些汇聚了大量图像 Token 的“图像密集专家”所导致的，同时图像数据本身的信息密度较低，对计算精度微调表现得更为鲁棒 [页码：2, 3]。

[基于文中逻辑的推断] 局部非对称降精度能够拉平负载掉队者且控制精度损耗在极低范围。如果只对负载偏离平均线且主要由图像 Token 填充的设备实施 FP4 量化加速，其余文本主导卡及低负载卡维持高精度运行，则可以利用图像 Token 的冗余度，在不影响模型整体精度的前提下就地加速掉队卡计算，拉平全局延迟 [页码：1, 2, 6]。

[基于文中逻辑的推断] 调度元数据搜集与在线转换开销可以通过与跨卡分发通信时间重叠进行完美隐藏。如果在每个 MoE 执行前，利用 CUDA Stream 将各 rank 收集负载元数据 Allgather 传输的时间（S）以及专家权重在线量化为 FP4 的计算时间（T）与跨 GPU Token 物理通信（All-to-All Dispatch）完全并行重叠，就能将 ReaLB 调度和转换开销完全隐蔽，实现零运行时调度开销 [页码：1, 2, 6]。

6. 方法：从洞见到可执行系统

[基于文中逻辑的推断] 本系统的前向推理总体流程实现了模式感知、自适应精度的零开销负载拉平。输入的文本和图像 Token 经过 Gate 路由分发；ReaLB 调度器在 MoE 执行前收集各 GPU 设备的总负载与模式占比，动态确定过载且图像主导的 GPU（Hot Rank）；由流水线协调器在线将该卡上的 MoE 权重和激活量化为 FP4。随后，这些特定的卡调用低精度 NVFP4 GEMM 算子进行专家层前向计算，其余卡维持默认的 W16A16 精度计算，最终通过 All-to-All 通信和规约汇总输出结果 [页码：5, 6]。

1. 路由与分析组件：

- [基于文中逻辑的推断] 动机：获取准确的当前迭代 Token 专家分配，避免历史预测滞后 [页码：5, 6]。
- [作者明确陈述] 运行机制：在 MoE 层运行前，在卡间执行极轻量级的 Allgather 传输，统计各 rank 上的全局设备负载与模式占比 [页码：5, 6]。
- [基于文中逻辑的推断] 技术优势：基于纯实时的路由分布实施无专家重定位的就地加速策略 [页码：6]。

2. 自适应调度器：

- [基于文中逻辑的推断] 动机：动态且精细地决定哪些设备可以安全地精度降级以拉平负载，同时保护高精度敏感 Token [页码：6]。
 - [作者明确陈述] 运行机制：运行同步决策策略，识别处于过载状态（负载偏离度 $IB_d > C = 1$ ）且图像比例超过阈值（ $R_{vd} > M_d$ ）的设备作为量化目标，标记为 "Hot Device"，执行 FP4 量化；高负载的文本主导卡（ $R_{vd} \leq M_d$ ）则被标记为 "Protected"，维持 W16A16 高精度。同时，调度器监测全局最大负载偏离度 IB_{global} 。若其超过警戒线 $\tau = 1.5$ ，则触发 AIMD 算法的乘性减机制使控制阈值 M_d 减半（容许更多专家降级），否则逐步加性恢复（提高精度，控制质量降级） [页码：6]。
 - [基于文中逻辑的推断] 技术优势：用极轻量级的阈值公式进行 O(1) 判定，能时刻紧跟最新迭代的路由热点，并在吞吐量和模型精度退化之间取得最优平衡 [页码：6]。
3. 流水线协调器与 LB 门控：
- [基于文中逻辑的推断] 动机：消除在线精度转换与元数据传输引入的运行调度开销，并在小 Batch 下规避不必要的转换 [页码：6, 7]。
 - [作者明确陈述] 运行机制：
 - 利用 CUDA 多 Stream 机制，将各 rank 的元数据 Allgather 传输时间 (S) 以及专家权重在线量化为 FP4 的计算时间 (T) 与跨 GPU Token 物理通信 (All-to-All Dispatch) 完全并行重叠 [页码：5, 6]。
 - 引入全局 Token 负载门控阈值 $\Gamma = 2048$ ，只有当全局并发 Token 数量大于此值时才激活 ReaLB，小 Batch 阶段（非计算受限）则关闭负载均衡以规避开销 [页码：7]。
 - [基于文中逻辑的推断] 技术优势：实现接近零的运行调度开销，且避免小 Batch 下的负优化 [页码：6, 7]。
4. 混合精度执行器：
- [基于文中逻辑的推断] 动机：加速掉队设备的 MoE 前向计算，消除全局同步等待 [页码：5]。
 - [作者明确陈述] 运行机制：在被指定为 "Hot Device" 的 GPU 上在线完成 BF16 到 FP4 的专家权重局部量化，并调用高效的 NVFP4 GEMM 算子执行专家层计算，其他 GPU 则继续运行默认的高精度计算 [页码：5]。
 - [基于文中逻辑的推断] 技术优势：非对称计算精度拉平计算掉队者，避免同步等待，且无需跨卡物理专家迁移 [页码：5]。

7. 为什么它可能有效

[基于文中逻辑的推断] 基于模态感知的就地 FP4 量化加速机制，能利用低精度 Tensor Core 的 4 倍 FLOPS 硬件加速，显著缩短掉队设备的 GEMM 计算耗时，拉平全局 MoE 同步延迟，而需要的条件是硬件具备 FP4 运算的底层加速支持（如 Blackwell 架构），并依赖高度优化的 NVFP4 算子支持 [页码：5, 15]。

[基于文中逻辑的推断] 流水线重叠机制能将元数据 Allgather 传输 (S) 和在线量化计算时间 (T) 完全隐藏在跨设备 Token 物理分发通信 (All-to-All Dispatch) 的时间窗口内，从而在不增加额外系统调度延迟的情况下实现负载拉平，需要的条件是硬件与软件系统支持多 CUDA Stream 异步并发，且 Token 跨卡分发通信时间足够宽以完全重叠 [页码：6]。

[基于文中逻辑的推断] 基于 AIMD 的阈值 M_d 动态调节机制，使得系统在面临高频剧烈波动的设备负载失衡时能够保持高度的反馈敏捷性。它既能在严重失衡时容许更多图像专家降级以拉平掉队卡，又能在失衡缓和时自动恢复高精度，以局部精度牺牲换取全局负载拉平，需要的条件是输入中图像 Token 具有较高的冗余度，允许局部降精度而不破坏整体语义理解 [页码：2, 6]。

[基于文中逻辑的推断] 全局 Token 负载门控机制使得该系统能够精确在“计算受限的大 Batch 推理场景”下激活 ReaLB 以释放吞吐增益，而在“小 Batch / 非计算受限的场景”下将其关闭，确保在 GEMM 计算不占主导时系统不会引入额外的调度与精度转换开销，需要的条件是系统能准确获取并发 Token 数，且设定的单卡 Token 门限 256（对应 8 卡 EP 部署下的全局 $\Gamma = 2048$ ）与计算/非计算受限的分界线完全对应 [页码：7]。

8. 实验与指标：证据是否支撑主张

比较工作与被批判限制的呼应

比较工作/基线	它试图解决的问题或优势	本文指出的具体 limit/失效条件	本文的对应模块	实际比较实验、指标和结果	仍未验证的边界
BF16 Baseline	无负载均衡，保持默认高精度运行 [背景知识]。	在多模态推理大 Batch 下，图像 Token 导致严重的卡间负载失衡，产生掉队者并拖慢全局同步 [页码：1, 3]。	运行时自适应调度模块、混合精度执行器 [页码：5, 6]。	Kimi-VL 在 MMMU/MathVista/DynaMath 上分别实现 $1.32 \times$, $1.31 \times$, $1.30 \times$ 的端到端加速，精度损失小于 3.1% [页码：8]。	卡数较少时，负载偏斜自然平滑，ReaLB 的加速增益将受限 [页码：14]。
Uniform FP4-All	将所有 MoE 计算均量化为 FP4 精度	无差别的粗糙量化导致多模态推理准确率发生难以接受	自适应调度器 （仅对图像主导的过载卡量化，高负载文	Kimi-VL 在 DynaMath 上，FP4-All 准确率下降 8.19%，	在极端噪声敏感或边缘高精尖场景（如临床医学影像

	以获取最大硬件加速 [背景知识]。	的严重退化（如在 DynaMath 上 Kimi-VL 准确率骤降 8.19%） [页码：8]。	本卡 Protected 保护） [页码：6]。	而 ReaLB 仅下降 3.10%，且保留了接近前者的加速性能 [页码：8]。	识别）下的精度劣化表现 [页码：14]。
EPLB (基于历史预测的负载均衡)	周期性重分配与复制热点专家以缓解负载不均 [背景知识]。	① 预测失配：多模态推理路由变化剧烈，历史预测滞后； ② 系统开销：专家迁移产生高昂通信延迟，副本占用显存 [页码：3，4]。	轻量级 AIMD 自适应调度 （就地精度量化，无专家迁移） [页码：6]。	Kimi-VL 下 EPLB 导致 MoE 延迟恶化到 2.15ms，而 ReaLB 降至 1.36ms。EPLB 的端到端加速比降至 0.83x 0.96x（负收益） [页码：8，9]。	论文未给出 EPLB 具体的微秒/毫秒级专家权重搬迁与调度延迟数值 [页码：3，4]。
ReaLB-seq (无流水线重叠消融变体)	验证流水线重叠机制 (Overlap) 的必要性 [背景知识]。	串行执行元数据收集和在线量化，其调度和精度转换延迟会暴露在推理主路径上 [页码：6]。	流水线协调器 （将 (S) 与 (T) 和 (Dispatch) 并行重叠） [页码：5，6]。	去掉重叠的 ReaLB-seq 在 Kimi-VL 上的加速比由 1.32 × 降至 1.25 ×（以 MMMU 为例） [页码：8，9]。	物理 PCIe 互连下（无 NVLink 延迟替代）的真实重叠效果 [页码：15]。

主张与证据强度地图

主张	对应实验/表图	直接证据	证据强度	尚未覆盖的条件
主张 1： ReaLB 能实现 $1.10 \times \sim 1.32 \times$ 的端到端多模态推理吞吐量加速。	Table 1 [页码：8], Figure 5(a, d) [页码：9]	[实验支持] 在 Kimi-VL 和 Qwen3-VL 两个主流 MMoE 模型上，ReaLB 相比 BF16 基线实现了 $1.10 \times \sim 1.32 \times$ 的端到端吞吐量加速 [页码：8]。	高 （在主流模型和多项基准上均有详尽的端到端对比）	真实 RTX 5090 PCIe 5.0 互连集群（未进行 NVLink 延迟替换）下的实际加速效果 [页码：15]。
主张 2 ReaLB 在加速的同时，能将模型推理平均精度下降控制在 1.0% 以内。	Table 1 [页码：8], Table 2 [页码：8]	[实验支持] Kimi-VL 平均退化 -0.36%，Qwen3-VL 平均退化 -0.59%；单任务中，Kimi-VL 在 MMMU 上下降 1.22%，在 DynaMath 上下降 3.10% [页码：8]。	中等 （多数基准符合 1.0% 以内，但 DynaMath 单项精度下降达 3.10%）	医疗、安全等边缘高精尖场景以及对噪声极其敏感的场景 [页码：14]。
主张 3： 多模态推理路由与负载表现出极高的瞬时动态波动与不可预测性。	Figure 1(b) [页码：2], Figure 2 [页码：4], Figure 10 [页码：16]	[实验支持] 设备负载失衡度在 500 个迭代中呈现高频持续波动，且历史记录预测的 Top-1 热点与实际观测热点发生严重错配 [页码：4，16]。	高 （时序折线和散点图直观展示了热点漂移和高频震荡）	其他典型的 MMoE（如 CogVLM, InternVL 等）上的真实路由情况 [页码：14]。
主张 4： 通过将元数据传输及在线量化与 Token Dispatch 重叠，能实现接近零的系统调度开销。	Figure 5(a, d) [页码：9], Table 1 [页码：8]	[实验支持] 相比于 ReaLB-seq，ReaLB 通过流水线重叠在 Kimi-VL 和 Qwen3-VL 上端到端耗时分别进一步缩短了 2.9% 和 7.1% [页码：8，9]。	高 （有无 Overlap 的消融对照实验及细粒度耗时分解提供了直接支持）	真实 PCIe 5.0 互连（非高带宽 NVLink 模拟）下重叠的完整性 [页码：15]。
主张 5： 基于 AIMD 的自适应调节能动态调节精度退化的敏感度，提供比固定阈值更优 of 精度-效率平衡。	Table 1 [页码：8], Figure 9 [页码：9]	[实验支持] 将 M_d 固定为 0 的变体 ReaLB-m1，在 Kimi-VL 的 MMMU 任务上准确率损失从	中等 （仅针对固定阈值 0 进行了消融对比，对其他固定阈值的广泛对比未充分展示）	其他模型和下游任务的多维度固定阈值参数敏感性分析 [页码：8]。

		ReaLB 的 -1.22% 扩大到了 -2.22% [页码：8]。		
主张 6 :ReaLB 适用于大 Batch 场景，在小 Batch 下通过门控自动规避以保证无负收益。	Figure 4 [页码：7]	[基于文中逻辑的推断] 单卡并发 Token 数量增加时，GEMM 计算耗时在总延迟中的占比迅速增大，并在 256 处构成了 Compute-bound 的分界线 [页码：7]。	中等 (图 4 证明了单卡 256 处 GEMM 的主导地位，但缺乏门控开启/关闭状态下小 Batch 阶段端到端耗时的直接数据对照)	小 Batch (并发 Token 数 < 2048) 下开启与关闭 ReaLB 的真实延迟与开销对比 [页码：7]。

9. 图表解读与论证关系

Figure 1: Motivation for real-time load balancing.

来源：OCR 第 2 页。

图像解读 验证问题：在多模态 MoE 推理中，专家选择的路由模式在推理迭代之间是否存在剧烈波动，以及是否存在负载热点设备转移 (Hot-spot Shift)，以此论证静态或基于历史预测的调度方案难以应对快速变化的负载，为 ReaLB 实时动态精度转换设计提供动机。

直接结论：Panel 1 显示，在 MMoE 模型的前向推理流中，拼接后的文本与图像 Token 经过 Gate 路由时分配极不平均，导致图像 Token 集中路由至某些特定的 Device 与 Expert，使其成为 Hot Device 与 Hot Expert。Panel 2 显示，Top-1 热点卡索引 (Top-1 Hot Rank Index) 在推理迭代中频繁切换。在部分时段 (如迭代 150-200) 表现出局部的热点稳定性，但在其他时段 (如迭代 380-440) 热点卡在极短的几个迭代内就在 Rank 4、Rank 6、Rank 1 之间频繁、无规律地切换，且热点上的 Token 数量波动巨大，最高可达 6000 左右。

设计含义：启发了 ReaLB 机制采用一种“零调度开销”的就地自适应精度调度设计，无需进行任何重量级的专家权重跨卡迁移或物理副本冗余。即在每个 MoE 层开始前，实时检测当前路由元数据，将当前过载的图像主导 GPU 上的 MoE 计算精度就地切换为 FP4 GEMM，以便立即拉平当前的计算掉队者，从而能够敏捷地跟踪这种高度动态波动的负载瓶颈。

如何阅读：

- Panel 1：按自下而上的数据流向阅读，观察输入拼接后的文本 (白块) 和图像 (黄块) Token 在 Gate 分发后，各设备 (Devices) 上黄块和白块的分布不均，重点对比标有红框的“Hot Device”与普通卡的负载差异。
- Panel 2：横轴为迭代数 (Iterations 100-600)，纵轴为最热卡号 (Top-1 Hot Rank Index 0-7)，散点颜色深浅表示该步 Token 的数量 (# Token 0-6000)。先观察散点在不同迭代中的纵坐标变化；重点比较绿色矩形框内的横向连贯分布 (说明存在短暂的局部性)，以及绿色矩形框外 (迭代 380 至 440 之间) 橙色箭头连接的跨卡号 (Rank 4 到 Rank 6 再到 Rank 1) 的大幅度垂直跳变 (说明热点在快速转移)。

适用范围与证据缺口：覆盖论文实际测试的在含有 8 张 RTX 5090 GPU (采用 EP 并行模式) 的集群上，运行 Kimi-VL 模型进行多模态推理时的动态路由行为。无额外证据缺口。




Figure 2: High dynamics in MMoE routing limit the effectiveness of prediction-based methods. (a) Load imbalance across devices, experts, and modalities. (b) Temporal variation in imbalance severity across iterations. (c) Rapid shifts of the top-1 hot device and expert, highlighting the mismatch between historical observations and current load.

来源：OCR 第 4 页。

图像解读 验证问题：负载在设备级 (Ranks) 与专家级 (Experts) 的分配是否存在严重偏斜，且这种偏斜是否主要由图像 Token 引起；不均衡程度在推理时间维度上的波动情况；以及基于历史滑动窗口的预测 (以 EPLB 为代表) 在面临高度动态的 MMoE 路由时是否会出现预测失配 (Prediction Mismatch) 这一关键缺陷。

直接结论：Panel 1 显示，设备和专家两级均存在严重的负载倾斜。其中 Rank-0 的负载远超 Device-level Ideal Load，且其上 91% 的 Token 均为图像 Token；其他超载卡 (如 Rank-2, 5, 7) 的图像 Token 占比也在 68%-77% 之间。专家端少数专家 (如 Expert 4, 18, 41) 的 Token 数量远超 Expert-level Ideal Load，且这些过载专家的图像 Token 比例均在 58%-93% 之间。Panel 2 显示，负载不均衡系数在整个 500 个迭代中呈现高频持续波动。Expert-level 不均衡度系数在 3 到 10 之间大范围剧烈震荡，Device-level 不均衡度系数则在 1.0 到 2.5 之间持续震荡。Panel 3 显示，依据前 200 个迭代的 historical record 预测的 Top-1 热点主要为 Rank-3/Rank-4 (红线所示)，然而在第 200 到 500 步的实际运行中，真实观测到的 Top-1 热点卡发生显著漂移，稳定在 Rank-1 附近 (绿线所示)。预测的红线与实测的绿线发生了完全错位。

设计含义：

1. 超载卡由高比例图像 Token 主导的特征，为 ReaLB 实施“模态感知、自适应精度的 MoE 调度机制”提供了核心依据。它允许 ReaLB 仅在运行时对图像主导的过载设备实施 FP4 精度量化，利用图像 Token 的高冗余度在不影响模型整体精度的前提下就地加速，从而拉平掉队设备。
2. 剧烈的不均衡波动以及严重的预测失配支持了 ReaLB 在运行时采用“AIMD 自适应控制”和“层级实时调度”的设计，不依赖历史滑动窗口，而是通过每个 MoE 层运行前实时的极轻量元数据收集来进行 O(1) 级的自适应精度转换决策，从而能时刻紧跟最新迭代的路由热点。

如何阅读：

- Panel 1：上半部分横轴为 Rank-0 至 Rank-7，纵轴为 Token 数，下半部分横轴为 Expert ID (0-63)，纵轴为 Token 数。对比各柱条的总体高度与其对应的 Device-level/Expert-level Ideal Load (水平虚线) 的差值，并比较柱条中黄色 (Vision) 与蓝色 (Text) 的高度比例，以及柱子下方标注的百分比。
- Panel 2：横轴为迭代数 (Iterations 0-500)，纵轴为负载不均衡度 (Load Imbalance (max/mean))。对比代表 Expert-level Imbalance (蓝色圆圈线) 和 Device-level Imbalance (橙色方块线) 的曲线高度和波动剧烈程度。
- Panel 3：横轴为迭代数 (Iterations 0-500)，纵轴为物理设备卡号 (Rank-0 至 Rank-7)。在 0-200 步的 Historical Record 灰色背景区观察散点的总体分布，在 200-500 步的未着色区对比红色的预测线与绿色的观测线的纵向对齐情况。

适用范围与证据缺口：覆盖论文中以 EPLB 作为代表性比较对象，对 Kimi-VL 模型进行 500 个迭代的推理测试时的负载分布、不均衡波动和热点错配表现。无额外证据缺口。




Figure 3: ReaLB design for efficient multimodal MoE inference. It combines modality-aware scheduling and an overlapping execution pipeline to mitigate device-level latency imbalance while minimizing runtime overhead.

来源：OCR 第 5 页。

图像解读 验证问题：展示并解释 ReaLB 如何通过“自适应调度”和“重叠流水线编排”这两大机制在不产生额外显存和调度开销的前提下，解决多模态混合专家模型（MMoE）推理中由图像 Token 导致的设备级负载失衡问题。

直接结论：在 ReaLB 调度下，并非所有过载的 GPU 都被降级：只有高负载且图像/视觉 Token 占绝对主导 of GPU (如 Rank-1) 会执行低精度的 W4A4 GEMM 计算；而以文本 Token 为主的超载 GPU (如 Rank-2) 以及低负载 GPU (如 Rank-0/3) 则保持高精度的 W16A16 GEMM 运行。元数据收集 (S) 与量化转换 (T) 的执行时间被完全隐藏在 All-to-All Dispatch 物理通信的时间窗之内，没有为推理主路径增加额外的延迟。

设计含义：展示了系统架构中利用 CUDA Stream 实现 (S) 与 (T) 开销与 (Dispatch) 物理通信完全重叠的流水线优化逻辑，以及调度决策中对“总负载”与“模态比例”的双重条件过滤设计。同时论证了统一低精量化 (FP4-All) 在文本处理上面临的精度下降限制，因而在高负载文本卡上设计了 "Protected" 保护屏障。

如何阅读：

- Panel (a)：从底部往顶部阅读。输入 Token 经过 Gate 路由到对应的 EP Rank，ReaLB Scheduler 和 Pipeline Orchestrator 共同决定并处理专家的计算精度，从而执行 MoE 计算。
- Panel (c)：从左至右代表时序。注意紫色虚线区域，元数据搜集 (S) 和精度转换 (T) 被包裹在跨设备 Token 分发 (Dispatch) 的物理通信时间中，即 "Hidden Overhead"。
- Panel ① (b)：比较四个 EP Rank (Rank 0 至 Rank 3) 的输入负载 (白色条形为文本 Token，黄色条形为图像 Token)：Rank-0 与 Rank-3 负载处于正常水平，执行默认的 W16A16 GEMM (蓝色实线框)；Rank-1 总负载高且图像 Token 占比极高 (Vision-heavy device)，被判定为 "Hot Device"，降级执行低精度的 W4A4 GEMM (粉色虚线框)，并获得 Tensor Core 的 4 倍 FLOPS 硬件加速；Rank-2 总负载虽高但主要由文本 Token 构成 (Text-heavy device)，被判定为 "Protected"，继续执行默认的 W16A16 GEMM 以保护文本语义精度。

适用范围与证据缺口：适用于支持多流并发、低精度 Tensor Core (如 FP4) 加速计算且具有专家并行 (EP) 的分布式多模态大模型推理环境。无额外证据缺口。




Figure 4: ReaLB is enabled only in the compute-bound regime with large batch sizes.

来源：OCR 第 7 页。

图像解读 验证问题：验证并解释为何 ReaLB 负载均衡仅在“大 Batch / 计算受限 (Compute-bound)”的场景下开启，而在“小 Batch / 非计算受限 (Non-compute-bound)”的场景下通过 LB 门控保持关闭，以避免不必要的调度和转换开销。

直接结论：随着并发 Token 数的增加，单层 MoE 的处理总延迟显著上升，且深绿色代表的 GEMM 计算耗时在总延迟中的占比迅速增大，主导了整体执行开销。当 Token 数量小于 256 时，单层 MoE 延迟极低（均小于 0.5 ms），且非 GEMM 算子（如 Activation 与 Reduction）的耗时比例相对显著。ReaLB 的开启门槛被精确设置在单卡 Token 负载等于 256 处。

设计含义：为 ReaLB 中全局 Batch 门控阈值 Γ 的设置提供了定量的实验支撑。实验中将单卡阈值设为 256（对应 8 卡 EP 部署下的全局阈值 $\Gamma = 2048$ ），这与图中橙色虚线标注的 Compute-bound 边界完全对应，确保了 LB 门控仅在 GEMM 主导瓶颈时才被激活。

如何阅读：

- 横轴 (x-axis)：并发的 Token 数量 (# Token)，采用对数刻度，范围为 4 到 16384。
- 纵轴 (y-axis)：单层 MoE 处理的总耗时 (Time)，单位为毫秒 (ms)，范围为 0 到 10 ms。
- 对比阅读：观察随着 Token 数量增大，不同耗时分量（尤其是深绿色 GEMM）占比的演变；并比对以 256 词元为分界线的左（关闭）右（开启）区域在总耗时和 GEMM 占比上的差异。

适用范围与证据缺口：本图基于 8 卡 EP 部署、vLLM 推理框架以及 NVFP4 GEMM 底层算子的软硬件组合，覆盖单卡并发负载为 4 到 16384 Token 的测试区间。无额外证据缺口。




Figure 5: Fine-grained MoE latency analysis. Top row (a-c): Kimi-VL; bottom row (d-f): Qwen-VL.

来源：OCR 第 9 页。

图像解读 验证问题：验证 ReaLB 方法在不同多模态 MoE 模型（Kimi-VL 和 Qwen-VL）下的端到端推理时间降低效果；验证 MoE 层在多线程迭代中的实时延迟降低幅度和延迟稳定性；以及在卡级（rank-wise）拉平掉队者（stragglers）的效果。此外，通过对比消融变体 ReaLB-seq 来验证流水线重叠隐藏开销机制的有效性；通过对比基准工作 EPLB 和 Async_EPLB 论证其系统调度开销过大且存在预测滞后从而导致负收益的缺陷，确立就地量化决策的优越性。

直接结论：

- **端到端加速：**在 Kimi-VL 下，ReaLB 相较于 Baseline 实现了 22.8% 的端到端耗时降低（即 1.30x 加速），而 EPLB 和 Async_EPLB 分别导致耗时增加了 3.9% 和 2.4%；FP4-All 减少了 25.8%，无重叠的 ReaLB-seq 减少了 19.9%。在 Qwen-VL 下，ReaLB 实现了 8.9% 的端到端耗时降低，而 EPLB 和 Async_EPLB 分别导致耗时增加了 19.5% 和 17.8%；FP4-All 减少了 11.0%，ReaLB-seq 仅减少了 1.8%。
- **MoE 层时序延迟：**Kimi-VL 中，ReaLB 平均延迟为 1.36 ± 0.03 ms，明显低于 Baseline 的 1.51 ± 0.04 ms，且波动极小；而 EPLB 平均延迟恶化至 2.15 ± 0.10 ms 且波动剧烈。Qwen-VL 中，ReaLB 平均延迟为 1.39 ± 0.04 ms，低于 Baseline 的 1.48 ± 0.04 ms；而 EPLB 延迟恶化至 1.99 ± 0.07 ms。
- **卡级负载分布：**Kimi-VL 中，在最慢的掉队节点（Rank 7，Baseline 延迟最大，接近 1.5ms）上，ReaLB 成功将延迟降至约 1.1ms（即实现了 1.29x 的局部加速），并且将其他超载节点（如 Rank 0、Rank 3）的延迟大幅拉平。Qwen-VL 中，在掉队节点 Rank 5 上，ReaLB 将延迟大幅压低（实现 1.62x 局部加速），使各卡 MoE 延迟的分布更加均衡，显现出极强的局部掉队拉平效果。

设计含义：

- 验证了 ReaLB 的端到端加速确实显著，且性能非常逼近 FP4-All 这一性能上限，证明了 ReaLB 在减少推理时间上的高效性。
- ReaLB-seq 与 ReaLB 的差距直观验证了隐藏调度与转换开销（通过与 dispatch 通信重叠）能显著收回性能损耗。在 (a) 中，ReaLB-seq 柱状图中可以看到灰色和粉色代表的 dispatch 与 online quantization 开销，而在 ReaLB 中由于重叠，这部分开销基本被 overlapping 成功隐藏。
- 表明由于多模态 MoE 推理的高度动态波动，EPLB 因为历史预测失配以及迁移专家产生高额的 eplb_overhead，导致其 MoE 层平均延迟反而比 Baseline 还要高（Kimi-VL: 2.15 ms vs 1.51 ms），验证了不进行物理迁移、在掉队卡就地降低精度的 ReaLB 设计的优越性与必要性。
- ReaLB 在部分 GPU Rank（如 Rank 0, 3, 4）上的延迟极低，这是因为在这些承载了大量图像 Token 且负载偏高的卡上被触发了 FP4 量化加速，从而将全局 MoE 同步延迟限制在了非掉队卡的最高延迟水平（即拉平了 stragglers，实现了 1.29x 和 1.62x 的局部加速）。

如何阅读：

- (a) & (d)：x 轴为不同策略/消融配置，y 轴为端到端耗时时间（Time breakdown (s)），图例代表耗时分解组件（attn, encoder, eplb_overhead, mlp, moe, combine, dispatch, realb_overhead, overlapping）。绿色百分比数字表示耗时减少，红色百分比数字表示耗时增加。
- (b) & (e)：x 轴为迭代次数（Iterations, 0-250），y 轴为 MoE 层平均延迟（MoE Layer Latency (ms)），图例区分 Baseline, EPLB, ReaLB。
- (c) & (f)：x 轴为分布式专家并行卡号（EP Rank Index, 0-7），y 轴为 MoE 层延迟（MoE Layer Latency (ms)），图例区分 Baseline, EPLB, ReaLB，特定柱子上方标有加速比（如 1.29x, 1.62x）或基准线标志（1.00x）。
- 对照组：均以 FP16/BF16 Baseline 作为主要对照组。

适用范围与证据缺口：本实验在单节点 8 张 RTX 5090 GPU 上进行，在 continuous batching 模式（max-num-seqs=12，DynaMath 1K 样本，EP=8）下测绘。无额外证据缺口。




Figure 6: Dynamics of device-level load imbalance across MoE layers 12-21.

来源：OCR 第 16 页。

图像解读 验证问题：验证多模态 MoE 模型在推理过程中设备间负载失衡（Load Imbalance）的严重程度及其极度动态和不可预测的波动特征。作者需要展示不同 MoE 层在数百个迭代步内的负载不均处于动态巨幅波动的状态，用以解释为什么静态分配或基于历史的滑动窗口预测调度（如 EPLB）无法准确应对这种高度动态变化的失衡，从而确立 ReaLB 采用实时、层级自适应决策设计的必要性。

直接结论：在所有 MoE 层（层 12 至 21）中，设备间的负载失衡度随着迭代步（0-500）发生着剧烈且高频的波动，没有呈现明显的收敛或固定周期。负载失衡度普遍处于 1.1 至 2.5 之间，在某些层（如 Layer 19、21）甚至在短时间内飙升至 3.5 到 4.0 以上，说明负载最大卡的处理负担可达平均水平的 3 到 4 倍。不同 MoE 层之间的波动模式和波峰出现的时间节点各不相同，表现出高度的时空异构性。

设计含义：这种极高的动态性意味着任何基于较长滑动窗口预测或离线静态调整的负载均衡方案均会失效。它直接启发并证明了 ReaLB 采用层级（Layer-wise）实时自适应决策（每个 MoE 层开始前即时收集当前设备负载与模态占比）以及 AIMD 自适应调节精度参数 M_d 方案的必要性，因为只有这样高度实时的轻量化反馈控制才能跟上如此剧烈波动的变化节奏。

如何阅读：

- 坐标轴：x 轴表示迭代次数（Iteration），范围为 0 至 500；y 轴表示设备级负载失衡度（Rank-level Load Imbalance (max/mean)），代表最重负载设备的负载与所有设备平均负载的比值，范围通常为 1.0 至 3.0 或 4.0 左右。
- 观察点：观察 10 个子图中浅蓝色折线的高频波动性，对比不同子图在相同迭代步时的失衡度，以此体会层间的波动异构性。

适用范围与证据缺口：本实验采用 Kimi-VL 模型（EP=8 并行配置），在 MMMU 数据集上测试并统计了 MoE 层 12 至 21 在 500 个迭代内的设备负载失衡。无额外证据缺口。

10. 完整因果推理树

- 根问题：在多模态混合专家模型（MMoE）推理的预填充阶段，大量图像 Token 导致设备间产生极度倾斜且高度动态变化的专家负载失衡，产生严重的掉队者设备并拖慢全局同步进度 [页码：1, 3]。
 - 旧方法限制：传统的离线或在线调度（如辅助平衡损失、影子专家、EPLB、LPLB 和无差别全量化 FP4-All）在面临高动态多模态路由时，要么由于无法修改已有门控而失效，要么因为专家迁移的高昂网络通信和显存开销导致延迟恶化（EPLB 在 Kimi-VL 上使延迟从 1.51 ms 恶化到 2.15 ms），要么因为无差别粗糙量化而引入难以接受的严重精度退化（如 Kimi-VL 在 DynaMath 上准确率骤降 8.19%） [页码：1, 3, 4, 8]。
 - 核心洞见/假设：基于图像 Token 具有更高的信息冗余度，假设在运行时只对承载了过多图像 Token 的超载 GPU 降低其专家的 GEMM 计算精度为 FP4，同时将调度与量化转换时间并入跨卡数据分发 All-to-All Dispatch 物理通信时间中重叠（Overlap）隐藏，就能在几乎不损失模型精度的前提下实现零开销的就地加速并拉平全局延迟 [页码：1, 2, 6]。
 - 方法模块：设计了包括实时 Allgather 收集路由数据的**路由与分析组件**、动态选择 "Hot Device" 并利用 AIMD 反馈控制规律动态演进精度控制阈值的**自适应调度器**、利用多 CUDA Stream 隐藏转换延迟并引入全局 Token 门控阈值的**流水线协调器与 LB 门控**，以及在 Hot Device 上就地进行 FP4 量化并调用 NVFP4 GEMM 算子进行计算的**混合精度执行器** [页码：5, 6, 7]。
 - 可验证预测 1：ReaLB 相比 BF16 基线与 EPLB 能实现明显的端到端吞吐量加速，且保留了逼近 FP4-All 的性能。
 - 指标与实验：在 Kimi-VL 和 Qwen3-VL 两个主流 MMoE 模型上进行 MMMU/MathVista/DynaMath 准确率与端到端吞吐量对比实验 [页码：7, 8]。
 - 图表证据：**Table 1** 呈现端到端吞吐加速；**Figure 5(a, d)** 呈现端到端延迟分解 [页码：8, 9]。
 - 结论与适用边界：[实验支持] ReaLB 实现了 $1.10 \times \sim 1.32 \times$ 的端到端吞吐量加速，且 EPLB 产生负收益；适用于大 Batch、EP 部署的计算受限场景 [页码：1, 7, 8]。
 - 可验证预测 2：ReaLB 在加速的同时，能将模型推理平均精度下降控制在 1.0% 以内，显著优于 FP4-All。
 - 指标与实验：在多模态下游任务基准上运行准确率评测，对比三种策略的准确率变化量 (ΔAcc) [页码：8]。
 - 图表证据：**Table 1** 呈现下游基准的准确率退化数值 [页码：8]。
 - 结论与适用边界：[实验支持] 平均准确率下降维持在 1.0% 以内，但 DynaMath 单项任务退化达 3.10%；在数据分布偏移或医疗等噪声极敏感的高精尖场景中需保守使用 [页码：8, 14]。
 - 可验证预测 3：流水线重叠机制能显著隐藏调度和精度转换延迟。
 - 指标与实验：包含与不包含 Overlap 的消融实验（ReaLB 与 ReaLB-seq 对比） [页码：8]。

- 图表证据：Table 1 中的消融比对；Figure 5(a, d) 细粒度 profile 耗时分解 [页码：8, 9]。
 - 结论与适用边界：[实验支持] 隐藏调度和转换延迟对释放硬件潜能起决定性作用，去掉重叠的 ReaLB-seq 加速比明显缩水 [页码：8, 9]。
- 可验证预测 4：基于 AIMD 的自适应调节能优于固定阈值设置。
 - 指标与实验：AIMD 动态机制与固定模式阈值变体 (ReaLB-m1) 的对比消融实验 [页码：8]。
 - 图表证据：Table 1 下的消融数据；Figure 9 阈值 M_d 随迭代波动的演进曲线 [页码：8, 9]。
 - 结论与适用边界：[实验支持] AIMD 动态调节精度能更细粒度地权衡系统加速与推理质量，避免固定阈值下准确率损失翻倍的风险 [页码：8]。

11. 结论、贡献与边界

贡献与结论总结

• 贡献总结：

1. [作者明确陈述] 首次识别并定量剖析了多模态 MoE 推理中由于模式分布不均引起的、随迭代动态波动的设备负载失衡及其不可预测性 [页码：2, 3]。
 2. [作者明确陈述] 提出了 ReaLB 负载均衡控制策略，首创了基于 AIMD 动态调节精度阈值来权衡推理质量与系统加速的方法 [页码：2, 6]。
 3. [作者明确陈述] 提出了开销感知的流水线重叠架构，通过将元数据传输及在线量化与 Token 跨卡分发阶段重叠，实现了接近零的系统调度延迟 [页码：2, 6]。
 4. [作者明确陈述] 在开源推理引擎 vLLM 中集成了方案，并在多种主流模型和多模态理解基准上验证了其取得加速与精度之间的最优权衡 [页码：2]。
- **证据充分的结论：**[实验支持] 在 Kimi-VL 和 Qwen3-VL 两个主流 MMoE 模型上，ReaLB 相比 BF16 基线实现了 $1.10 \times \sim 1.32 \times$ 的端到端吞吐量加速，且平均准确率下降控制在 1.0% 以内（除了 DynaMath 单项任务退化 3.10% 外），完成了在仅产生极低精度损耗的情况下显著提高端到端推理吞吐量的闭环验证 [页码：1, 8]。
 - **尚属推断的意义：**[基于文中逻辑的推断] 该方法打破了云端多模态 MoE 部署时因图像 Token 导致的网络等待与物理卡闲置限制，为低延迟、高并发部署提供了可行的实时非对称混合精度优化范式，也为未来在更大规模、多精度配置下的神经网络运行提供了范本 [页码：1, 2]。
 - **局限与适用条件：**
 1. [作者明确陈述] 本系统高度依赖硬件对 FP4 Tensor 乘法的底层加速支持（如 Blackwell 架构）及像 FlashInfer 这样高度优化的 NVFP4 算子 [页码：5, 15]。
 2. [基于文中逻辑的推断] 对于在训练期就已经被添加了极强负载均衡正则化的 MoE 模型，其推理路由本身倾斜较小，ReaLB 的作用会大打折扣 [页码：14]。
 3. [基于文中逻辑的推断] 在卡数较少导致负载已天然平滑，或医疗、安全等对精度极端敏感的边缘高精尖应用中，需要非常保守地使用该技术 [页码：14]。

审稿式风险检查

- **贡献新意 (Novelty of Contribution)**：[基于文中逻辑的推断] 本文突破了传统物理专家迁移与复制的思路，首创了非对称就地精度量化来拉平掉队设备，新颖性极高；当前证据未显示新意风险 [页码：2, 6]。
- **写作与可复现性 (Writing & Reproducibility)**：[基于文中逻辑的推断] 存在轻微可复现性风险。论文在端到端加速评测中为了模拟服务器环境，使用 H20 上的 NVLink 延迟 (4 TB/s) 人为替代了 RTX 5090 原本较慢的 PCIe 5.0 (64 GB/s) 传输延迟；在不作延迟替换的纯 PCIe 集群中，ReaLB 实际的端到端吞吐加速效果未予说明，这给其他研究者在本本地 PCIe 集群上的重现带来了一定的不确定性 [页码：15]。
- **效果大小 (Effect Size)**：[实验支持] 加速效果在不同模型上存在一定波动。在 Kimi-VL 上 ReaLB 能实现 22.8% 的端到端耗时降低 ($1.30 \times$ 加速)，但在 Qwen3-VL 上端到端加速比仅为 $1.10 \times \sim 1.13 \times$ (耗时降低 8.9%)，在部分模型上的加速上限受到了一定限制 [页码：8]。
- **实验覆盖 (Experimental Coverage)**：[实验支持] 泛化性评估覆盖偏窄。本实验仅验证了 Kimi-VL 和 Qwen3-VL 两个模型，对于其他多模态 MoE 模型（如 CogVLM、InternVL 等）是否具有同等的兼容性和加速和精度表现，文中未予说明，存在泛化推广风险 [页码：14]。
- **方法设计 (Method Design)**：[基于文中逻辑的推断] 存在在特定严苛任务上的精度安全风险。在 DynaMath 数学任务中，精度下降达到了 3.10%，说明在强逻辑推理、数学或高精度图像边缘识别场景下，局部精度降级可能会引入非预期的幻觉或计算偏差，需要在应用边界上审慎防范 [页码：8, 14]。

12. 面向初学者的学习路径

• 1. 混合专家架构 (Mixture-of-Experts, MoE)

- [背景知识] [页码：1, 2]
- 通俗解释：这是一种神经网络模型设计，它不让一个单一的大神经网络处理所有输入数据，而是将网络拆分为许多个被称为“专家”的小网络；对于每个输入的词或图像块 (Token)，由一个分配器 (门控网络) 实时挑选最擅长该内容的 12 个专家进行计算。

- 现实类比：想象一家大型咨询公司，里面有精通翻译的专家、精通数学的专家和精通法律的专家。当客户（输入 Token）带着外语合同来咨询时，公司不需要动用所有人，只需派发给翻译专家和法律专家即可，其他人则可以保持闲置，从而极大节省了人力成本和时间。
- 2. **专家并行 (Expert Parallelism, EP)**
 - ：[背景知识] [页码：1, 3]
 - 通俗解释：由于 MoE 模型的总体参数量极其庞大，单张 GPU 显存无法全部装下，因此需要将不同的专家分派到不同的物理 GPU 上；在计算时，Token 必须通过网络分发发送到目标专家所在的 GPU 上运行。
 - 现实类比：由于咨询公司的各个专家团队规模太大，不得不分在不同的大楼（GPU）里办公。客户需要哪位专家服务，就必须乘车前往对应的大楼（All-to-All 物理通信分发）。
- 3. **掉队者 (Stragglers)**
 - ：[背景知识] [页码：1, 3]
 - 通俗解释：在多张卡并行计算的过程中，因为各 GPU 分配到的 Token 数量严重不均，导致某些承担了过多计算量的 GPU 处理非常慢；而由于模型运行在每一步都需要所有卡同步到齐才能进行下一步，这些最慢的设备就成了拉低全局性能的“掉队者”。
 - 现实类比：团队分工写报告，各人写完自己的部分后一起汇总交卷。如果某个人分到了 90% 的撰写任务，其他人写完后只能干等着他，团队的最终交卷时间完全被这一个最慢的组员绑架。
- 4. **预填充阶段 (Prefill Stage)**
 - ：[背景知识] [页码：1, 18]
 - 通俗解释：这是大模型推理的第一阶段，模型需要一次性通读并提取用户输入的提示词（包括所有文字和图像数据）的上下文关联；该阶段由于需要同时处理海量 Token，计算强度极高，是典型的计算密集型任务。
 - 现实类比：类似于考生在动笔写第一句答案（Decode 阶段）之前，必须先将整张考卷通读一遍，理清题干信息（Prefill 阶段）。
- 5. **模型量化 (Model Quantization)**
 - ：[背景知识] [页码：1, 15]
 - 通俗解释：这是一种模型压缩技术，将高精度格式（如用 16 个比特表示一个实数的 BF16）的数据，转换为低精度格式（如用 4 个比特表示一个实数的 FP4），从而极大地减少数据体积和计算开销，但会损失一小部分计算精度。
 - 现实类比：把一根刻度精确到毫米的钢尺（高精度）换成一根只有厘米刻度的塑料尺（低精度）。虽然测量结果没那么精密了，但使用起来更轻便，速度也更快。
- 6. **AIMD 反馈控制 (Additive-Increase Multiplicative-Decrease)**
 - ：[背景知识] [页码：2, 6]
 - 通俗解释：这是一种源自计算机网络拥塞控制的调节机制，在网络通畅时，非常谨慎地一点点增加发送量（加性增）；而一旦探测到发生了网络拥堵，就立刻成倍地削减发送量（乘性减），例如直接减半，以此来维持系统的高响应与高稳定。
 - 现实类比：司机在高速公路上开车，如果路况很好，就每隔 5 秒把时速提高 1 公里（加性增）；一旦看到前方亮起刹车灯或有雾，就立刻把车速减半（乘性减），确保安全。