

论文解构报告

ReaLB: Real-Time Load Balancing for Multi-modal MoE Inference

Yingping Wang, Yi Wu, Xiangyu Wu, Junwei Cui, Weilin Cai, Zhijiang Guo, Jiayi Huang

Mixture-of-Experts

多模态推理

专家并行

负载均衡

低精度计算

目录

摘要翻译	3
1. 一句话总览	3
2. 阅读范围与证据状态	3
3. 根问题：论文究竟要解决什么	3
4. 旧方法为何不够	5
5. 核心洞见与假设	6
6. 方法：从洞见到可执行系统	6
7. 为什么它可能有效	7
8. 实验与指标：证据是否支撑主张	7
9. 图表解读与论证关系	9
10. 完整因果推理树	12
11. 结论、贡献与边界	12
12. 术语与第一性原理学习路径	13

摘要翻译

混合专家（MoE）架构广泛应用于现代大语言模型和多模态模型中。然而，推理效率常常受到跨不同模态高度动态且倾斜的专家负载的限制。在大批量的预填充（prefill）阶段，视觉 token 往往主导输入序列。在专家并行（EP）下，这会导致严重的负载不均衡，部分设备过载，从而降低系统整体吞吐量。我们提出了 ReaLB，一种面向多模态 MoE（MMoE）推理的实时负载均衡方法，具有零调度开销。ReaLB 在运行时以每个 EP rank 为粒度动态调整 MoE 专家的计算精度：对于由视觉密集型专家主导的 rank，ReaLB 分配更低精度的计算，利用 FP4 Tensor Core 提升执行效率。ReaLB 不需要冗余专家，也不需要额外的显存分配，而是在运行过程中即时进行逐层的专家精度转换，并将相关开销隐藏在 MoE 计算之前的 dispatch 阶段中。在代表性 MMoE 模型上的实验表明，ReaLB 实现了 1.10 倍至 1.32 倍的端到端加速，同时将平均精度损失限制在 1% 以内。

1. 一句话总览

论文元数据

字段	内容
标题	ReaLB: Real-Time Load Balancing for Multimodal MoE Inference
作者	Yingping Wang, Yi Wu, Xiangyu Wu, Junwei Cui, Weilin Cai, Zhijiang Guo, Jiayi Huang
发表场所 / 年份	文中未说明
研究领域	系统, 机器学习
关键词	Mixture-of-Experts, 多模态推理, 专家并行, 负载均衡, 低精度计算

资源链接

- 原始文件：本地上传文件（无外部链接）
- arXiv：文中未说明
- DOI：文中未说明
- 代码 / 数据集：文中未说明

标签（5 个）：Mixture-of-Experts · 多模态推理 · 专家并行负载均衡 · FP4 低精度计算 · vLLM 推理系统

ReaLB 是一种运行时、模态感知的 MoE 负载均衡方法：它不迁移专家，而是在每次前向传播前根据瞬时负载与视觉 token 占比，对"过载且视觉专家主导"的 EP rank 动态切换为 FP4 低精度计算，并把转换开销隐藏在 dispatch 通信中，实现 $1.10\times-1.32\times$ 端到端加速、平均精度损失控制在 1% 以内【作者明确陈述】（）。

2. 阅读范围与证据状态

OCR 覆盖正文第 1-9 页及附录第 16-19 页（Appendix F、G、H、I 部分内容），涵盖引言、动机分析（3.1/3.2 节）、方法设计（4.1-4.3 节）与主实验（5.1-5.3 节）【作者明确陈述】（）。

- 附录 Appendix H 中关于 M_d 演化的"详细实证分析"文字部分未被本 OCR 完整收录，仅有其对应图片（图片批次 5 图片 2）【作者明确陈述】（）。
- 多处关键指标（ ΔAcc 、Speedup）仅有文字定义、无显式计算公式，具体聚合口径未披露，标注为"文中未说明"【作者明确陈述】（）。
- 论文正文出现"ReaLB-mi"与"ReaLB-m1/ReaLB-m2"两套命名，OCR 未做主观统一，如实标注不一致，可能反映 OCR 抽取或版本差异【基于文中逻辑的推断】（）。

3. 根问题：论文究竟要解决什么

在专家并行（EP，把不同专家分布到不同 GPU 上运行的并行策略）部署下，每个 GPU 通常固定托管一部分专家；一次 MoE 层前向计算的层延迟由所有 rank 中最慢的一个决定，即 $T_{MoE}(x) = \max_i T_i(x)$ ，这是一种"木桶效应"结构【作者明确陈述】（）。多模态 MoE（MMoE）推理阶段，尤其是大 batch 的 prefill（一次性处理输入提示词的阶段）阶段，视觉 token 数量远多于文本 token，导致路由到不同专家/设备的 token 量高度倾斜，进而产生严重的设备间负载不均衡，拖慢整体吞吐【作者明确陈述】（）。MoE 通过每个 token 仅激活少数专家实现参数高效扩展，广泛用于现代大模型与多模态模型；但这种稀疏激活+输入依赖路由由天然导致负载不均衡，多模态场景下这一问题更严重，因此直接决定了系统实际可部署的吞吐上限【作者明确陈述】（）。难点在于：该"最慢 rank"的身份在迭代间快速、不可预测地变化，使得依赖历史统计的静态或预测式方法从根本上失效【实验支持】（）。

本文的 story：旧路线（无论训练期均衡损失，还是推理期的专家复制/迁移调度）失效的技术原因是"用历史统计去预测下一时刻的热点"，而推理阶段路由的时间局部性太弱，预测必然滞后；本文的核心转折是把问题从"路由/专家放置优化"转化为"计算精度

自适应"——不追预测，只在当下"原地"降低已确认过载且可容忍精度损失的视觉专家的计算精度，从根本上避免了预测需求 [作者明确陈述] ()。

前排论文大图 问题严重性 呼应：第 3 节：EP 最慢 rank 决定层延迟且其身份不可预测




Figure 1: Motivation for real-time load balancing.

图组解读

- **图组结论**：Hot Device/Hot Expert 位于视觉 token 主导的输入侧，Top-1 热点 rank 在迭代间发生明显跳变
- **论证关系**：为"视觉专家聚集致 straggler"核心洞见与专家激活高动态性提供直观场景，与 Figure 2 定量证据互补
- **适用范围**：不含量化对比，不能单独证明视觉主导与过载之间的因果关系




Figure 2: High dynamics in MMoE routing limit the effectiveness of prediction-based methods. (a) Load imbalance across devices, experts, and modalities. (b) Temporal variation in imbalance severity across iterations. (c) Rapid shifts of the top-1 hot device and expert, highlighting the mismatch between historical observations and current load.

图组解读

- **图组结论**: 设备/专家视觉 token 占比差异显著，专家级不均衡波动远超设备级，预测线与观测线 200 迭代后明显分离
- **论证关系**: 支撑观察 1/观察 2 及 EPLB 预测失配批判，是"瞬时判定优于历史统计"的核心可视化证据
- **适用范围**: 仅验证预测失配一条 limit，基于 Kimi-VL/MMMU 单一设置，未涉及通信与显存开销

4. 旧方法为何不够

路线	原本解决什么	依赖前提/遗留限制	本文批判的具体 limit	对应设计模块
训练期辅助损失 / device-constrained routing	训练阶段调节门控提升专家利用率均衡	假设可在训练时调整梯度/路由目标	"不能直接用于推理", 未展开具体机制 [作者明确陈述] ()	无对应设计模块 (仅作背景问题设定)
FasterMoE 影子专家	复制过载专家到多设备均衡负载	需要额外显存与通信带宽	引入额外内存与通信开销 [作者明确陈述] ()	ReaLB 原地精度切换, 不复制专家
EPLB 历史式专家放置	用历史窗口统计周期性重放置专家	假设负载具有时间局部性	预测滞后、通信开销 $K \cdot Bytes_{expert}$ 、显存开销线性增长 [作者明确陈述] ()	瞬时状态判定 IB_d 取代历史预测
LPLB	用线性规划更均匀重分配 token 流量	需高频调用逼近实时性	高频调用的调度开销可能超过均衡收益 [作者明确陈述] ()	LB Gate + 通信重叠的开销感知设计
通信侧重叠/核融合	降低 all-to-all 通信成本	假设计算已经均衡	无法解决计算本身不均衡 [作者明确陈述] ()	借用既有通信窗口隐藏精度转换开销

以上每条限制对应的实验证据仅部分完整：EPLB 一行有 Table 1/5.3 节量化对比支持 [实验支持] ()；FasterMoE、LPLB、通信侧优化、训练期方法均**未被论文纳入实测对比**，其批判停留在文字论证层面，无法从当前 OCR 内容确认量化差距。综合看，旧方法的核心技术限制可归纳为两条：**(a) 依赖历史统计预测，无法适应推理路由的强瞬时波动；(b) 通过专家复制/迁移实现均衡，天然引入通信和显存开销** [基于文中逻辑的推断] (推理依据：训练期方法、EPLB、LPLB、FasterMoE 的批评中反复出现"预测滞后"与"额外开销"两类问题,)。

5. 核心洞见与假设

核心洞见/贡献：EP 的 straggler (掉队者，即拖慢整体的最慢设备) 主要由聚集了视觉专家的 rank 造成；视觉 token 相较文本 token 在前向传播中表现出更高冗余性 (引用支持 [3,38]) [作者明确陈述] ()。由此推出的核心假设：**将"视觉主导且过载"的 rank 切换为低精度计算，可在几乎不损失文本相关精度的前提下降低该 rank 延迟，从而消除设备间执行时间不均衡** [作者明确陈述] ()。

支撑该洞见的观察 (实现所需前提)：

- 观察 1 (模态驱动的负载倾斜)：某 rank 视觉 token 占比可超 90%，另一些低于 50%；专家级占比范围 31%–93% [实验支持] (，Kimi-VL/MMMU/8GPU)。
- 观察 2 (不可预测的高动态性)：同一短窗口内热点专家负载/均值比可从约 $2\times$ 变到 $12\times$ ，时间局部性远弱于训练阶段 [实验支持] ()。

理论支撑：论文将均衡问题形式化为在线策略优化目标

$$\max_{\pi} \mathbb{E}_x \left[\max_i T_i(x) - \max_i T_i(\pi(x)) - T_{LB}(\pi, x) \right]$$

并论证：优化"token/专家均衡"这类代理指标并非最小化 $\max_i T_i$ 的必要条件；推理阶段不需要为优化稳定性维持 token 均衡，只需直接最小化执行延迟 [作者明确陈述] ()。这为"不追求专家/token 完全均衡，只直接压低设备级延迟"的设计选择提供了理论依据。

前提可能失效的场景：若视觉 token 的冗余性假设不成立 (即视觉专家对精度同样敏感)，或负载倾斜并非以模态为主因，该核心假设的适用性会被削弱；论文未提供该前提的反向消融，属于证据缺口 (见 4.2 节相关说明)。

6. 方法：从洞见到可执行系统

总览：输入为当前层各设备的负载与模态构成 → 判定过载设备 → 在过载设备中筛出"视觉主导"者 → 对这些设备的专家在线转换为 FP4 精度并执行计算 → 转换开销与元数据收集被安排在 dispatch 通信窗口内隐藏 → 输出经均衡后的 MoE 层结果，供后续 Combine/下一层使用 [作者明确陈述] ()。

1. 运行时状态与热点识别 (IB_d , 阈值 C)

- 动机：需要不依赖历史统计、纯瞬时的"是否过载"判定 [作者明确陈述] ()。
- 输入/过程/输出：输入当前层各设备 token 负载 $Load_d$ 与平均负载 $Ideal$ ；计算 $IB_d = Load_d / Ideal$ ；输出热点集合 $\mathcal{H} = \{d \mid IB_d > C\}$ ， $C = 1$ 表示完全均衡 [作者明确陈述] ()。
- 优势：仅用当前层瞬时数据，规避历史预测滞后问题 [基于文中逻辑的推断] ()。

2. 模态感知精度分配 (R_{vd} , M_d)

- 动机：区分"视觉主导可压缩"与"文本主导不可压缩"的过载设备 [作者明确陈述] ()。

- 输入/过程/输出：输入设备上视觉/文本 token 数 N_{vd}, N_{td} ；计算 $R_{vd} = N_{vd}/(N_{vd} + N_{td})$ ；对 $d \in \mathcal{H}$ 且 $R_{vd} > M_d$ 的设备标记为可压缩，其专家用低精度 GEMM 执行，其余保持标准精度 [作者明确陈述] ()。
- 优势：把降精度限定在对损失不敏感的视觉专家上 [作者明确陈述] ()。

3. AIMD 自适应阈值控制

- 动机：固定阈值难以兼顾响应速度与稳定性 [作者明确陈述] ()。
- 规则： $IB_{global} = \max_d IB_d$ ，拥塞阈值 $\tau = 1.5$ ；若 $IB_{global} > \tau$ 则 $M_d = 0.5M_d$ ，否则 $M_d = \min(1, M_d + 0.1)$ [作者明确陈述] ()。
- 优势：借鉴网络拥塞控制思想，拥塞时快速收紧、平稳期逐渐放松 [作者明确陈述] ()。

4. 在线精度转换

- 动机：不增加显存占用的前提下支持实时精度切换 [作者明确陈述] ()。
- 过程：每个专家仅存原始高精度权重+预计算缩放因子；调度下发新精度配置时在线量化到目标精度 [作者明确陈述] ()。


5. 开销隐藏的流水线编排

- 动机：元数据收集 S 与精度转换 T 本身引入额外计算，需从关键路径移除 [作者明确陈述] ()。
- 过程： S 、 T 与 dispatch 阶段的设备间通信重叠执行 [作者明确陈述] ()。
- 优势：LB 开销只涉及本地转换和轻量元数据收集，不随 EP 规模扩展，而 dispatch 延迟随 EP 规模增长，因此重叠后 LB 开销被通信“淹没” [作者明确陈述] ()。


6. LB Gate (全局 batch 阈值 Γ)

- 动机：只有 GEMM 计算主导延迟时，设备负载不均衡才直接转化为延迟不均衡；小 batch 时启用 LB 无意义甚至有害 [作者明确陈述] ()。
- 过程：聚合设备负载超过 $\Gamma = 2048$ (256×8) 时启用 LB，否则退回标准执行 [作者明确陈述] ()。

前排论文大图 方法流水线 呼应：第 6 节：模态感知精度分配与开销隐藏流水线的整体系统设计



Panel 1



Panel 2

Figure 3: RealB design for efficient multimodal MoE inference. It combines modality-aware scheduling and an overlapping execution pipeline to mitigate device-level latency imbalance while minimizing runtime overhead.

图组解读

- **图组结论**：Rank-1 视觉主导过载转 NVFP4 精度，Rank-2 文本主导过载保持标准精度并标注 Protected
- **论证关系**：具体实例化“过载不等于降精度”判定规则，与开销隐藏流水线设计互补
- **适用范围**：为示意性简化架构，不含任何速度/精度数值，不能论证实际效果幅度

7. 为什么它可能有效

- 瞬时状态判定 (IB_d) 只依赖当前层数据，逻辑上避免了历史统计对时间局部性的假设，因而能应对 3.2 节实证的强瞬时波动 [基于文中逻辑的推断] ()。
- 将降精度限定于“视觉主导+过载”设备，理论上兼顾速度与精度，前提是视觉 token 冗余性假设成立（背景知识支持，非本文直接实验验证的前提本身） [背景知识] ()。
- 流水线重叠使 LB 开销不随 EP 规模线性增长，理论上具有可扩展性，但该扩展性论证仅为理论推演，未在不同 EP 规模下实测验证 [基于文中逻辑的推断] ()。
- AIMD 通过瞬时拥塞信号（而非历史窗口）调节阈值，预期能在拥塞与稳定之间取得比固定阈值更好的平衡 [作者明确陈述] ()。

8. 实验与指标：证据是否支撑主张

8.1 实验问题与判定标准

- 效果问题: ReaLB 相对 Baseline/EPLB/FP4-All 的端到端速度与精度损失如何? → 对应 Table 1/2 [实验支持] ()。
- 机制/必要性问题: 预测式方法是否确实因动态性而失效? 模态感知与流水线重叠是否各自必要? → 对应 5.3 节延迟分解、ReaLB-seq/ReaLB-m1/m2 消融 [实验支持] ()。
- 鲁棒性问题: 方法是否跨模型 (Kimi-VL、Qwen3-VL) 泛化? → 对应两模型对比结果 [实验支持] ()。
- 适用范围问题: 方法是否仅在计算受限 (大 batch) 场景有效? → 对应 LB Gate 部分, 但缺乏量化消融 [作者明确陈述] (, 量化对比"文中未说明")。

8.2 数据、任务、对比与运行设置

- 硬件: 8×NVIDIA RTX 5090, DP+EP 混合并行 [作者明确陈述] ()。
- 框架: vLLM v0.13.0, 混合精度来自 LLM Compressor, NVFP4 GEMM kernel 来自 FlashInfer [作者明确陈述] ()。
- 模型: Kimi-VL-A3B-Instruct (64 路由专家)、Qwen3-VL-30B-A3B-Instruct (128 路由专家), 均做 NVFP4 PTQ [作者明确陈述] ()。
- 任务/benchmark: MMMU、MathVista、DynaMath [作者明确陈述] ()。
- 部署: Prefill-Decode colocated, continuous batching [作者明确陈述] ()。
- 超参数: 容量因子 $C = 1$, M_d 初始 0.9, $\Gamma = 2048$ [作者明确陈述] ()。
- 对比方法: Baseline (W16A16)、FP4-All (全 W4A4)、EPLB、Async_EPLB、ReaLB、ReaLB-seq、ReaLB-m1/m2 [作者明确陈述] ()。
- 重复次数/统计方式: 文中未说明 (Panel2/5 给出均值±标准差, 但未说明重复运行次数或统计口径)。

8.3 指标字典与对应公式

- **指标与方向**: Speedup (端到端速度提升), 无符号标注, 比值形式, 越大越好。
 - **定义与公式**: 作者文字定义为"相对 BF16 baseline 的端到端吞吐速度提升" (); **来源层级: 无可核验公式**——正文未给出显式计算式或聚合口径。
 - **实验用途**: 回答效果问题, 比较 ReaLB 与 Baseline/EPLB/FP4-All。
 - **读数与边界**: 区间 $1.10 \times - 1.32 \times$ (); 不能证明该提升在不同 EP 规模、硬件平台下同样成立 (仅 8×RTX5090 单一配置)。
- **指标与方向**: ΔAcc (精度下降), 单位百分点, 越小越好。
 - **定义与公式**: 作者文字定义"相对 BF16 baseline 的准确率下降" (); **来源层级: 无可核验公式**——未给出分子分母或跨 benchmark 聚合方式。
 - **实验用途**: 检验模态感知降精度是否比全模型降精度 (FP4-All) 更保守。
 - **读数与边界**: 如 Kimi-VL/DynaMath, FP4-All -8.19%, ReaLB -3.10% [实验支持] (); Qwen-VL 上 ReaLB 平均 <0.6% (); "平均精度损失<1%"的跨 benchmark 聚合方法文中未说明。
- **指标与方向**: 吞吐 (tokens/sec), 越大越好。
 - **定义与公式**: 作者明示测量方法——CUDA 事件细粒度计时+vLLM benchmark 测端到端吞吐, 单位为"处理 token 数/秒 (输入+输出)" (), 属"作者文字定义"的测量方法而非公式。
 - **实验用途**: 作为 Speedup 的底层测量依据。
 - **读数与边界**: 具体吞吐绝对数值未在本 OCR 文字中给出, 仅有换算后的 Speedup 倍数。
- **指标与方向**: MoE 层延迟, 单位 ms, 越小越好。
 - **定义与公式**: 作者说明其用途为"捕捉逐层执行效率" (), 基于 CUDA 事件测量, 无显式公式; **来源层级: 无可核验公式**。
 - **实验用途**: 检验 EPLB 是否因预测失配"加剧"而非缓解不均衡。
 - **读数与边界**: Kimi-VL 上 ReaLB 从 1.51ms→1.36ms, EPLB 反而从 1.51ms→2.15ms [实验支持] (); Qwen-VL 上 1.48ms→1.39ms (ReaLB)、→1.99ms (EPLB), 为图像补充数值 [图像直接可见] ()。
- **指标与方向**: IB_d (设备级负载不均衡度), 无量纲比值, 越接近 1 越均衡。
 - **定义与公式**: $IB_d = Load_d / Ideal$, **来源层级: 原文公式** ()。
 - **实验用途**: 作为热点识别的判定输入, 也是图 6/7 类附录证据的纵轴定义。
 - **读数与边界**: 附录图显示跨 10 个 MoE 层普遍在 1.0–2.0 波动、间歇达 2.5–4.0 [图像直接可见] (); 仅是聚合比值, 不揭示具体是哪个 rank/专家持续热点。

8.4 主结果、消融与证据边界 比较工作与被批判限制的呼应

比较工作/基线	核心限制或失效条件	本文对应模块	直接实验与仍未验证的边界
EPLB	历史窗口预测滞后于路由动态性；再平衡带来通信/显存开销 [作者明确陈述] ()	瞬时 IB_d 判定 + 原地降精度 (4.2 节)	Table 1/2、5.3 节延迟分解直接验证 (EPLB speedup 多次<1.00, MoE 延迟升至 2.15ms) [实验支持] () ; 未验证不同 EP 规模下 EPLB 通信/显存开销的量化对比
FP4-All	均匀低精度对多模态负载过于激进, 精度损失显著 [作者明确陈述] ()	模态感知选择性降精度 (4.2 节)	Table 1 直接对比 $\Delta\text{Acc}/\text{Speedup}$ [实验支持] () ; 缺少"仅对文本主导 rank 降精度"的反向消融
FasterMoE、LPLB、通信侧重叠方法	分别为显存/通信开销、高频调度开销、无法解决计算不均衡 [作者明确陈述] ()	无专家复制、开销感知设计、借用通信窗口	论文未将三者纳入实测对比表, 无法从当前 OCR 内容确认量化差距

主张与证据

主张	直接证据 (实验/表图)	证据强度与边界
C1: 端到端 $1.10\times-1.32\times$ 加速、精度损失<1%	Table 1 逐 benchmark 数值 [实验支持] ()	覆盖较完整, 但"<1%"的跨 benchmark 平均口径文中未说明
C3: EPLB 无法适应推理路由动态性	Figure 2c 预测/观测分离、5.3 节 MoE 延迟对比 [实验支持] ()	缺少"预测命中率"量化指标, 仅有定性+间接速度证据
C4: 模态感知优于均匀降精度	Table 1 ReaLB vs FP4-All 的 $\Delta\text{Acc}/\text{Speedup}$ [实验支持] ()	缺少反向消融, 无法完全分离"模态选择"与"降精度比例"各自贡献
C5: 流水线重叠隐藏开销	ReaLB vs ReaLB-seq 对比 (, 及附录 Appendix I 跨 benchmark 复现) [实验支持]	缺少 S+T 绝对开销时间的直接测量
C9: 仅计算受限场景有效	LB Gate 定性说明+ $\Gamma=2048$ ()	Gate 开关的量化消融数字文中未说明

- 消融显示 AIMD 自适应控制比固定阈值 (ReaLB-m1/m2) 更稳定 [实验支持] (), 但 M_d 演化的详细文字分析在 Appendix H 未被本 OCR 完整收录。
- Rank 级别最高提速 $1.29\times$ (Kimi-VL)、附录图片显示 Qwen-VL 某 rank 达 $1.62\times$ (该数值未被正文引用) [实验支持] ()。
- 所有实验均在单一 $8\times\text{RTX5090}$ 集群上完成, 未见跨 EP 规模或跨硬件平台验证 [基于文中逻辑的推断] ()。

9. 图表解读与论证关系

#Token	Token Alignment (ms)	Activation (ms)	Reduction (ms)	GEMM (ms)
4	0.5	0.5	0.5	0.5
8	0.5	0.5	0.5	0.5
16	0.5	0.5	0.5	0.5
32	0.5	0.5	0.5	0.5
64	0.5	0.5	0.5	0.5
128	0.5	0.5	0.5	0.5
256	0.5	0.5	0.5	1.0
512	0.5	0.5	0.5	1.5
1024	0.5	0.5	0.5	2.0
2048	0.5	0.5	0.5	3.0
4096	0.5	0.5	0.5	5.0
8192	0.5	0.5	0.5	8.0
16384	0.5	0.5	0.5	10.0

Figure 4: ReaLB is enabled only in the compute-bound regime with large batch sizes.

图组解读 适用边界 呼应: 第 6 节: LB Gate 仅在计算受限、聚合负载超过 $\Gamma=2048$ 时启用

- **图组结论:** token 数增大后 GEMM 分段占比迅速上升, 虚线右侧成为主导分段
- **论证关系:** 为"仅计算受限区间启用 LB"提供定性支持, 呼应主张地图 C9
- **适用范围:** 虚线与 $\Gamma=2048$ 精确对齐无法从对数轴判读, 无开关前后量化加速数字




Figure 5: Fine-grained MoE latency analysis. Top row (a-c): Kimi-VL; bottom row (d-f): Qwen-VL.

图组解读 实验结论 呼应：第 8 节：C3（EPLB 无法适应动态路由）与 C5（流水线重叠隐藏开销）

- **图组结论**: Kimi-VL 上 ReaLB 总时长-22.8%、EPLB+3.9%，MoE 延迟 ReaLB 1.51→1.36ms、EPLB→2.15ms，Qwen-VL 趋势一致
- **论证关系**: 直接验证 EPLB 历史预测适得其反的机制与流水线重叠的速度收益
- **适用范围**: 仅覆盖 DynaMath 单一 benchmark，跨 benchmark 泛化性由附录图补充验证




Figure 6: Dynamics of device-level load imbalance across MoE layers 12-21.

图组解读 适用边界 呼应：第 8 节：观察 2（不可预测高动态性）从单层扩展到多层的验证边界

- **图组结论**: 跨 10 个 MoE 层（Layer12-21） IB_d 普遍在 1.0-2.0 波动，间歇达 2.5-4.0
- **论证关系**: 支撑逐层瞬时判定设计的必要性，将动态性观察从单层扩展到多层
- **适用范围**: 具体模型/数据集未重复说明，无法从当前 OCR 内容确认确切实验设置




Figure 7: Overloaded devices and experts across iterations for layer 12-19, with token proportions for different modalities.

图组解读 适用边界 呼应：第 8 节：视觉 token 占比 31%-93% 的模态负载倾斜跨层泛化边界

- **图组结论**: 8 层（Layer12-19）均现超载 rank 与视觉占比 60%-96% 的热点专家，个别专家仅约 26%
- **论证关系**: 将模态驱动负载倾斜从单层扩展到 8 层，佐证 R_{vd} 阈值判定的必要性
- **适用范围**: 具体模型/数据集来源未标注，无法从当前 OCR 内容确认




Figure 8: Token composition in continuous batching.

图组解读 适用边界 呼应：第 8 节：colocated 部署近似 prefill-only 场景的方法学假设

- **图组结论**: Decode token 占比全程远低于 10%，视觉 token 占比在 0.2-1.0 间剧烈波动
- **论证关系**: 为 colocated 设置不被 decode token 污染背书，支撑观察 1/观察 2 的动态性描述
- **适用范围**: 具体模型/benchmark 未标注，无法从当前 OCR 内容确认




Figure 10: End-to-end latency breakdown on additional benchmarks.

图组解读 **实验结论** 呼应：第 8 节：C1/C3/C5 主张从 DynaMath 扩展到 MMMU/MathVista 的泛化验证

- **图组结论**：MMMU/MathVista 上 EPLB/Async_EPLB 总时长增加 (+3.1%~+22.4%)，ReaLB 降幅均大于 ReaLB-seq
- **论证关系**：复现 EPLB 预测失效机制与流水线重叠速度收益，验证跨 benchmark 稳健性
- **适用范围**：各分段无绝对数值，无法精确量化究竟隐藏了多少开销




Figure 9: Evolution of the control parameter under AIMD-based adaptive control on DynaMath. The red background indicates time steps where the global imbalance exceeds the congestion threshold.

图组解读 **消融验证** 呼应：第 6 节：AIMD 自适应阈值控制的瞬时拥塞响应规则 ($\tau=1.5$)

- **图组结论**： M_d 在拥塞区间骤降、非拥塞期逐步回升，Qwen3-VL 拥塞区间更宽更连续
- **论证关系**：可视化 AIMD 规则的实际触发过程，为 AIMD 优于静态阈值的主张提供机制解释
- **适用范围**：无静态阈值对照曲线，是否优于固定阈值仍需依赖 Table 1 数字

表格证据：Table 1: Main performance comparison and trade-offs under different load balancing strategies.

- 实验结论** 呼应：第 8 节：C1 ($1.10\times-1.32\times$ 加速、精度损失<1%) 与 C4 (模态感知优于均匀降精度)
- **图组结论**：ReaLB 相对 Baseline 加速 $1.10\times-1.32\times$ ，较 FP4-All 精度损失显著更低 (如 DynaMath -3.10% vs -8.19%)
 - **论证关系**：量化对比 ReaLB/EPLB/FP4-All 的速度-精度权衡，直接支撑核心效果主张
 - **适用范围**：跨 benchmark 平均口径文中未说明，仅 $8\times RTX5090$ 单一硬件配置

Model	Workload	Baseline	EPLB	FP4-All	ReaLB-m1	ReaLB-m2	ReaLB-seq	ReaLB
Kimi-VL	MMMU Δ Acc $\downarrow$	0.00	0.00	-4.22	-2.22	0.00	-1.22	-1.22
	Speedup $\uparrow$	1.00	0.91	1.34	1.32	1.29	1.25	1.32
	MathVista Δ Acc $\downarrow$	0.00	0.00	-2.00	-2.00	-1.10	-1.70	-1.70
	Speedup $\uparrow$	1.00	0.95	1.40	1.32	1.30	1.26	1.31
	DynaMath Δ Acc $\downarrow$	0.00	0.00	-8.19	-3.80	-2.50	-3.10	-3.10
	Speedup $\uparrow$	1.00	0.96	1.41	1.30	1.29	1.25	1.30
Qwen-VL	MMMU Δ Acc $\downarrow$	0.00	0.00	-2.44	-0.34	-0.34	-0.00	-0.00
	Speedup $\uparrow$	1.00	0.91	1.18	1.13	1.13	1.01	1.13
	MathVista Δ Acc $\downarrow$	0.00	0.00	-2.70	-1.60	-1.30	-0.40	-0.40
	Speedup $\uparrow$	1.00	0.83	1.16	1.14	1.13	1.01	1.13
	DynaMath Δ Acc $\downarrow$	0.00	0.00	-1.89	-1.59	-1.09	-0.39	-0.39
	Speedup $\uparrow$	1.00	0.84	1.12	1.10	1.10	1.02	1.10

表格证据: Table 2: Accuracy stability of ReaLB across additional multimodal benchmarks (). 实验结论 呼应:

第 8 节: ReaLB 平均精度损失<1% 在多个多模态基准上的稳定性

- 图组结论: Qwen-VL 上 ReaLB 平均精度损失<0.6%, 跨基准保持稳定低损失
- 论证关系: 补充验证模态感知降精度策略的精度稳健性, 支撑 C4 主张
- 适用范围: 具体聚合口径与重复次数文中未说明

Model	AI2D	InfoVQA	TextVQA	MMBench	AVG
Kimi-VL	-0.13	-0.38	-0.91	-0.00	-0.36
Qwen-VL	-1.23	-0.00	-0.53	-0.60	-0.59

表格证据: Table 4: Speedup of ReaLB in the prefill-only setting. 适用边界 呼应: 第 6 节: LB Gate 仅在计算受限、大

batch 场景生效的适用条件

- 图组结论: 报告 prefill-only 部署下 ReaLB 相对 Baseline 的加速比, 具体数值正文未展开引用
- 论证关系: 为"计算受限场景"适用条件提供 prefill-only 模式下的补充验证
- 适用范围: 未纳入正文 Table 1/2 主对比, 跨 EP 规模下是否成立未见验证

Model	MMMU	MathVista	DynaMath
Kimi-VL	1.35 \$ \times \$	1.33 \$ \times \$	1.34 \$ \times \$
Qwen-VL	1.12 \$ \times \$	1.12 \$ \times \$	1.10 \$ \times \$

10. 完整因果推理树

- 根问题: EP 下 MMoE 推理层延迟由最慢 rank 决定, 该 rank 身份在迭代间快速变化、难以预测 ()
 - 旧方法限制: 历史预测式方法 (EPLB/LPLB) 跟不上动态性; 专家迁移/复制类方法引入通信与内存开销 ()
 - 核心洞见/假设: 过载 rank 往往是视觉专家聚集的 rank, 视觉 token 冗余度更高、对精度下降更不敏感 ()
 - 方法模块: 模态感知精度分配 R_{vd}/M_d ()
 - 可验证预测: 只对视觉主导+过载 rank 降精度, 可在精度损失可控前提下降低其延迟
 - 指标与实验: ΔAcc 、Speedup、MoE 层延迟 (Table 1,)
 - 图表证据: Figure 5 延迟分解、附录跨 benchmark 图 ()
 - 结论与适用边界: Kimi-VL/Qwen-VL 上均验证有效 [实验支持] (), 但未覆盖"模态隔离"架构, 未做反向消融 (文中未说明)
 - 方法模块: 瞬时热点识别 IB_d ()
 - 可验证预测: 瞬时判定应比历史窗口更快命中真实热点
 - 指标与实验: Figure 2c 预测/观测对比、5.3 节 MoE 延迟 ()
 - 图表证据: Figure 2c、附录 Figure 6 ()
 - 结论与适用边界: 定性支持充分, 但"命中率"量化指标未被当前证据直接验证 (文中未说明)
 - 方法模块: 开销隐藏流水线 ()
 - 可验证预测: LB 开销可被通信窗口"淹没", 不随 EP 规模扩展
 - 指标与实验: ReaLB vs ReaLB-seq 速度差 ()
 - 图表证据: Figure 5 realb_overhead/overlapping 分段 ()
 - 结论与适用边界: 速度收益已验证 [实验支持]; 跨 EP 规模的可扩展性未被当前证据直接验证 (仅单一硬件配置)
 - 方法模块: AIMD 阈值控制 ()
 - 可验证预测: 自适应阈值应比固定阈值更稳定
 - 指标与实验: ReaLB vs ReaLB-m1/m2 (Table 1,)
 - 图表证据: 附录 AIMD 轨迹图 ()
 - 结论与适用边界: 稳定性优势已验证 [实验支持]; M_d 详细收敛行为在 Appendix H 未被当前证据直接验证
 - 方法模块: LB Gate ()
 - 可验证预测: 仅在计算受限 (大 batch) 场景启用才有收益
 - 指标与实验: Figure 4 定性趋势 ()
 - 图表证据: Figure 4 GEMM 占比堆叠图
 - 结论与适用边界: 定性支持存在; 开关 Gate 前后的量化效果未被当前证据直接验证 (文中未说明)

11. 结论、贡献与边界

贡献: 识别并量化 MMoE 推理中模态驱动的动态负载不均衡 [作者明确陈述]; 提出模态感知、精度自适应的 ReaLB 调度机制配合 AIMD 控制; 设计开销感知流水线编排隐藏转换延迟; 在 vLLM 中实现并在两个 MMoE 模型上验证性能提升 ()。

证据充分的结论: EPLB 在动态路由下确实表现为速度不稳定甚至负收益 [实验支持] (); ReaLB 相对 FP4-All 精度损失显著更低、吞吐相近 [实验支持] (); 流水线重叠对速度收益有实测贡献 [实验支持] ()。

尚属推断的意义: 瞬时判定"天然"优于历史预测的机制解释是逻辑推断而非直接量化验证 (缺少命中率指标) [基于文中逻辑的推断]; LB 开销的可扩展性论证为理论推导, 未经跨 EP 规模实测 [基于文中逻辑的推断]。

适用条件: 需要 GEMM 主导延迟的大 batch 计算受限场景 ($\Gamma = 2048$); 需模态融合 (modality-fused) 架构而非模态隔离架构 [作者明确陈述] ()。

局限: 硬件规模单一 ($8 \times \text{RTX5090}$); 消融未完全分离模态选择与精度切换各自贡献; 关键指标 (ΔAcc 、Speedup) 缺显式公式; 命名不一致 (ReaLB-mi vs ReaLB-m1/m2) 未获澄清。

审稿式风险检查:

- 贡献新意: 核心创新 (精度自适应替代路由/放置优化) 有清晰的问题-洞见对应链, 当前证据未显示明显新意风险。
- 写作/可复现性: 命名不一致 (ReaLB-mi/ReaLB-m1/m2) 及关键指标无显式公式, 存在可复现性风险 [作者明确陈述] ()。
- 效果大小: 加速幅度 ($1.10 \times - 1.32 \times$) 在不同模型间差异较大 (Kimi-VL 高于 Qwen-VL), 当前证据未充分说明该差异原因。
- 实验覆盖: 单一硬件规模、缺少反向消融 (仅对文本主导 rank 降精度)、部分基线 (FasterMoE、LPLB) 未纳入实测对比, 是实验覆盖的真实缺口。
- 方法设计: LB Gate 阈值 Γ 、AIMD 参数 ($\tau = 1.5$ 、增减系数) 均为经验设定, 当前证据未显示这些超参数的敏感性分析覆盖不足以外的额外风险。

12. 术语与第一性原理学习路径

12.1 核心术语

- **术语:** MoE (Mixture-of-Experts, 混合专家) —— 一种神经网络层设计, 将前馈网络替换为多个"小专家", 每个 token 只经过其中少数专家计算。
 - **第一性原理角色:** 连接"模型容量"与"计算量"两个基本量——通过稀疏激活在扩大参数规模的同时控制单 token 计算成本。
 - **本文位置:** 整个负载不均衡问题的根源结构 ()。
- **术语:** EP (Expert Parallelism, 专家并行) —— 把不同专家分布到不同 GPU 上运行的并行策略。
 - **第一性原理角色:** 受"跨设备通信带宽"约束; 决定了负载不均衡如何转化为跨设备执行时间差异。
 - **本文位置:** 负载均衡问题发生的物理载体 ()。
- **术语:** IB_d (设备级负载不均衡度) —— 某设备负载与平均负载之比。
 - **第一性原理角色:** 连接"瞬时负载状态"与"是否过载"这一判定动作的基本量。
 - **本文位置:** 热点识别模块的核心输入 ()。
- **术语:** R_{vd} (视觉 token 占比) —— 某设备上视觉 token 数占该设备总 token 数的比例。
 - **第一性原理角色:** 连接"输入模态构成"与"是否可安全降精度"的判据。
 - **本文位置:** 模态感知精度分配的判定变量 ()。
- **术语:** FP4/NVFP4 (4-bit 浮点低精度计算) —— 用更少比特表示数字以加速矩阵乘法, 可能损失精度。
 - **第一性原理角色:** 受"数值表示精度 vs 计算吞吐"这一物理/硬件约束的权衡。
 - **本文位置:** ReaLB 对视觉主导过载 rank 的执行方式 ()。
- **术语:** AIMD (加性增乘性减) —— 网络拥塞控制思想: 通畅时缓慢增加、拥塞时大幅降低。
 - **第一性原理角色:** 连接"瞬时拥塞信号"与"控制变量调整幅度"的反馈机制。
 - **本文位置:** M_d 阈值的自适应更新规则 ()。
- **术语:** dispatch (all-to-all 通信阶段) —— EP 下各设备把 token 发送到对应专家所在设备的通信过程。
 - **第一性原理角色:** 受设备间通信带宽/延迟约束; 是本文用于"隐藏"精度转换开销的时间窗口。
 - **本文位置:** 开销隐藏流水线编排的关键位置 ()。
- **术语:** LB Gate (负载均衡开关, 全局阈值 Γ) —— 仅在聚合负载超过阈值时启用均衡机制。
 - **第一性原理角色:** 连接"计算是否受限于 GEMM"与"是否值得付出 LB 开销"的判据。
 - **本文位置:** 控制 ReaLB 在何种 batch 规模下生效 ()。

12.2 学习路径

1. MoE 的基本对象是"专家网络+路由门控", 理解它是后续一切负载问题的起点 (好比理解"分诊制医院"才能理解"某科室排队"问题)。
2. EP 的约束是"跨设备通信带宽有限、每设备专家固定", 理解这一物理约束才能理解为何"最慢设备决定整层延迟"。
3. 推理阶段路由动态性 (强于训练阶段) 是理解"为什么历史预测方法失效"的机制前提。
4. 低精度计算 (FP4) 的"速度-精度权衡"是理解 ReaLB"降精度换速度"这一设计选择合理性的基础。

5. AIMD 拥塞控制思想是理解 M_d 阈值如何在瞬时信号驱动下自动调节的最后一环，直接连接到本文的可观测指标 (Speedup、 ΔAcc) 与结论边界。