

论文解构报告

ReaLB: Real-Time Load Balancing for Multi-modal MoE Inference

Yingping Wang, Yi Wu, Xiangyu Wu, Junwei Cui, Weilin Cai, Zhijiang Guo, Jiayi Huang

Mixture-of-Experts

多模态推理

专家并行

负载均衡

低精度计算

目录

摘要翻译	3
1. 一句话总览	3
2. 阅读范围与证据状态	3
3. 根问题：论文究竟要解决什么	3
4. 旧方法为何不够	4
5. 核心洞见与假设	5
6. 方法：从洞见到可执行系统	5
7. 为什么它可能有效	6
8. 实验与指标：证据是否支撑主张	6
9. 图表解读与论证关系	8
10. 完整因果推理树	10
11. 结论、贡献与边界	11
12. 术语与第一性原理学习路径	11

摘要翻译

混合专家（MoE）架构广泛应用于现代大语言模型和多模态模型中。然而，推理效率常常受到跨不同模态高度动态且倾斜的专家负载的限制。在大批量的预填充（prefill）阶段，视觉 token 往往主导输入序列。在专家并行（EP）下，这会导致严重的负载不均衡，部分设备过载，从而降低系统整体吞吐量。我们提出了 ReaLB，一种面向多模态 MoE（MMoE）推理的实时负载均衡方法，具有零调度开销。ReaLB 在运行时以每个 EP rank 为粒度动态调整 MoE 专家的计算精度：对于由视觉密集型专家主导的 rank，ReaLB 分配更低精度的计算，利用 FP4 Tensor Core 提升执行效率。ReaLB 不需要冗余专家，也不需要额外的显存分配，而是在运行过程中即时进行逐层的专家精度转换，并将相关开销隐藏在 MoE 计算之前的 dispatch 阶段中。在代表性 MMoE 模型上的实验表明，ReaLB 实现了 1.10 倍至 1.32 倍的端到端加速，同时将平均精度损失限制在 1% 以内。

1. 一句话总览

论文元数据

字段	内容
标题	ReaLB: Real-Time Load Balancing for Multimodal MoE Inference
作者	Yingping Wang, Yi Wu, Xiangyu Wu, Junwei Cui, Weilin Cai, Zhijiang Guo, Jiayi Huang
发表场所 / 年份	文中未说明
研究领域	系统, 机器学习
关键词	Mixture-of-Experts, 多模态推理, 专家并行, 负载均衡, 低精度计算

资源链接

- 原始文件：本地上传文件（无外部链接）
- arXiv：文中未说明
- DOI：文中未说明
- 代码 / 数据集：文中未说明

标签（5 个）：Mixture-of-Experts · 多模态推理 · 专家并行负载均衡 · FP4 低精度计算 · vLLM 推理系统

ReaLB 是一种运行时、模态感知的 MoE 负载均衡方法：它不迁移专家，而是在每次前向传播前根据瞬时负载与视觉 token 占比，对"过载且视觉专家主导"的 EP rank 动态切换为 FP4 低精度计算，并把转换开销隐藏在 dispatch 通信中，实现 $1.10\times-1.32\times$ 端到端加速、平均精度损失控制在 1% 以内 [作者明确陈述]。

2. 阅读范围与证据状态

OCR 覆盖正文第 1-9 页及附录第 16-19 页（Appendix F、G、H、I 部分内容），涵盖引言、动机分析（3.1/3.2 节）、方法设计（4.1-4.3 节）与主实验（5.1-5.3 节） [作者明确陈述]。

- 附录 Appendix H 中关于 M_d 演化的"详细实证分析"文字部分未被本 OCR 完整收录，仅有其对应图片（图片批次 5 图片 2） [作者明确陈述]。
- 多处关键指标（ ΔAcc 、Speedup）仅有文字定义、无显式计算公式，具体聚合口径未披露，标注为"文中未说明" [作者明确陈述]。
- 论文正文出现"ReaLB-mi"与"ReaLB-m1/ReaLB-m2"两套命名，OCR 未做主观统一，如实标注不一致，可能反映 OCR 抽取或版本差异 [基于文中逻辑的推断]。

3. 根问题：论文究竟要解决什么

在专家并行（EP，把不同专家分布到不同 GPU 上运行的并行策略）部署下，每个 GPU 通常固定托管一部分专家；一次 MoE 层前向计算的层延迟由所有 rank 中最慢的一个决定，即 $T_{MoE}(x) = \max_i T_i(x)$ ，这是一种"木桶效应"结构 [作者明确陈述]。多模态 MoE（MMoE）推理阶段，尤其是大 batch 的 prefill（一次性处理输入提示词的阶段）阶段，视觉 token 数量远多于文本 token，导致路由到不同专家/设备的 token 量高度倾斜，进而产生严重的设备间负载不均衡，拖慢整体吞吐 [作者明确陈述]。MoE 通过每个 token 仅激活少数专家实现参数高效扩展，广泛用于现代大模型与多模态模型；但这种稀疏激活+输入依赖路由天然导致负载不均衡，多模态场景下这一问题更严重，因此直接决定了系统实际可部署的吞吐上限 [作者明确陈述]。难点在于：该"最慢 rank"的身份在迭代间快速、不可预测地变化，使得依赖历史统计的静态或预测式方法从根本上失效 [实验支持]。

本文的 story：旧路线（无论训练期均衡损失，还是推理期的专家复制/迁移调度）失效的技术原因是"用历史统计去预测下一时刻的热点"，而推理阶段路由的时间局部性太弱，预测必然滞后；本文的核心转折是把问题从"路由/专家放置优化"转化为"计算精度自适应"——不追预测，只在当下"原地"降低已确认过载且可容忍精度损失的视觉专家的计算精度，从根本上避免了预测需求 [作者明确陈述]。




Figure 1: Motivation for real-time load balancing.

图组解读

- **图组结论**：Top-1 热点 Rank 在迭代间剧烈跳变，最慢设备动态变化。
- **论证关系**：直观展示 EP 掉队者由视觉专家聚集引起及路由高度动态性。
- **适用范围**：不提供量化对比，不能单独证明视觉主导过载的因果关系。

4. 旧方法为何不够

综合看，旧方法的核心技术限制可归纳为两条：(a) 依赖历史统计预测，无法适应推理路由的强瞬时波动；(b) 通过专家复制/迁移实现均衡，天然引入通信和显存开销 [基于文中逻辑的推断]（推理依据：训练期方法、EPLB、LPLB、FasterMoE 的批判中反复出现“预测滞后”与“额外开销”两类问题）。

训练期辅助损失/device-constrained routing

前提：原本解决什么：训练阶段调节门控提升专家利用率均衡；依赖前提：假设可在训练时调整梯度/路由目标。

本文指出的失效点

“不能直接用于推理”，未展开具体机制 [作者明确陈述]



本文对应模块

无对应设计模块（仅作背景问题设定）

检验：未被论文纳入实测对比，其批判停留在文字论证层面

FasterMoE 影子专家

前提：原本解决什么：复制过载专家到多设备均衡负载；依赖前提：需要额外显存与通信带宽。

本文指出的失效点

引入额外内存与通信开销 [作者明确陈述]



本文对应模块

ReaLB 原地精度切换，不复制专家

检验：未被论文纳入实测对比，其批判停留在文字论证层面

EPLB 历史式专家放置

前提：原本解决什么：用历史窗口统计周期性重放置专家；依赖前提：假设负载具有时间局部性。

本文指出的失效点

预测滞后、通信开销 $K \cdot Bytes_{expert}$ 、显存开销线性增长 [作者明确陈述]



本文对应模块

瞬时状态判定 IB_d 取代历史预测

检验：Table 1/5.3 节量化对比支持 [实验支持]

LPLB

前提：原本解决什么：用线性规划更均匀重分配 token 流量；依赖前提：需高频调用逼近实时性。

本文指出的失效点

高频调用的调度开销可能超过均衡收益 [作者明确陈述]



本文对应模块

LB Gate + 通信重叠的开销感知设计

通信侧重叠/核融合

前提：原本解决什么：降低 all-to-all 通信成本；依赖前提：假设计算已经均衡。

本文指出的失效点

无法解决计算本身不均衡 [作者明确陈述]



本文对应模块

借用既有通信窗口隐藏精度转换开销

检验：未被论文纳入实测对比，其批判停留在文字论证层面

5. 核心洞见与假设

核心洞见/贡献：EP 的 straggler (掉队者，即拖慢整体的最慢设备) 主要由聚集了视觉专家的 rank 造成；视觉 token 相较文本 token 在前向传播中表现出更高冗余性 (引用支持 [3,38]) [作者明确陈述]。由此推出的核心假设：**将"视觉主导且过载"的 rank 切换为低精度计算，可在几乎不损失文本相关精度的前提下降低该 rank 延迟，从而消除设备间执行时间不均衡** [作者明确陈述]。

支撑该洞见的观察 (实现所需前提)：

- 观察 1 (模态驱动的负载倾斜)：某 rank 视觉 token 占比可超 90%，另一些低于 50%；专家级占比范围 31%–93% [实验支持] (Kimi-VL/MMMU/8GPU)。
- 观察 2 (不可预测的高动态性)：同一短窗口内热点专家负载/均值比可从约 $2\times$ 变到 $12\times$ ，时间局部性远弱于训练阶段 [实验支持]。

理论支撑：论文将均衡问题形式化为在线策略优化目标

$$\max_{\pi} \mathbb{E}_x \left[\max_i T_i(x) - \max_i T_i(\pi(x)) - T_{LB}(\pi, x) \right]$$

并论证：优化"token/专家均衡"这类代理指标并非最小化

$$\max_i T_i$$

的必要条件；推理阶段不需要为优化稳定性维持 token 均衡，只需直接最小化执行延迟 [作者明确陈述]。这为"不追求专家/token 完全均衡，只直接压低设备级延迟"的设计选择提供了理论依据。

前提可能失效的场景：若视觉 token 的冗余性假设不成立 (即视觉专家对精度同样敏感)，或负载倾斜并非以模态为主因，该核心假设的适用性会被削弱；论文未提供该前提的反向消融，属于证据缺口 (见 4.2 节相关说明)。

6. 方法：从洞见到可执行系统

总览：输入为当前层各设备的负载与模态构成 → 判定过载设备 → 在过载设备中筛出"视觉主导"者 → 对这些设备的专家在线转换为 FP4 精度并执行计算 → 转换开销与元数据收集被安排在 dispatch 通信窗口内隐藏 → 输出经均衡后的 MoE 层结果，供后续 Combine/下一层使用 [作者明确陈述]。

1. 运行时状态与热点识别 (IB_d , 阈值 C)

- 动机：需要不依赖历史统计、纯瞬时的"是否过载"判定 [作者明确陈述]。
- 输入/过程/输出：输入当前层各设备 token 负载 $Load_d$ 与平均负载 $Ideal$ ；计算 $IB_d = Load_d / Ideal$ ；输出热点集合 $\mathcal{H} = \{d \mid IB_d > C\}$ ， $C = 1$ 表示完全均衡 [作者明确陈述]。
- 优势：仅用当前层瞬时数据，规避历史预测滞后问题 [基于文中逻辑的推断]。

2. 模态感知精度分配 (R_{vd} , M_d)

- 动机：区分"视觉主导可压缩"与"文本主导不可压缩"的过载设备 [作者明确陈述]。
- 输入/过程/输出：输入设备上视觉/文本 token 数 N_{vd}, N_{td} ；计算 $R_{vd} = N_{vd} / (N_{vd} + N_{td})$ ；对 $d \in \mathcal{H}$ 且 $R_{vd} > M_d$ 的设备标记为可压缩，其专家用低精度 GEMM 执行，其余保持标准精度 [作者明确陈述]。
- 优势：把降精度限定在对损失不敏感的视觉专家上 [作者明确陈述]。

3. AIMD 自适应阈值控制

- 动机：固定阈值难以兼顾响应速度与稳定性 [作者明确陈述]。
- 规则： $IB_{global} = \max_d IB_d$ ，拥塞阈值 $\tau = 1.5$ ；若 $IB_{global} > \tau$ 则 $M_d = 0.5M_d$ ，否则 $M_d = \min(1, M_d + 0.1)$ [作者明确陈述]。
- 优势：借鉴网络拥塞控制思想，拥塞时快速收紧、平稳期逐渐放松 [作者明确陈述]。

4. 在线精度转换

- 动机：不增加显存占用的前提下支持实时精度切换 [作者明确陈述]。
- 过程：每个专家仅存原始高精度权重+预计算缩放因子；调度下发新精度配置时在线量化到目标精度 [作者明确陈述]。

5. 开销隐藏的流水线编排


- 动机：元数据收集 S 与精度转换 T 本身引入额外计算，需从关键路径移除 [作者明确陈述]。
- 过程： S 、 T 与 dispatch 阶段的设备间通信重叠执行 [作者明确陈述]。

- 优势：LB 开销只涉及本地转换和轻量元数据收集，不随 EP 规模扩展，而 dispatch 延迟随 EP 规模增长，因此重叠后 LB 开销被通信"淹没" [作者明确陈述]。


6. LB Gate (全局 batch 阈值 Γ)

- 动机：只有 GEMM 计算主导延迟时，设备负载不均衡才直接转化为延迟不均衡；小 batch 时启用 LB 无意义甚至有害 [作者明确陈述]。
- 过程：聚合设备负载超过 $\Gamma = 2048$ (256×8) 时启用 LB，否则退回标准执行 [作者明确陈述]。

前排论文大图 方法流水线 呼应：第 6 节：方法：从洞见到可执行系统



Panel 1



Panel 2

Figure 3: ReaLB design for efficient multimodal MoE inference. It combines modality-aware scheduling and an overlapping execution pipeline to mitigate device-level latency imbalance while minimizing runtime overhead.

图组解读

- **图组结论：**过载且视觉主导的 Rank 转为 FP4，文本主导受保护。
- **论证关系：**实例化模态感知精度分配与开销隐藏重叠流水线设计。
- **适用范围：**示意图未包含真实加速与精度数据，不能证明效果幅度。

7. 为什么它可能有效

- 瞬时状态判定 (IB_d) 只依赖当前层数据，逻辑上避免了历史统计对时间局部性的假设，因而能应对 3.2 节实证的强瞬时波动 [基于文中逻辑的推断]。
- 将降精度限定于"视觉主导+过载"设备，理论上兼顾速度与精度，前提是视觉 token 冗余性假设成立（背景知识支持，非本文直接实验验证的前提本身） [背景知识]。
- 流水线重叠使 LB 开销不随 EP 规模线性增长，理论上具有可扩展性，但该扩展性论证仅为理论推演，未在不同 EP 规模下实测验证 [基于文中逻辑的推断]。
- AIMD 通过瞬时拥塞信号（而非历史窗口）调节阈值，预期能在拥塞与稳定之间取得比固定阈值更好的平衡 [作者明确陈述]。

8. 实验与指标：证据是否支撑主张

8.1 实验问题与判定标准

- 效果问题：ReaLB 相对 Baseline/EPLB/FP4-All 的端到端速度与精度损失如何？→ 对应 Table 1/2 [实验支持]。
- 机制/必要性问题：预测式方法是否确实因动态性而失效？模态感知与流水线重叠是否各自必要？→ 对应 5.3 节延迟分解、ReaLB-seq/ReaLB-m1/m2 消融 [实验支持]。
- 鲁棒性问题：方法是否跨模型（Kimi-VL、Qwen3-VL）泛化？→ 对应两模型对比结果 [实验支持]。
- 适用范围问题：方法是否仅在计算受限（大 batch）场景有效？→ 对应 LB Gate 部分，但缺乏量化消融 [作者明确陈述]。

8.2 数据、任务、对比与运行设置

- 硬件：8×NVIDIA RTX 5090，DP+EP 混合并行 [作者明确陈述]。
- 框架：vLLM v0.13.0，混合精度来自 LLM Compressor，NVFP4 GEMM kernel 来自 FlashInfer [作者明确陈述]。
- 模型：Kimi-VL-A3B-Instruct（64 路由专家）、Qwen3-VL-30B-A3B-Instruct（128 路由专家），均做 NVFP4 PTQ [作者明确陈述]。
- 任务/benchmark：MMM U、MathVista、DynaMath [作者明确陈述]。
- 部署：Prefill-Decode colocated，continuous batching [作者明确陈述]。
- 超参数：容量因子 $C = 1$ ， M_d 初始 0.9， $\Gamma = 2048$ [作者明确陈述]。
- 对比方法：Baseline (W16A16)、FP4-All (全 W4A4)、EPLB、Async_EPLB、ReaLB、ReaLB-seq、ReaLB-m1/m2 [作者明确陈述]。

· 重复次数/统计方式：文中未说明（Panel2/5 给出均值±标准差，但未说明重复运行次数或统计口径）。

8.3 指标字典与对应公式

- **指标与方向**：Speedup（端到端速度提升），无符号标注，比值形式，越大越好。
 - ▶ **定义与公式**：作者文字定义为"相对 BF16 baseline 的端到端吞吐速度提升"；**来源层级：无可核验公式**——正文未给出显式计算式或聚合口径。
 - ▶ **实验用途**：回答效果问题，比较 ReaLB 与 Baseline/EPLB/FP4-All。
 - ▶ **读数与边界**：区间 $1.10\times-1.32\times$ ；不能证明该提升在不同 EP 规模、硬件平台下同样成立（仅 $8\times RTX5090$ 单一配置）。
- **指标与方向**： ΔAcc （精度下降），单位百分点，越小越好。
 - ▶ **定义与公式**：作者文字定义"相对 BF16 baseline 的准确率下降"；**来源层级：无可核验公式**——未给出分子分母或跨 benchmark 聚合方式。
 - ▶ **实验用途**：检验模态感知降精度是否比全模型降精度（FP4-All）更保守。
 - ▶ **读数与边界**：如 Kimi-VL/DynaMath, FP4-All -8.19% , ReaLB -3.10% [实验支持]；Qwen-VL 上 ReaLB 平均 $<0.6\%$ ；"平均精度损失 $<1\%$ "的跨 benchmark 聚合方法文中未说明。
- **指标与方向**：吞吐（tokens/sec），越大越好。
 - ▶ **定义与公式**：作者明示测量方法——CUDA 事件细粒度计时+vLLM benchmark 测端到端吞吐，单位为"处理 token 数/秒（输入+输出）"，属"作者文字定义"的测量方法而非公式。
 - ▶ **实验用途**：作为 Speedup 的底层测量依据。
 - ▶ **读数与边界**：具体吞吐绝对数值未在本 OCR 文字中给出，仅有换算后的 Speedup 倍数。
- **指标与方向**：MoE 层延迟，单位 ms，越小越好。
 - ▶ **定义与公式**：作者说明其用途为"捕捉逐层执行效率"，基于 CUDA 事件测量，无显式公式；**来源层级：无可核验公式**。
 - ▶ **实验用途**：检验 EPLB 是否因预测失配"加剧"而非缓解不均衡。
 - ▶ **读数与边界**：Kimi-VL 上 ReaLB 从 $1.51ms\rightarrow 1.36ms$, EPLB 反而从 $1.51ms\rightarrow 2.15ms$ [实验支持]；Qwen-VL 上 $1.48ms\rightarrow 1.39ms$ (ReaLB)、 $\rightarrow 1.99ms$ (EPLB)，为图像补充数值 [图像直接可见]。
- **指标与方向**： IB_d （设备级负载不均衡度），无量纲比值，越接近 1 越均衡。
 - ▶ **定义与公式**： $IB_d = Load_d / Ideal$ ，**来源层级：原文公式**。
 - ▶ **实验用途**：作为热点识别的判定输入，也是图 6/7 类附录证据的纵轴定义。
 - ▶ **读数与边界**：附录图显示跨 10 个 MoE 层普遍在 1.0–2.0 波动、间歇达 2.5–4.0 [图像直接可见]；仅是聚合比值，不揭示具体是哪个 rank/专家持续热点。

8.4 主结果、消融与证据边界 比较工作与被批判限制的呼应

比较工作/基线	核心限制或失效条件	本文对应模块	直接实验与仍未验证的边界
EPLB	历史窗口预测滞后于路由动态性；再平衡带来通信/显存开销 [作者明确陈述]	瞬时 IB_d 判定 + 原地降精度 (4.2 节)	Table 1/2、5.3 节延迟分解直接验证（EPLB speedup 多次 <1.00 , MoE 延迟升至 2.15ms） [实验支持]；未验证不同 EP 规模下 EPLB 通信/显存开销的量化对比
FP4-All	均匀低精度对多模态负载过于激进，精度损失显著 [作者明确陈述]	模态感知选择性降精度（4.2 节）	Table 1 直接对比 ΔAcc /Speedup [实验支持]；缺少"仅对文本主导 rank 降精度"的反向消融
FasterMoE、LPLB、通信侧重叠方法	分别为显存/通信开销、高频调度开销、无法解决计算不均衡 [作者明确陈述]	无专家复制、开销感知设计、借用通信窗口	论文未将三者纳入实测对比表，无法从当前 OCR 内容确认量化差距

主张与证据

主张	直接证据（实验/表图）	证据强度与边界
C1：端到端 $1.10\times-1.32\times$ 加速、精度损失 $<1\%$	Table 1 逐 benchmark 数值 [实验支持]	覆盖较完整,但" $<1\%$ "的跨 benchmark 平均口径文中未说明
C3：EPLB 无法适应推理路由动态性	Figure 2c 预测/观测分离、5.3 节 MoE 延迟对比 [实验支持]	缺少"预测命中率"量化指标，仅有定性+间接速度证据
C4：模态感知优于均匀降精度	Table 1 ReaLB vs FP4-All 的 ΔAcc /Speedup [实验支持]	缺少反向消融，无法完全分离"模态选择"与"降精度比例"各自贡献
C5：流水线重叠隐藏开销	ReaLB vs ReaLB-seq 对比，及附录 Appendix I 跨 benchmark 复现 [实验支持]	缺少 S+T 绝对开销时间的直接测量
C9：仅计算受限场景有效	LB Gate 定性说明+ $\Gamma=2048$	Gate 开关的量化消融数字文中未说明

- 消融显示 AIMD 自适应控制比固定阈值 (ReaLB-m1/m2) 更稳定 [实验支持], 但 M_d 演化的详细文字分析在 Appendix H 未被本 OCR 完整收录。
- Rank 级别最高提速 $1.29\times$ (Kimi-VL)、附录图片显示 Qwen-VL 某 rank 达 $1.62\times$ (该数值未被正文引用) [实验支持]。
- 所有实验均在单一 $8\times\text{RTX5090}$ 集群上完成, 未见跨 EP 规模或跨硬件平台验证 [基于文中逻辑的推断]。

9. 图表解读与论证关系




Figure 2: High dynamics in MMoE routing limit the effectiveness of prediction-based methods. (a) Load imbalance across devices, experts, and modalities. (b) Temporal variation in imbalance severity across iterations. (c) Rapid shifts of the top-1 hot device and expert, highlighting the mismatch between historical observations and current load.

图组解读 **实验结论** 呼应: 第 8 节: 实验与指标: 证据是否支撑主张

- **图组结论:** 负载动态剧烈, 预测线与实际线严重偏离。
- **论证关系:** 直观证明 EPLB 历史预测失配, 支撑动态路由限制批判。
- **适用范围:** 仅覆盖单模型单任务, 未量化预测命中率与通信开销。




Figure 4: ReaLB is enabled only in the compute-bound regime with large batch sizes.

图组解读 **适用边界** 呼应: 第 6 节: 方法: 从洞见到可执行系统

- **图组结论:** 随 token 增加 GEMM 成为主要耗时瓶颈。
- **论证关系:** 为 LB Gate 仅在大 batch 计算受限场景启用提供依据。
- **适用范围:** 缺乏开关 LB Gate 的前后量化对比数据。




Figure 5: Fine-grained MoE latency analysis. Top row (a-c): Kimi-VL; bottom row (d-f): Qwen-VL.

图组解读 **消融验证** 呼应: 第 8 节: 实验与指标: 证据是否支撑主张

- **图组结论:** ReaLB 显著降低 MoE 延迟, EPLB 反而增加延迟。
- **论证关系:** 验证流水线重叠收益及 EPLB 预测失配适得其反机制。
- **适用范围:** 单数据集测得, 跨数据集泛化见附录实验。




Figure 6: Dynamics of device-level load imbalance across MoE layers 12-21.

图组解读 **实验结论** 呼应：第 5 节：核心洞见与假设

- **图组结论**：设备级负载不均衡度在跨层跨迭代中持续剧烈波动。
- **论证关系**：证明多层路由动态性，支撑逐层瞬时判定设计必要性。
- **适用范围**：展示聚合比值，未揭示具体热点专家分布。



Figure 7: Overloaded devices and experts across iterations for layer 12-19, with token proportions for different modalities.

图组解读 **实验结论** 呼应：第 5 节：核心洞见与假设

- **图组结论**：过载设备和专家普遍呈现显著的视觉 token 主导特征。
- **论证关系**：实测证明过载与视觉主导强相关，支撑模态感知假设。
- **适用范围**：受限于特定测试窗口，具体配置需正文补充说明。




Figure 8: Token composition in continuous batching.

图组解读 **适用边界** 呼应：第 8 节：实验与指标：证据是否支撑主张

- **图组结论**：连续批处理中 prefill 视觉 token 占绝对主导地位。
- **论证关系**：支持将部署环境简化为近似 prefill 场景的方法假设。
- **适用范围**：具体模型与任务未在图题明确标注。




Figure 10: End-to-end latency breakdown on additional benchmarks.

图组解读 **实验结论** 呼应：第 8 节：实验与指标：证据是否支撑主张

- **图组结论**: ReaLB 在多数数据集上均实现端到端加速, EPLB 普遍拖慢。
- **论证关系**: 证明主张 C1 与 C5 具有跨 benchmark 与跨模型泛化性。
- **适用范围**: 未标注分段绝对耗时, 无法定量化隐藏开销。




Figure 9: Evolution of the control parameter under AIMD-based adaptive control on DynaMath. The red background indicates time steps where the global imbalance exceeds the congestion threshold.

图组解读 **消融验证** 呼应：第 6 节：方法：从洞见到可执行系统

- **图组结论**: 控制参数在拥塞时快速降低、非拥塞时逐步回升。
- **论证关系**: 可视化 AIMD 控制机制在瞬时拥塞信号下的动态响应。
- **适用范围**: 未包含静态阈值对照曲线, 优越性需结合表格数据。

10. 完整因果推理树

- 根问题: EP 下 MMoE 推理层延迟由最慢 rank 决定, 该 rank 身份在迭代间快速变化、难以预测
 - 旧方法限制: 历史预测式方法 (EPLB/LPLB) 跟不上动态性; 专家迁移/复制类方法引入通信与内存开销
 - 核心洞见/假设: 过载 rank 往往是视觉专家聚集的 rank, 视觉 token 冗余度更高、对精度下降更不敏感
 - 方法模块: 模态感知精度分配 R_{vd}/M_d
 - 可验证预测: 只对视觉主导+过载 rank 降精度, 可在精度损失可控前提下降低其延迟
 - 指标与实验: ΔAcc 、Speedup、MoE 层延迟 (Table 1)
 - 图表证据: Figure 5 延迟分解、附录跨 benchmark 图
 - 结论与适用边界: Kimi-VL/Qwen-VL 上均验证有效 [实验支持], 但未覆盖"模态隔离"架构, 未做反向消融 (文中未说明)
 - 方法模块: 瞬时热点识别 IB_d
 - 可验证预测: 瞬时判定应比历史窗口更快命中真实热点
 - 指标与实验: Figure 2c 预测/观测对比、5.3 节 MoE 延迟
 - 图表证据: Figure 2c、附录 Figure 6
 - 结论与适用边界: 定性支持充分, 但"命中率"量化指标未被当前证据直接验证 (文中未说明)
 - 方法模块: 开销隐藏流水线
 - 可验证预测: LB 开销可被通信窗口"淹没", 不随 EP 规模扩展
 - 指标与实验: ReaLB vs ReaLB-seq 速度差
 - 图表证据: Figure 5 realb_overhead/overlapping 分段
 - 结论与适用边界: 速度收益已验证 [实验支持]; 跨 EP 规模的可扩展性未被当前证据直接验证 (仅单一硬件配置)
 - 方法模块: AIMD 阈值控制
 - 可验证预测: 自适应阈值应比固定阈值更稳定
 - 指标与实验: ReaLB vs ReaLB-m1/m2 (Table 1)
 - 图表证据: 附录 AIMD 轨迹图

- 结论与适用边界：稳定性优势已验证 [实验支持]； M_d 详细收敛行为在 Appendix H 未被当前证据直接验证
- 方法模块：LB Gate
 - 可验证预测：仅在计算受限（大 batch）场景启用才有收益
 - 指标与实验：Figure 4 定性趋势
 - 图表证据：Figure 4 GEMM 占比堆叠图
 - 结论与适用边界：定性支持存在；开关 Gate 前后的量化效果未被当前证据直接验证（文中未说明）

11. 结论、贡献与边界

贡献：识别并量化 MMoE 推理中模态驱动的动态负载不均衡 [作者明确陈述]；提出模态感知、精度自适应的 ReaLB 调度机制配合 AIMD 控制；设计开销感知流水线编排隐藏转换延迟；在 vLLM 中实现并在两个 MMoE 模型上验证性能提升。

证据充分的结论：EPLB 在动态路由下确实表现为速度不稳定甚至负收益 [实验支持]；ReaLB 相对 FP4-All 精度损失显著更低、吞吐相近 [实验支持]；流水线重叠对速度收益有实测贡献 [实验支持]。

尚属推断的意义：瞬时判定“天然”优于历史预测的机制解释是逻辑推断而非直接量化验证（缺少命中率指标）[基于文中逻辑的推断]；LB 开销的可扩展性论证为理论推导，未经跨 EP 规模实测 [基于文中逻辑的推断]。

适用条件：需要 GEMM 主导延迟的大 batch 计算受限场景（ $\Gamma = 2048$ ）；需模态融合（modality-fused）架构而非模态隔离架构 [作者明确陈述]。

局限：硬件规模单一（ $8 \times \text{RTX5090}$ ）；消融未完全分离模态选择与精度切换各自贡献；关键指标（ ΔAcc 、Speedup）缺显式公式；命名不一致（ReaLB-mi vs ReaLB-m1/m2）未获澄清。

审稿式风险检查：

- 贡献新意：核心创新（精度自适应替代路由/放置优化）有清晰的问题-洞见对应链，当前证据未显示明显新意风险。
- 写作/可复现性：命名不一致（ReaLB-mi/ReaLB-m1/m2）及关键指标无显式公式，存在可复现性风险 [作者明确陈述]。
- 效果大小：加速幅度（ $1.10 \times - 1.32 \times$ ）在不同模型间差异较大（Kimi-VL 高于 Qwen-VL），当前证据未充分说明该差异原因。
- 实验覆盖：单一硬件规模、缺少反向消融（仅对文本主导 rank 降精度）、部分基线（FasterMoE、LPLB）未纳入实测对比，是实验覆盖的真实缺口。
- 方法设计：LB Gate 阈值 Γ 、AIMD 参数（ $\tau = 1.5$ 、增减系数）均为经验设定，当前证据未显示这些超参数的敏感性分析覆盖不足以外的额外风险。

12. 术语与第一性原理学习路径

12.1 核心术语

- **术语：**MoE（Mixture-of-Experts，混合专家）——一种神经网络层设计，将前馈网络替换为多个“小专家”，每个 token 只经过其中少数专家计算。
 - **第一性原理角色：**连接“模型容量”与“计算量”两个基本量——通过稀疏激活在扩大参数规模的同时控制单 token 计算成本。
 - **本文位置：**整个负载不均衡问题的根源结构。
- **术语：**EP（Expert Parallelism，专家并行）——把不同专家分布到不同 GPU 上运行的并行策略。
 - **第一性原理角色：**受“跨设备通信带宽”约束；决定了负载不均衡如何转化为跨设备执行时间差异。
 - **本文位置：**负载均衡问题发生的物理载体。
- **术语：** IB_d （设备级负载不均衡度）——某设备负载与平均负载之比。
 - **第一性原理角色：**连接“瞬时负载状态”与“是否过载”这一判定动作的基本量。
 - **本文位置：**热点识别模块的核心输入。
- **术语：** R_{vd} （视觉 token 占比）——某设备上视觉 token 数占该设备总 token 数的比例。
 - **第一性原理角色：**连接“输入模态构成”与“是否可安全降精度”的判据。
 - **本文位置：**模态感知精度分配的判定变量。
- **术语：**FP4/NVFP4（4-bit 浮点低精度计算）——用更少比特表示数字以加速矩阵乘法，可能损失精度。
 - **第一性原理角色：**受“数值表示精度 vs 计算吞吐”这一物理/硬件约束的权衡。
 - **本文位置：**ReaLB 对视觉主导过载 rank 的执行方式。
- **术语：**AIMD（加性增乘性减）——网络拥塞控制思想：通畅时缓慢增加、拥塞时大幅降低。
 - **第一性原理角色：**连接“瞬时拥塞信号”与“控制变量调整幅度”的反馈机制。
 - **本文位置：** M_d 阈值的自适应更新规则。
- **术语：**dispatch（all-to-all 通信阶段）——EP 下各设备把 token 发送到对应专家所在设备的通信过程。
 - **第一性原理角色：**受设备间通信带宽/延迟约束；是本文用于“隐藏”精度转换开销的时间窗口。
 - **本文位置：**开销隐藏流水线编排的关键位置。

- **术语**: LB Gate (负载均衡开关, 全局阈值 Γ) —— 仅在聚合负载超过阈值时启用均衡机制。
 - **第一性原理角色**: 连接"计算是否受限于 GEMM"与"是否值得付出 LB 开销"的判据。
 - **本文位置**: 控制 ReaLB 在何种 batch 规模下生效。

12.2 学习路径

1. MoE 的基本对象是"专家网络+路由门控", 理解它是后续一切负载问题的起点 (好比理解"分诊制医院"才能理解"某科室排队"问题)。
2. EP 的约束是"跨设备通信带宽有限、每设备专家固定", 理解这一物理约束才能理解为何"最慢设备决定整层延迟"。
3. 推理阶段路由动态性 (强于训练阶段) 是理解"为什么历史预测方法失效"的机制前提。
4. 低精度计算 (FP4) 的"速度-精度权衡"是理解 ReaLB"降精度换速度"这一设计选择合理性的基础。
5. AIMD 拥塞控制思想是理解 M_d 阈值如何在瞬时信号驱动下自动调节的最后一环, 直接连接到本文的可观测指标 (Speedup、 ΔAcc) 与结论边界。