

论文解构报告

ReaLB: Real-Time Load Balancing for Multi-modal MoE Inference

Yingping Wang, Yi Wu, Xiangyu Wu, Junwei Cui, Weilin Cai, Zhijiang Guo, Jiayi Huang

Mixture-of-Experts

多模态推理

专家并行

负载均衡

低精度计算

目录

摘要翻译	3
1. 一句话总览	3
2. 阅读范围与证据状态	3
3. 根问题：论文究竟要解决什么	3
4. 旧方法为何不够	5
5. 核心洞见与假设	6
6. 方法：从洞见到可执行系统	6
7. 为什么它可能有效	7
8. 实验与指标：证据是否支撑主张	8
9. 图表解读与论证关系	9
10. 完整因果推理树	12
11. 结论、贡献与边界	12
12. 术语与第一性原理学习路径	13

摘要翻译

混合专家（MoE）架构广泛应用于现代大语言模型和多模态模型中。然而，推理效率常常受到跨不同模态高度动态且倾斜的专家负载的限制。在大批量的预填充（prefill）阶段，视觉 token 往往主导输入序列。在专家并行（EP）下，这会导致严重的负载不均衡，部分设备过载，从而降低系统整体吞吐量。我们提出了 ReaLB，一种面向多模态 MoE（MMoE）推理的实时负载均衡方法，具有零调度开销。ReaLB 在运行时以每个 EP rank 为粒度动态调整 MoE 专家的计算精度：对于由视觉密集型专家主导的 rank，ReaLB 分配更低精度的计算，利用 FP4 Tensor Core 提升执行效率。ReaLB 不需要冗余专家，也不需要额外的显存分配，而是在运行过程中即时进行逐层的专家精度转换，并将相关开销隐藏在 MoE 计算之前的 dispatch 阶段中。在代表性 MMoE 模型上的实验表明，ReaLB 实现了 1.10 倍至 1.32 倍的端到端加速，同时将平均精度损失限制在 1% 以内。

1. 一句话总览

论文元数据

字段	内容
标题	ReaLB: Real-Time Load Balancing for Multimodal MoE Inference
作者	Yingping Wang, Yi Wu, Xiangyu Wu, Junwei Cui, Weilin Cai, Zhijiang Guo, Jiayi Huang
发表场所 / 年份	文中未说明
研究领域	系统, 机器学习
关键词	Mixture-of-Experts, 多模态推理, 专家并行, 负载均衡, 低精度计算

资源链接

- 原始文件：本地上传文件（无外部链接）
- arXiv：文中未说明
- DOI：文中未说明
- 代码 / 数据集：文中未说明

标签（5个）：Mixture-of-Experts · 多模态推理 · 专家并行负载均衡 · FP4 低精度计算 · vLLM 推理系统

ReaLB 是一种运行时、模态感知的 MoE 负载均衡方法：它不迁移专家，而是在每次前向传播前根据瞬时负载与视觉 token 占比，对"过载且视觉专家主导"的 EP rank 动态切换为 FP4 低精度计算，并把转换开销隐藏在 dispatch 通信中，实现 $1.10\times-1.32\times$ 端到端加速、平均精度损失控制在 1% 以内【作者明确陈述】（）。

2. 阅读范围与证据状态

OCR 覆盖正文第 1-9 页及附录第 16-19 页（Appendix F、G、H、I 部分内容），涵盖引言、动机分析（3.1/3.2 节）、方法设计（4.1-4.3 节）与主实验（5.1-5.3 节）【作者明确陈述】（）。

- 附录 Appendix H 中关于 #mi("M_d") 演化的"详细实证分析"文字部分未被本 OCR 完整收录，仅有其对应图片（图片批次 5 图片 2）【作者明确陈述】（）。
- 多处关键指标（ΔAcc、Speedup）仅有文字定义、无显式计算公式，具体聚合口径未披露，标注为"文中未说明"【作者明确陈述】（）。
- 论文正文出现"ReaLB-mi"与"ReaLB-m1/ReaLB-m2"两套命名，OCR 未做主观统一，如实标注不一致，可能反映 OCR 抽取或版本差异【基于文中逻辑的推断】（）。

3. 根问题：论文究竟要解决什么

在专家并行（EP，把不同专家分布到不同 GPU 上运行的并行策略）部署下，每个 GPU 通常固定托管一部分专家；一次 MoE 层前向计算的层延迟由所有 rank 中最慢的一个决定，即 $\#mi("T_{\mathrm{MoE}}(x)=\max_i T_i(x)")$ ，这是一种"木桶效应"结构【作者明确陈述】（）。多模态 MoE（MMoE）推理阶段，尤其是大 batch 的 prefill（一次性处理输入提示词的阶段）阶段，视觉 token 数量远多于文本 token，导致路由到不同专家/设备的 token 量高度倾斜，进而产生严重的设备间负载不均衡，拖慢整体吞吐【作者明确陈述】（）。

MoE 通过每个 token 仅激活少数专家实现参数高效扩展，广泛用于现代大模型与多模态模型；但这种稀疏激活+输入依赖路由天然导致负载不均衡，多模态场景下这一问题更严重，因此直接决定了系统实际可部署的吞吐上限【作者明确陈述】（）。难点在于：该"最慢 rank"的身份在迭代间快速、不可预测地变化，使得依赖历史统计的静态或预测式方法从根本上失效【实验支持】（）。

本文的 story：旧路线（无论训练期均衡损失，还是推理期的专家复制/迁移调度）失效的技术原因是"用历史统计去预测下一时刻的热点"，而推理阶段路由的时间局部性太弱，预测必然滞后；本文的核心转折是把问题从"路由/专家放置优化"转化为"计算精度

自适应"——不追预测，只在当下"原地"降低已确认过载且可容忍精度损失的视觉专家的计算精度，从根本上避免了预测需求 [作者明确陈述] ()。

前排论文大图 **问题严重性** 呼应：第 3 节：EP 最慢 rank 决定层延迟且其身份不可预测




Figure 1: Motivation for real-time load balancing.

图组解读

- **图组结论**: Hot Device/Hot Expert 位于视觉 token 主导的输入侧，Top-1 热点 rank 在迭代间发生明显跳变
- **论证关系**: 为"视觉专家聚集致 straggler"核心洞见与专家激活高动态性提供直观场景，与 Figure 2 定量证据互补
- **适用范围**: 不含量化对比，不能单独证明视觉主导与过载之间的因果关系




Figure 2: High dynamics in MMoE routing limit the effectiveness of prediction-based methods. (a) Load imbalance across devices, experts, and modalities. (b) Temporal variation in imbalance severity across iterations. (c) Rapid shifts of the top-1 hot device and expert, highlighting the mismatch between historical observations and current load.

图组解读

- **图组结论**: 设备/专家视觉 token 占比差异显著，专家级不均衡波动远超设备级，预测线与观测线 200 迭代后明显分离
- **论证关系**: 支撑观察 1/观察 2 及 EPLB 预测失配批判，是"瞬时判定优于历史统计"的核心可视化证据
- **适用范围**: 仅验证预测失配一条 limit，基于 Kimi-VL/MMMU 单一设置，未涉及通信与显存开销

4. 旧方法为何不够

路线	原本解决什么	依赖前提/遗留限制	本文批判的具体 limit	对应设计模块
训练期辅助损失 / device-constrained routing	训练阶段调节门控提升专家利用率均衡	假设可在训练时调整梯度/路由目标	"不能直接用于推理", 未展开具体机制 [作者明确陈述] ()	无对应设计模块 (仅作背景问题设定)
FasterMoE 影子专家	复制过载专家到多设备均衡负载	需要额外显存与通信带宽	引入额外内存与通信开销 [作者明确陈述] ()	ReaLB 原地精度切换, 不复制专家
EPLB 历史式专家放置	用历史窗口统计周期性重放置专家	假设负载具有时间局部性	预测滞后、通信开销 $\#mi("K\cdot Bytes_{\{expert\}}")$ 、显存开销线性增长 [作者明确陈述] ()	瞬时状态判定 $\#mi("IB_d")$ 取代历史预测
LPLB	用线性规划更均匀重分配 token 流量	需高频调用逼近实时性	高频调用的调度开销可能超过均衡收益 [作者明确陈述] ()	LB Gate + 通信重叠的开销感知设计
通信侧重叠/核融合	降低 all-to-all 通信成本	假设计算已经均衡	无法解决计算本身不均衡 [作者明确陈述] ()	借用既有通信窗口隐藏精度转换开销

以上每条限制对应的实验证据仅部分完整：EPLB 一行有 Table 1/5.3 节量化对比支持 [实验支持] ()；FasterMoE、LPLB、通信侧优化、训练期方法均**未被论文纳入实测对比**，其批判停留在文字论证层面，无法从当前 OCR 内容确认量化差距。综合看，旧方法的核心技术限制可归纳为两条：**(a) 依赖历史统计预测，无法适应推理路由的强瞬时波动；(b) 通过专家复制/迁移实现均衡，天然引入通信和显存开销** [基于文中逻辑的推断] (推理依据：训练期方法、EPLB、LPLB、FasterMoE 的批评中反复出现"预测滞后"与"额外开销"两类问题,)。

5. 核心洞见与假设

核心洞见/贡献：EP 的 straggler (掉队者，即拖慢整体的最慢设备) 主要由聚集了视觉专家的 rank 造成；视觉 token 相较文本 token 在前向传播中表现出更高冗余性 (引用支持 [3,38]) [作者明确陈述] ()。由此推出的核心假设：**将"视觉主导且过载"的 rank 切换为低精度计算，可在几乎不损失文本相关精度的前提下降低该 rank 延迟，从而消除设备间执行时间不均衡** [作者明确陈述] ()。

支撑该洞见的观察 (实现所需前提)：

- 观察 1 (模态驱动的负载倾斜)：某 rank 视觉 token 占比可超 90%，另一些低于 50%；专家级占比范围 31%–93% [实验支持] (, Kimi-VL/MMMU/8GPU)。
- 观察 2 (不可预测的高动态性)：同一短窗口内热点专家负载/均值比可从约 $2\times$ 变到 $12\times$ ，时间局部性远弱于训练阶段 [实验支持] ()。

理论支撑：论文将均衡问题形式化为在线策略优化目标

$$\#mitex(\max_{\pi}\ \ \mathbb{E}_x[\max_i T_i(x)-\max_i T_i(\pi(x))-T_{\mathrm{LB}}(\pi,x)\big])$$

并论证：优化"token/专家均衡"这类代理指标并非最小化 $\#mi("\max_i T_i")$ 的必要条件；推理阶段不需要为优化稳定性维持 token 均衡，只需直接最小化执行延迟 [作者明确陈述] ()。这为"不追求专家/token 完全均衡，只直接压低设备级延迟"的设计选择提供了理论依据。

前提可能失效的场景：若视觉 token 的冗余性假设不成立 (即视觉专家对精度同样敏感)，或负载倾斜并非以模态为主因，该核心假设的适用性会被削弱；论文未提供该前提的反向消融，属于证据缺口 (见 4.2 节相关说明)。

6. 方法：从洞见到可执行系统

总览：输入为当前层各设备的负载与模态构成 → 判定过载设备 → 在过载设备中筛出"视觉主导"者 → 对这些设备的专家在线转换为 FP4 精度并执行计算 → 转换开销与元数据收集被安排在 dispatch 通信窗口内隐藏 → 输出经均衡后的 MoE 层结果，供后续 Combine/下一层使用 [作者明确陈述] ()。

1. 运行时状态与热点识别 ($\#mi("IB_d")$, 阈值 $\#mi("C")$)

- 动机：需要不依赖历史统计、纯瞬时的"是否过载"判定 [作者明确陈述] ()。
- 输入/过程/输出：输入当前层各设备 token 负载 $\#mi("Load_d")$ 与平均负载 $\#mi("Ideal")$ ；计算 $\#mi("IB_d = Load_d/Ideal")$ ；输出热点集合 $\#mi("\mathcal{H}=\{d\mid IB_d>C\}")$ ， $\#mi("C=1")$ 表示完全均衡 [作者明确陈述] ()。
- 优势：仅用当前层瞬时数据，规避历史预测滞后问题 [基于文中逻辑的推断] ()。

2. 模态感知精度分配 (#mi("R_{vd}"), #mi("M_d"))

- 动机：区分"视觉主导可压缩"与"文本主导不可压缩"的过载设备【作者明确陈述】（）。
- 输入/过程/输出：输入设备上视觉/文本 token 数 #mi("N_{vd}, N_{td}"); 计算 #mi("R_{vd}=N_{vd}/(N_{vd}+N_{td})"); 对 #mi("d\in\mathcal{H}") 且 #mi("R_{vd}>M_d") 的设备标记为可压缩，其专家用低精度 GEMM 执行，其余保持标准精度【作者明确陈述】（）。
- 优势：把降精度限定在对损失不敏感的视觉专家上【作者明确陈述】（）。

3. AIMD 自适应阈值控制

- 动机：固定阈值难以兼顾响应速度与稳定性【作者明确陈述】（）。
- 规则：#mi("IB_{global}=\max_d IB_d"), 拥塞阈值 #mi("\tau=1.5"); 若 #mi("IB_{global}>\tau") 则 #mi("M_d=0.5M_d"), 否则 #mi("M_d=\min(1, M_d+0.1)")【作者明确陈述】（）。
- 优势：借鉴网络拥塞控制思想，拥塞时快速收紧、平稳期逐渐放松【作者明确陈述】（）。

4. 在线精度转换

- 动机：不增加显存占用的前提下支持实时精度切换【作者明确陈述】（）。
- 过程：每个专家仅存原始高精度权重+预计算缩放因子；调度下发新精度配置时在线量化到目标精度【作者明确陈述】（）。


5. 开销隐藏的流水线编排

- 动机：元数据收集 #mi("S") 与精度转换 #mi("T") 本身引入额外计算，需从关键路径移除【作者明确陈述】（）。
- 过程：#mi("S")、#mi("T") 与 dispatch 阶段的设备间通信重叠执行【作者明确陈述】（）。
- 优势：LB 开销只涉及本地转换和轻量元数据收集，不随 EP 规模扩展，而 dispatch 延迟随 EP 规模增长，因此重叠后 LB 开销被通信"淹没"【作者明确陈述】（）。


6. LB Gate (全局 batch 阈值 #mi("\Gamma"))

- 动机：只有 GEMM 计算主导延迟时，设备负载不均衡才直接转化为延迟不均衡；小 batch 时启用 LB 无意义甚至有害【作者明确陈述】（）。
- 过程：聚合设备负载超过 #mi("\Gamma=2048") (256×8) 时启用 LB，否则退回标准执行【作者明确陈述】（）。

前排论文大图 方法流水线 呼应：第 6 节：模态感知精度分配与开销隐藏流水线的整体系统设计



Panel 1



Panel 2

Figure 3: ReaLB design for efficient multimodal MoE inference. It combines modality-aware scheduling and an overlapping execution pipeline to mitigate device-level latency imbalance while minimizing runtime overhead.

图组解读

- **图组结论**：Rank-1 视觉主导过载转 NVFP4 精度，Rank-2 文本主导过载保持标准精度并标注 Protected
- **论证关系**：具体实例化"过载不等于降精度"判定规则，与开销隐藏流水线设计互补
- **适用范围**：为示意性简化架构，不含任何速度/精度数值，不能论证实际效果幅度

7. 为什么它可能有效

- 瞬时状态判定 (#mi("IB_d")) 只依赖当前层数据，逻辑上避免了历史统计对时间局部性的假设，因而能应对 3.2 节实证的强瞬时波动【基于文中逻辑的推断】（）。
- 将降精度限定于"视觉主导+过载"设备，理论上兼顾速度与精度，前提是视觉 token 冗余性假设成立（背景知识支持，非本文直接实验验证的前提本身）【背景知识】（）。
- 流水线重叠使 LB 开销不随 EP 规模线性增长，理论上具有可扩展性，但该扩展性论证仅为理论推演，未在不同 EP 规模下实测验证【基于文中逻辑的推断】（）。

- AIMD 通过瞬时拥塞信号（而非历史窗口）调节阈值，预期能在拥塞与稳定之间取得比固定阈值更好的平衡【作者明确陈述】（）。

8. 实验与指标：证据是否支撑主张

8.1 实验问题与判定标准

- 效果问题：ReaLB 相对 Baseline/EPLB/FP4-All 的端到端速度与精度损失如何？→ 对应 Table 1/2【实验支持】（）。
- 机制/必要性问题：预测式方法是否确实因动态性而失效？模态感知与流水线重叠是否各自必要？→ 对应 5.3 节延迟分解、ReaLB-seq/ReaLB-m1/m2 消融【实验支持】（）。
- 鲁棒性问题：方法是否跨模型（Kimi-VL、Qwen3-VL）泛化？→ 对应两模型对比结果【实验支持】（）。
- 适用范围问题：方法是否仅在计算受限（大 batch）场景有效？→ 对应 LB Gate 部分，但缺乏量化消融【作者明确陈述】（，量化对比"文中未说明"）。

8.2 数据、任务、对比与运行设置

- 硬件：8×NVIDIA RTX 5090，DP+EP 混合并行【作者明确陈述】（）。
- 框架：vLLM v0.13.0，混合精度来自 LLM Compressor，NVFP4 GEMM kernel 来自 FlashInfer【作者明确陈述】（）。
- 模型：Kimi-VL-A3B-Instruct（64 路由专家）、Qwen3-VL-30B-A3B-Instruct（128 路由专家），均做 NVFP4 PTQ【作者明确陈述】（）。
- 任务/benchmark：MMMU、MathVista、DynaMath【作者明确陈述】（）。
- 部署：Prefill-Decode colocated，continuous batching【作者明确陈述】（）。
- 超参数：容量因子 $\#mi("C=1")$ ， $\#mi("M_d")$ 初始 0.9， $\#mi("\Gamma=2048")$ 【作者明确陈述】（）。
- 对比方法：Baseline（W16A16）、FP4-All（全 W4A4）、EPLB、Async_EPLB、ReaLB、ReaLB-seq、ReaLB-m1/m2【作者明确陈述】（）。
- 重复次数/统计方式：文中未说明（Panel2/5 给出均值±标准差，但未说明重复运行次数或统计口径）。

8.3 指标字典与对应公式

- **指标与方向**：Speedup（端到端速度提升），无符号标注，比值形式，越大越好。
 - **定义与公式**：作者文字定义为"相对 BF16 baseline 的端到端吞吐速度提升"（）；**来源层级：无可核验公式**——正文未给出显式计算式或聚合口径。
 - **实验用途**：回答效果问题，比较 ReaLB 与 Baseline/EPLB/FP4-All。
 - **读数与边界**：区间 $1.10\times-1.32\times$ （）；不能证明该提升在不同 EP 规模、硬件平台下同样成立（仅 8×RTX5090 单一配置）。
- **指标与方向**： ΔAcc （精度下降），单位百分点，越小越好。
 - **定义与公式**：作者文字定义"相对 BF16 baseline 的准确率下降"（）；**来源层级：无可核验公式**——未给出分子分母或跨 benchmark 聚合方式。
 - **实验用途**：检验模态感知降精度是否比全模型降精度（FP4-All）更保守。
 - **读数与边界**：如 Kimi-VL/DynaMath，FP4-All -8.19%，ReaLB -3.10%【实验支持】（）；Qwen-VL 上 ReaLB 平均 <0.6%（）；"平均精度损失<1%"的跨 benchmark 聚合方法文中未说明。
- **指标与方向**：吞吐（tokens/sec），越大越好。
 - **定义与公式**：作者明示测量方法——CUDA 事件细粒度计时+vLLM benchmark 测端到端吞吐，单位为"处理 token 数/秒（输入+输出）"（），属"作者文字定义"的测量方法而非公式。
 - **实验用途**：作为 Speedup 的底层测量依据。
 - **读数与边界**：具体吞吐绝对数值未在本 OCR 文字中给出，仅有换算后的 Speedup 倍数。
- **指标与方向**：MoE 层延迟，单位 ms，越小越好。
 - **定义与公式**：作者说明其用途为"捕捉逐层执行效率"（），基于 CUDA 事件测量，无显式公式；**来源层级：无可核验公式**。
 - **实验用途**：检验 EPLB 是否因预测失配"加剧"而非缓解不均衡。
 - **读数与边界**：Kimi-VL 上 ReaLB 从 1.51ms→1.36ms，EPLB 反而从 1.51ms→2.15ms【实验支持】（）；Qwen-VL 上 1.48ms→1.39ms（ReaLB）、→1.99ms（EPLB），为图像补充数值【图像直接可见】（）。
- **指标与方向**： $\#mi("IB_d")$ （设备级负载不均衡度），无量纲比值，越接近 1 越均衡。
 - **定义与公式**： $\#mi("IB_d = Load_d/Ideal")$ ，**来源层级：原文公式**（）。
 - **实验用途**：作为热点识别的判定输入，也是图 6/7 类附录证据的纵轴定义。
 - **读数与边界**：附录图显示跨 10 个 MoE 层普遍在 1.0-2.0 波动、间歇达 2.5-4.0【图像直接可见】（）；仅是聚合比值，不揭示具体是哪个 rank/专家持续热点。

8.4 主结果、消融与证据边界 比较工作与被批判限制的呼应

比较工作/基线	核心限制或失效条件	本文对应模块	直接实验与仍未验证的边界
EPLB	历史窗口预测滞后于路由动态性；再平衡带来通信/显存开销 [作者明确陈述] ()	瞬时 #mi("IB_d") 判定 + 原地降精度 (4.2 节)	Table 1/2、5.3 节延迟分解直接验证 (EPLB speedup 多次<1.00, MoE 延迟升至 2.15ms) [实验支持] () ; 未验证不同 EP 规模下 EPLB 通信/显存开销的量化对比
FP4-All	均匀低精度对多模态负载过于激进, 精度损失显著 [作者明确陈述] ()	模态感知选择性降精度 (4.2 节)	Table 1 直接对比 $\Delta\text{Acc}/\text{Speedup}$ [实验支持] () ; 缺少"仅对文本主导 rank 降精度"的反向消融
FasterMoE、LPLB、通信侧重叠方法	分别为显存/通信开销、高频调度开销、无法解决计算不均衡 [作者明确陈述] ()	无专家复制、开销感知设计、借用通信窗口	论文未将三者纳入实测对比表, 无法从当前 OCR 内容确认量化差距

主张与证据

主张	直接证据 (实验/表图)	证据强度与边界
C1: 端到端 $1.10\times-1.32\times$ 加速、精度损失<1%	Table 1 逐 benchmark 数值 [实验支持] ()	覆盖较完整, 但"<1%"的跨 benchmark 平均口径文中未说明
C3: EPLB 无法适应推理路由动态性	Figure 2c 预测/观测分离、5.3 节 MoE 延迟对比 [实验支持] ()	缺少"预测命中率"量化指标, 仅有定性+间接速度证据
C4: 模态感知优于均匀降精度	Table 1 ReaLB vs FP4-All 的 $\Delta\text{Acc}/\text{Speedup}$ [实验支持] ()	缺少反向消融, 无法完全分离"模态选择"与"降精度比例"各自贡献
C5: 流水线重叠隐藏开销	ReaLB vs ReaLB-seq 对比 (, 及附录 Appendix I 跨 benchmark 复现) [实验支持]	缺少 S+T 绝对开销时间的直接测量
C9: 仅计算受限场景有效	LB Gate 定性说明+ $\Gamma=2048$ ()	Gate 开关的量化消融数字文中未说明

- 消融显示 AIMD 自适应控制比固定阈值 (ReaLB-m1/m2) 更稳定 [实验支持] (), 但 #mi("M_d") 演化的详细文字分析在 Appendix H 未被本 OCR 完整收录。
- Rank 级别最高提速 $1.29\times$ (Kimi-VL)、附录图片显示 Qwen-VL 某 rank 达 $1.62\times$ (该数值未被正文引用) [实验支持] ()。
- 所有实验均在单一 $8\times\text{RTX5090}$ 集群上完成, 未见跨 EP 规模或跨硬件平台验证 [基于文中逻辑的推断] ()。

9. 图表解读与论证关系




Figure 4: ReaLB is enabled only in the compute-bound regime with large batch sizes.

图组解读 **适用边界** 呼应: 第 6 节: LB Gate 仅在计算受限、聚合负载超过 $\Gamma=2048$ 时启用

- **图组结论:** token 数增大后 GEMM 分段占比迅速上升, 虚线右侧成为主导分段
- **论证关系:** 为"仅计算受限区间启用 LB"提供定性支持, 呼应主张地图 C9
- **适用范围:** 虚线与 $\Gamma=2048$ 精确对齐无法从对数轴判读, 无开关前后量化加速数字




Figure 5: Fine-grained MoE latency analysis. Top row (a-c): Kimi-VL; bottom row (d-f): Qwen-VL.

图组解读 实验结论 呼应：第 8 节：C3（EPLB 无法适应动态路由）与 C5（流水线重叠隐藏开销）

- **图组结论**: Kimi-VL 上 ReaLB 总时长-22.8%、EPLB+3.9%，MoE 延迟 ReaLB 1.51→1.36ms, EPLB→2.15ms, Qwen-VL 趋势一致
- **论证关系**: 直接验证 EPLB 历史预测适得其反的机制与流水线重叠的速度收益
- **适用范围**: 仅覆盖 DynaMath 单一 benchmark, 跨 benchmark 泛化性由附录图补充验证




Figure 6: Dynamics of device-level load imbalance across MoE layers 12-21.

图组解读 适用边界 呼应：第 8 节：观察 2（不可预测高动态性）从单层扩展到多层的验证边界

- **图组结论**: 跨 10 个 MoE 层（Layer12-21）#mi("IB_d")普遍在 1.0–2.0 波动，间歇达 2.5–4.0
- **论证关系**: 支撑逐层瞬时判定设计的必要性，将动态性观察从单层扩展到多层
- **适用范围**: 具体模型/数据集未重复说明, 无法从当前 OCR 内容确认确切实验设置




Figure 7: Overloaded devices and experts across iterations for layer 12-19, with token proportions for different modalities.

图组解读 适用边界 呼应：第 8 节：视觉 token 占比 31%–93% 的模态负载倾斜跨层泛化边界

- **图组结论**: 8 层（Layer12-19）均现超载 rank 与视觉占比 60%–96% 的热点专家，个别专家仅约 26%
- **论证关系**: 将模态驱动负载倾斜从单层扩展到 8 层，佐证 #mi("R_{vd}")阈值判定的必要性
- **适用范围**: 具体模型/数据集来源未标注, 无法从当前 OCR 内容确认




Figure 8: Token composition in continuous batching.

图组解读 适用边界 呼应：第 8 节：colocated 部署近似 prefill-only 场景的方法学假设

- **图组结论**: Decode token 占比全程远低于 10%，视觉 token 占比在 0.2–1.0 间剧烈波动
- **论证关系**: 为 colocated 设置不被 decode token 污染背书，支撑观察 1/观察 2 的动态性描述
- **适用范围**: 具体模型/benchmark 未标注, 无法从当前 OCR 内容确认




Figure 10: End-to-end latency breakdown on additional benchmarks.

图组解读 **实验结论** 呼应：第 8 节：C1/C3/C5 主张从 DynaMath 扩展到 MMMU/MathVista 的泛化验证

- **图组结论**：MMMU/MathVista 上 EPLB/Async_EPLB 总时长增加 (+3.1%~+22.4%)，ReaLB 降幅均大于 ReaLB-seq
- **论证关系**：复现 EPLB 预测失效机制与流水线重叠速度收益，验证跨 benchmark 稳健性
- **适用范围**：各分段无绝对数值，无法精确量化究竟隐藏了多少开销




Figure 9: Evolution of the control parameter under AIMD-based adaptive control on DynaMath. The red background indicates time steps where the global imbalance exceeds the congestion threshold.

图组解读 **消融验证** 呼应：第 6 节：AIMD 自适应阈值控制的瞬时拥塞响应规则 ($\tau=1.5$)

- **图组结论**：#mi("M_d")在拥塞区间骤降、非拥塞期逐步回升，Qwen3-VL 拥塞区间更宽更连续
- **论证关系**：可视化 AIMD 规则的实际触发过程，为 AIMD 优于静态阈值的主张提供机制解释
- **适用范围**：无静态阈值对照曲线，是否优于固定阈值仍需依赖 Table 1 数字

表格证据：Table 1: Main performance comparison and trade-offs under different load balancing strategies.

实验结论 呼应：第 8 节：C1 ($1.10 \times -1.32 \times$ 加速、精度损失 < 1%) 与 C4 (模态感知优于均匀降精度)

- **图组结论**：ReaLB 相对 Baseline 加速 $1.10 \times -1.32 \times$ ，较 FP4-All 精度损失显著更低（如 DynaMath -3.10% vs -8.19% ）
- **论证关系**：量化对比 ReaLB/EPLB/FP4-All 的速度-精度权衡，直接支撑核心效果主张
- **适用范围**：跨 benchmark 平均口径文中未说明，仅 $8 \times \text{RTX5090}$ 单一硬件配置

Model	Workload	Baseline	EPLB	FP4-All	ReaLB-m1	ReaLB-m2	ReaLB-seq	ReaLB
Kimi-VL	MMMU $\Delta \text{Acc} \downarrow$	0.00	0.00	-4.22	-2.22	0.00	-1.22	-1.22
	Speedup $\uparrow$	1.00	0.91	1.34	1.32	1.29	1.25	1.32
	MathVista $\Delta \text{Acc} \downarrow$	0.00	0.00	-2.00	-2.00	-1.10	-1.70	-1.70
	Speedup $\uparrow$	1.00	0.95	1.40	1.32	1.30	1.26	1.31
	DynaMath $\Delta \text{Acc} \downarrow$	0.00	0.00	-8.19	-3.80	-2.50	-3.10	-3.10
	Speedup $\uparrow$	1.00	0.96	1.41	1.30	1.29	1.25	1.30
Qwen-VL	MMMU $\Delta \text{Acc} \downarrow$	0.00	0.00	-2.44	-0.34	-0.34	-0.00	-0.00
	Speedup $\uparrow$	1.00	0.91	1.18	1.13	1.13	1.01	1.13
	MathVista $\Delta \text{Acc} \downarrow$	0.00	0.00	-2.70	-1.60	-1.30	-0.40	-0.40
	Speedup $\uparrow$	1.00	0.83	1.16	1.14	1.13	1.01	1.13
	DynaMath $\Delta \text{Acc} \downarrow$	0.00	0.00	-1.89	-1.59	-1.09	-0.39	-0.39
	Speedup $\uparrow$	1.00	0.84	1.12	1.10	1.10	1.02	1.10

表格证据: Table 2: Accuracy stability of ReaLB across additional multimodal benchmarks (). 实验结论 呼应:

第 8 节: ReaLB 平均精度损失<1% 在多个多模态基准上的稳定性

- **图组结论:** Qwen-VL 上 ReaLB 平均精度损失<0.6%，跨基准保持稳定低损失
- **论证关系:** 补充验证模态感知降精度策略的精度稳健性，支撑 C4 主张
- **适用范围:** 具体聚合口径与重复次数文中未说明

Model	AI2D	InfoVQA	TextVQA	MMBench	AVG
Kimi-VL	-0.13	-0.38	-0.91	-0.00	-0.36
Qwen-VL	-1.23	-0.00	-0.53	-0.60	-0.59

表格证据: Table 4: Speedup of ReaLB in the prefill-only setting. 适用边界 呼应: 第 6 节: LB Gate 仅在计算受限、大

batch 场景生效的适用条件

- **图组结论:** 报告 prefill-only 部署下 ReaLB 相对 Baseline 的加速比，具体数值正文未展开引用
- **论证关系:** 为"计算受限场景"适用条件提供 prefill-only 模式下的补充验证
- **适用范围:** 未纳入正文 Table 1/2 主对比，跨 EP 规模下是否成立未见验证

Model	MMMU	MathVista	DynaMath
Kimi-VL	1.35 $\times$	1.33 $\times$	1.34 $\times$
Qwen-VL	1.12 $\times$	1.12 $\times$	1.10 $\times$

10. 完整因果推理树

- 根问题: EP 下 MMoE 推理层延迟由最慢 rank 决定，该 rank 身份在迭代间快速变化、难以预测 ()
 - 旧方法限制: 历史预测式方法 (EPLB/LPLB) 跟不上动态性; 专家迁移/复制类方法引入通信与内存开销 ()
 - 核心洞见/假设: 过载 rank 往往是视觉专家聚集的 rank，视觉 token 冗余度更高、对精度下降更不敏感 ()
 - 方法模块: 模态感知精度分配 $\#mi("R_{vd}"/\#mi("M_d"))$ ()
 - 可验证预测: 只对视觉主导+过载 rank 降精度，可在精度损失可控前提下降低其延迟
 - 指标与实验: ΔAcc 、Speedup、MoE 层延迟 (Table 1,)
 - 图表证据: Figure 5 延迟分解、附录跨 benchmark 图 ()
 - 结论与适用边界: Kimi-VL/Qwen-VL 上均验证有效 [实验支持] ()，但未覆盖"模态隔离"架构，未做反向消融 (文中未说明)
 - 方法模块: 瞬时热点识别 $\#mi("IB_d")$ ()
 - 可验证预测: 瞬时判定应比历史窗口更快命中真实热点
 - 指标与实验: Figure 2c 预测/观测对比、5.3 节 MoE 延迟 ()
 - 图表证据: Figure 2c、附录 Figure 6 ()
 - 结论与适用边界: 定性支持充分，但"命中率"量化指标未被当前证据直接验证 (文中未说明)
 - 方法模块: 开销隐藏流水线 ()
 - 可验证预测: LB 开销可被通信窗口"淹没"，不随 EP 规模扩展
 - 指标与实验: ReaLB vs ReaLB-seq 速度差 ()
 - 图表证据: Figure 5 realb_overhead/overlapping 分段 ()
 - 结论与适用边界: 速度收益已验证 [实验支持]; 跨 EP 规模的可扩展性未被当前证据直接验证 (仅单一硬件配置)
 - 方法模块: AIMD 阈值控制 ()
 - 可验证预测: 自适应阈值应比固定阈值更稳定
 - 指标与实验: ReaLB vs ReaLB-m1/m2 (Table 1,)
 - 图表证据: 附录 AIMD 轨迹图 ()
 - 结论与适用边界: 稳定性优势已验证 [实验支持]; $\#mi("M_d")$ 详细收敛行为在 Appendix H 未被当前证据直接验证
 - 方法模块: LB Gate ()
 - 可验证预测: 仅在计算受限 (大 batch) 场景启用才有收益
 - 指标与实验: Figure 4 定性趋势 ()
 - 图表证据: Figure 4 GEMM 占比堆叠图
 - 结论与适用边界: 定性支持存在; 开关 Gate 前后的量化效果未被当前证据直接验证 (文中未说明)

11. 结论、贡献与边界

贡献: 识别并量化 MMoE 推理中模态驱动的动态负载不均衡 [作者明确陈述]; 提出模态感知、精度自适应的 ReaLB 调度机制配合 AIMD 控制; 设计开销感知流水线编排隐藏转换延迟; 在 vLLM 中实现并在两个 MMoE 模型上验证性能提升 ()。

证据充分的结论: EPLB 在动态路由下确实表现为速度不稳定甚至负收益 [实验支持] (); ReaLB 相对 FP4-All 精度损失显著更低、吞吐相近 [实验支持] (); 流水线重叠对速度收益有实测贡献 [实验支持] ()。

尚属推断的意义: 瞬时判定"天然"优于历史预测的机制解释是逻辑推断而非直接量化验证 (缺少命中率指标) [基于文中逻辑的推断]; LB 开销的可扩展性论证为理论推导, 未经跨 EP 规模实测 [基于文中逻辑的推断]。

适用条件: 需要 GEMM 主导延迟的大 batch 计算受限场景 ($\#mi("\Gamma=2048")$); 需模态融合 (modality-fused) 架构而非模态隔离架构 [作者明确陈述] ()。

局限: 硬件规模单一 ($8\times RTX5090$); 消融未完全分离模态选择与精度切换各自贡献; 关键指标 (ΔAcc 、Speedup) 缺显式公式; 命名不一致 (ReaLB-mi vs ReaLB-m1/m2) 未获澄清。

审稿式风险检查:

- 贡献新意: 核心创新 (精度自适应替代路由/放置优化) 有清晰的问题-洞见对应链, 当前证据未显示明显新意风险。
- 写作/可复现性: 命名不一致 (ReaLB-mi/ReaLB-m1/m2) 及关键指标无显式公式, 存在可复现性风险 [作者明确陈述] ()。
- 效果大小: 加速幅度 ($1.10\times-1.32\times$) 在不同模型间差异较大 (Kimi-VL 高于 Qwen-VL), 当前证据未充分说明该差异原因。
- 实验覆盖: 单一硬件规模、缺少反向消融 (仅对文本主导 rank 降精度)、部分基线 (FasterMoE、LPLB) 未纳入实测对比, 是实验覆盖的真实缺口。
- 方法设计: LB Gate 阈值 $\#mi("\Gamma)$ 、AIMD 参数 ($\#mi("\tau=1.5")$)、增减系数) 均为经验设定, 当前证据未显示这些超参数的敏感性分析覆盖不足以外的额外风险。

12. 术语与第一性原理学习路径

12.1 核心术语

- **术语:** MoE (Mixture-of-Experts, 混合专家) ——一种神经网络层设计, 将前馈网络替换为多个"小专家", 每个 token 只经过其中少数专家计算。
 - **第一性原理角色:** 连接"模型容量"与"计算量"两个基本量——通过稀疏激活在扩大参数规模的同时控制单 token 计算成本。
 - **本文位置:** 整个负载不均衡问题的根源结构 ()。
- **术语:** EP (Expert Parallelism, 专家并行) ——把不同专家分布到不同 GPU 上运行的并行策略。
 - **第一性原理角色:** 受"跨设备通信带宽"约束; 决定了负载不均衡如何转化为跨设备执行时间差异。
 - **本文位置:** 负载均衡问题发生的物理载体 ()。
- **术语:** $\#mi("IB_d")$ (设备级负载不均衡度) ——某设备负载与平均负载之比。
 - **第一性原理角色:** 连接"瞬时负载状态"与"是否过载"这一判定动作的基本量。
 - **本文位置:** 热点识别模块的核心输入 ()。
- **术语:** $\#mi("R_{vdj}")$ (视觉 token 占比) ——某设备上视觉 token 数占该设备总 token 数的比例。
 - **第一性原理角色:** 连接"输入模态构成"与"是否可安全降精度"的判据。
 - **本文位置:** 模态感知精度分配的判定变量 ()。
- **术语:** FP4/NVFP4 (4-bit 浮点低精度计算) ——用更少比特表示数字以加速矩阵乘法, 可能损失精度。
 - **第一性原理角色:** 受"数值表示精度 vs 计算吞吐"这一物理/硬件约束的权衡。
 - **本文位置:** ReaLB 对视觉主导过载 rank 的执行方式 ()。
- **术语:** AIMD (加性增乘性减) ——网络拥塞控制思想: 通畅时缓慢增加、拥塞时大幅降低。
 - **第一性原理角色:** 连接"瞬时拥塞信号"与"控制变量调整幅度"的反馈机制。
 - **本文位置:** $\#mi("M_d")$ 阈值的自适应更新规则 ()。
- **术语:** dispatch (all-to-all 通信阶段) ——EP 下各设备把 token 发送到对应专家所在设备的通信过程。
 - **第一性原理角色:** 受设备间通信带宽/延迟约束; 是本文用于"隐藏"精度转换开销的时间窗口。
 - **本文位置:** 开销隐藏流水线编排的关键位置 ()。
- **术语:** LB Gate (负载均衡开关, 全局阈值 $\#mi("\Gamma)$) ——仅在聚合负载超过阈值时启用均衡机制。
 - **第一性原理角色:** 连接"计算是否受限于 GEMM"与"是否值得付出 LB 开销"的判据。
 - **本文位置:** 控制 ReaLB 在何种 batch 规模下生效 ()。

12.2 学习路径

1. MoE 的基本对象是"专家网络+路由门控", 理解它是后续一切负载问题的起点 (好比理解"分诊制医院"才能理解"某科室排队"问题)。
2. EP 的约束是"跨设备通信带宽有限、每设备专家固定", 理解这一物理约束才能理解为何"最慢设备决定整层延迟"。
3. 推理阶段路由动态性 (强于训练阶段) 是理解"为什么历史预测方法失效"的机制前提。
4. 低精度计算 (FP4) 的"速度-精度权衡"是理解 ReaLB"降精度换速度"这一设计选择合理性的基础。

5. AIMD 拥塞控制思想是理解 `#mi("M_d")` 阈值如何在瞬时信号驱动下自动调节的最后一环, 直接连接到本文的可观测指标 (Speedup、 ΔAcc) 与结论边界。