

论文解构报告

ServeGen: Workload Characterization and Generation of Large Language Model Serving in Production

Yuyuan Xiang, Xue Li, Kun Qian, Wenyuan Yu, Ennan Zhai, Xin Jin

2025

大语言模型服务

工作负载特征分析

基准测试

工作负载生成

源文件：<https://arxiv.org/pdf/2505.09999>

arXiv：<https://arxiv.org/abs/2505.09999>

DOI：[10.48550/arxiv.2505.09999](https://doi.org/10.48550/arxiv.2505.09999)

生成时间：2026-07-20

目录

- 摘要翻译 3
 - 1. 一句话总览 3
 - 2. 阅读范围与证据状态 3
 - 3. 根问题：论文究竟要解决什么 3
 - 4. 旧方法为何不够 4
 - 5. 核心洞见与假设 4
 - 6. 方法：从洞见到可执行系统 5
 - 7. 为什么它可能有效 5
 - 8. 实验与指标：证据是否支撑主张 6
 - 9. 图表解读与论证关系 8
 - 10. 完整因果推理树 9
 - 11. 结论、贡献与边界 10
 - 12. 面向初学者的学习路径 10

随着大语言模型 (LLM) 的广泛应用, 服务 LLM 推理请求已成为一项日益重要的任务, 吸引了积极的研究进展。实际的工作负载在这一过程中起着至关重要的作用: 它们对于激发和评估服务技术和系统是必不可少的。然而, 由于缺乏全面的工作负载特征分析, 现有对真实世界中 LLM 服务工作负载的理解非常有限。先前的分析在规模和范围上都显不足, 未能完全捕获复杂的工作负载特征。在本文中, 我们通过对从我们全球云 LLM 服务中收集的 LLM 服务工作负载进行深入的特征分析, 填补了这一空白。我们的分析不仅涵盖了语言模型, 还涵盖了新兴的多模态模型 and 推理模型, 并在每种情况下都揭示了重要的新发现。此外, 基于我们的发现, 我们提出了 ServeGen, 这是一个通过在每个客户端的基础上进行组合来生成逼真 LLM 服务工作负载的系统性框架。实际应用案例验证了, 与幼稚的工作负载生成方法相比, ServeGen 能够实现更准确的性能基准测试, 并揭示了原本可能被忽视的新设计启示。ServeGen 已在 <https://github.com/alibaba/ServeGen> 开源。

1. 一句话总览

论文元数据

字段	内容
标题	ServeGen
作者	文中未说明
发表场所 / 年份	文中未说明
研究领域	大语言模型推理, 系统评测
关键词	大语言模型, 在线推理, 工作负载特征刻画, 负载生成器, ServeGen

资源链接

- 原始文件: 本地上传文件
- arXiv: 文中未说明
- DOI: 文中未说明
- 代码 / 数据集: 文中未说明

标签 (3-5 个) : 大语言模型推理 · 工作负载生成 · 系统性能评测 · 多模态与推理模型 · 客户端分解

[作者明确陈述] 本论文针对真实生产环境下大语言模型 (LLM, 指能够理解和生成人类语言的深度学习程序) 在线推理服务工作负载 (Workload, 指模型服务接收的所有请求构成的整体流量) 特征刻画缺失的问题, 提出了一种基于客户端分解 (Client Deconstruction, 将全局流量拆解为每个独立客户端维度的行为) 进行因果建模的开源负载生成框架 ServeGen [页码: 2]。[实验支持] 实验结果表明, ServeGen 能在资源规划中纠正传统失真方法低估 50% 服务器配置的问题, 并能在前填充与解码分离架构 (PD-Disaggregation, 将大模型推理的预填充和解码阶段分配在不同硬件资源上运行的架构) 中准确指导实例配比决策 [页码: 12, 13]。

2. 阅读范围与证据状态

[作者明确陈述] 本报告基于对论文第 2 页至第 13 页的 OCR 文本和图像证据分析 [页码: 2-13]。[作者明确陈述] 明显缺失或损坏的内容包括:

- 论文具体的代码仓库链接、作者列表及发表场所与年份 [页码: 2-4];
- 原始请求日志中去除了文本的具体字符内容, 导致前缀缓存 (Prefix Caching, 缓存重复公共提示词以节省计算资源的技术) 的真实重复率数据缺失 [页码: 13];
- 系统中有 17 张图片因超出数量限制而未能进行视觉分析 [页码: 13]。[基于文中逻辑的推断] 影响结论可靠性的限制在于:
- 由于数据仅包含 4 个月的生产日志, 因此在长周期 (如跨年) 的纵向趋势演进上证据不足 [页码: 13];
- 未引入复杂的插件调用 (Plugin Calls, 推理中途调用外部搜索引擎、数据库或 API) 的交互, 仅刻画了独立的请求-响应流, 对复杂代理 (Agent) 负载的泛化性仍有待验证 [页码: 13]。[背景知识] 需要指出, 报告中关于大模型推理引擎工作原理 (如 Prefill 阶段为算力密集型, Decoding 阶段为显存带宽密集型) 属于该领域的经典背景知识, 并非本论文的特有发现。

3. 根问题: 论文究竟要解决什么

[作者明确陈述] 本文要解决的核心问题是缺乏对大语言模型推理服务在真实生产环境下的全维度、大规模工作负载的系统特征刻画, 以及由此导致的测试负载失真问题 [页码: 2]。[作者明确陈述] 这一问题极其重要, 因为真实负载是指导大模型推理引擎系统优化和基准测试 (Benchmarking, 性能评估) 的基石。若测试负载失真, 将导致实验室中的优化系统在实际生产中发生严重性能退化, 甚至可能迫使开发团队推翻底层的架构设计, 阻碍技术落地 [页码: 2]。[基于文中逻辑的推断] 该问题的核心难点在于:

- **隐私与规模门槛**: 因商业机密限制, 极难获取真实且大规模的生产级大模型推理服务日志 [页码: 2];

- **新型模型的复杂性**：新兴的多模态大模型和推理模型（在输出前进行长时“思考”的模型）引入了非文本输入的前置处理开销和长时双峰思考行为，其流量特性处于未知状态 [页码：2, 3]；
- **宏观流量的多变性**：全局流量的到达率和请求长度随时间存在高突发和独立的动态漂移，用传统的数学模型直接在全局尺度进行统一拟合极其困难 [页码：5, 6]。[作者明确陈述] 一个成功的负载生成工具必须能精准复现真实工作负载中高突发的流量波动、多模态前置计算引起的排队阻塞，以及推理模型思考与输出的双峰分布特征，且能输出与真实生产一致的性能评测结论 [页码：11, 12]。

本文的 story：[基于文中逻辑的推断] 主流的测试负载生成路线通常采用 NAIVE（天真）方法，即静态地结合泊松过程（用以模拟请求到达时间）与 ShareGPT 等开源文本数据集 [页码：2, 11]。这种方式在技术上忽略了客户端的异构性与流量的动态关联，低估了突发流量带来的性能挑战，致使生成的负载“看起来比实际容易处理” [页码：2]。本文实现的核心转折在于：虽然全局宏观流量看似无序，但在解耦到每个独立客户端（例如特定的应用或用户）后，其行为特征（如突发性、请求长度分布）是高度稳定且可预测的，全局的动态漂移本质上是由少数极高流量的头部客户端的速率涨落所驱动的 [页码：6]。基于这一核心洞见，作者将流量生成从“全局强行拟合”转向“基于客户端分解的因果建模”，从而开发出高逼真度的 ServeGen 框架，准确暴露真实生产中的系统瓶颈 [页码：6, 11]。

4. 旧方法为何不够

[基于文中逻辑的推断] 已有大模型工作负载分析 and 生成方法在真实系统评测中面临三大局限：一是假设请求数据特征（如长度）与时间无关，忽略了随时间推移的动态漂移规律；二是采用全局重采样或单一随机过程拟合，抹平了客户端之间的异构偏斜；三是缺乏对多模态输入的前置开销和推理模型长时双峰思考行为的机制建模，导致测试负载显著失真，低估了生产环境的延迟压力 [页码：2, 3, 11]。[作者明确陈述] 本文对以下具体已有技术路线与基线进行了深入对比与批判：

1. BurstGPT [46]

- **原本解决的问题**：刻画了大模型推理服务工作负载的突发特性，开源了真实数据集，提出使用参数化 Gamma 过程（一种描述突发流量到达的统计模型）建模到达波动 [页码：4, 13]。
- **依赖的前提或遗留限制**：分析范围仅限于早期大模型，且日志采样时间尺度较小 [页码：4, 13]。
- **本文批判的具体 limit**：(1) 分析规模和模型类型严重受限（仅 4 个月，2 个模型）；(2) 未能捕捉到输入输出长度随时间的动态漂移与多轮对话的到达平缓效应；(3) 完全无法适用于包含前置处理开销的多模态负载和具有长思考特征的 Reasoning 推理负载 [页码：4, 13]。
- **本文对应的回应模块**：**Request Data Sampler (请求数据采样器)** 与 **Client Generator (客户端生成器)**。通过混合分布采样输入输出长度、加入多轮对话轮际时间 (ITT) 约束，以及支持多模态和思考-回答双峰建模的 Client Pool（客户端池）来回应 [页码：11]。
- **检验的比较实验**：表 2 中的时间跨度、模型数量及负载类型规模对比 [页码：4]，以及图 19 中多模态与推理负载的生成准确度对比 [页码：12]。

2. LMM Serving Characterization [38]

- **原本解决的问题**：针对包含图片的多模态大模型服务进行了工作负载的特征分析，旨在揭示图像大模型推理的特点 [页码：4, 13]。
- **依赖的前提或遗留限制**：由于数据收集难度，仅基于 2 天的短时间段日志进行分析 [页码：4, 13]。
- **本文批判的具体 limit**：(1) 规模受限，无法反映中长期流量规律；(2) 没有考虑多模态非文本数据特殊的离散大小聚类分布，未能体现多模态与文本负载独立漂移的规律；(3) 负载生成仍采用静态拼接的 NAIVE 方法 [页码：4, 13]。
- **本文对应的回应模块**：**Request Data Sampler (请求数据采样器)**。其支持多模态非规则 Token 长度采样，并能模拟多模态与文本负载独立漂移的物理规律 [页码：11]。
- **检验的比较实验**：表 2 的表征分析规模对比 [页码：4]；图 19 中多模态 (mm-image) 生成的散点图拟合优度比较 [页码：12]。

3. NAIVE Workload Generation [33, 49, 50, 55]

- **原本解决的问题**：通过静态结合 Poisson 过程（假设请求到达相互独立且均匀发生的经典过程）与 ShareGPT 开源数据集，快速产生大模型系统的测试负载 [页码：2, 11]。
- **依赖的前提或遗留限制**：假设请求到达是均匀或简单的分布，且数据长度与到达时间完全独立 [页码：2, 11]。
- **本文批判的具体 limit**：严重低估了生产负载真实的突发性与客户端偏斜特征，导致测试负载失真（看起来比实际更容易被系统处理）；在实例资源配置规划中低估高达 50% 的资源配置需求，并在评估新型推理架构（如前填充与解码分离架构）时，会由于无法模拟瞬时排队阻塞而得出错误的架构配比结论 [页码：2, 12, 13]。
- **本文对应的回应模块**：**Client Generator (客户端生成器)** 与 **Timestamp Sampler (时间戳采样器)**。前者通过保留真实的客户端偏斜比例，模拟头部客户端的主导效应；后者为各客户端独立生成时间戳，以复现宏观负载的动态漂移 [页码：11]。
- **检验的比较实验**：实例资源配置热力图中的过度/不足备货百分比对比（图 20） [页码：12]，以及 SGLang 引擎上 PD 分离架构在不同配置配比下的 SLO 达成率测试（图 21） [页码：12, 13]。

5. 核心洞见与假设

[作者明确陈述] 本文的核心洞见是**基于客户端分解的因果建模假设**。虽然在宏观尺度上，大模型服务的整体工作负载呈现出高度无序、高突发且特征独立漂移的现象，但一旦将流量解耦到每个独立的客户端（即具体的上游租户或用户），除发送速率外的其他行为

特征（如突发度、输入输出长度分布）在客户端内都是高度稳定且可预测的。整体负载的动态漂移本质上是由极少数头部客户端的速率涨落所驱动的结果 [页码：6]。

[基于文中逻辑的推断] 为落地上述洞见，系统设计了以下三个非核心洞见本身的**实现组件**：

1. **Client Generator (客户端生成器)**：负责模拟生产环境中的客户端异构性，从 Client Pool（客户端池）中提取偏斜的客户端参数 [页码：11]；
 2. **Timestamp Sampler (时间戳采样器)**：利用参数化时间函数，为每个客户端独立采样并合并请求时间戳 [页码：11]；
 3. **Request Data Sampler (请求数据采样器)**：负责时变特征的模拟，以及多模态与推理模型中特殊长度分布的采样 [页码：11]。
- [实验支持] 作者基于百炼平台真实日志的分析支撑了这一因果建模假设的可行性：数据显示仅头部 1.2% 的高频客户端就贡献了全局 90% 的请求流量，且它们的速率起伏解释了整体负载宏观特征的变化原因 [页码：6]。[基于文中逻辑的推断] 该假设依赖的前提是：每个独立客户端的内部行为属性（如输入和输出的长度统计特性）在时间上具备中长期的相对稳定性。这一前提在以下场景可能会失效：
- **流量去中心化场景**：若系统接收的请求均来自离散且无分级、无倾斜的单一类型用户，缺少明显的头部客户端主导效应 [页码：11]；
 - **客户端行为突变场景**：若客户端所服务的业务逻辑发生瞬时切换（如突发性的社会热点事件导致用户查询习惯在短时间内产生剧烈非平稳改变），此时基于历史画像预测的行为属性将会失真。

6. 方法：从洞见到可执行系统

[作者明确陈述] ServeGen 框架的工作流程总览为：输入目标客户端数量与全局请求速率，系统在内部通过提取真实特征或用户自定义的方式配置客户端画像，并针对每个客户端生成独立的请求时间戳和多维度请求数据长度，最终融合成一份包含精确时间戳、模型类型、输入/输出 Token 长度及前置处理参数的生产级逼真工作负载轨迹文件（Workload Trace），输入到下游的模型推理引擎（如 vLLM 或 SGLang）中进行评测 [页码：11, 12]。

该系统通过以下三个主要模块协同运行：

1. 客户端生成器 (Client Generator)

- **解决的遗留挑战 (动机)**：以往方法采用全局重采样，抹平了生产环境中由不同上游应用所代表的客户端之间高度异构且倾斜（头部效应明显）的分布特征 [页码：2, 11]。
- **如何运行**：输入目标客户端总数与全局目标流量速率，系统从包含真实客户端速率、突发度变异系数（CV）特征的 **Client Pool (客户端池)** 中进行采样（或由用户自定义指定参数），输出由多个异构客户端组成的画像配置 [页码：11]。
- **预期技术优势**：[基于文中逻辑的推断] 完整保留了真实客户端的倾斜比例，从而能够在后续的生成中忠实重现由头部高流量客户端所主导的瞬时负载尖峰。
- **与前后模块的连接**：[基于文中逻辑的推断] 输出的客户端画像配置被直接传递给**时间戳采样器**和**请求数据采样器**，用作其行为建模的控制参数。

2. 时间戳采样器 (Timestamp Sampler)

- **解决的遗留挑战 (动机)**：全局请求流量的到达存在日夜周期变化，且在短时间内呈现高突发和非静止性，使用单一经典的指数分布无法在所有时间段和工作负载中实现良好拟合 [页码：5, 11]。
- **如何运行**：输入各客户端画像的速率及 CV。系统首先将客户端发送速率表示为含时间参数 t 的函数以模拟日夜漂移；随后为每个客户端指定专属的概率分布（如 Gamma 分布或 Weibull 分布），独立生成其请求的时间戳序列；最后将所有客户端的时间戳序列合并并按时间顺序进行重排序，输出全局的请求时间序列 [页码：11]。
- **预期技术优势**：[基于文中逻辑的推断] 通过独立客户端时间戳的叠加，自然模拟出宏观流量中平缓期与短时突发交替出现的特征，而无需强行用复杂的全局统一分布进行拟合。
- **与前后模块的连接**：[基于文中逻辑的推断] 接收**客户端生成器**的画像，输出按时间排序的全局时间戳序列并输入给**请求数据采样器**。

3. 请求数据采样器 (Request Data Sampler)

- **解决的遗留挑战 (动机)**：大模型的输入输出长度在时间上存在独立的动态漂移，且多模态模型（离散块大小）和推理模型（思考/回答双峰分布）的 Token 长度表现出特殊的统计学分布，这是以往纯文本静态拼接所无法模拟的 [页码：3, 4, 11]。
- **如何运行**：接收合并后的全局时间戳序列。系统利用混合 Pareto 分布和对数正态（Log-normal）分布采样输入 Token 长度，使用指数分布采样输出 Token 长度，并让均值参数随时间 t 独立漂移；对于多模态请求，其非文本模态 Token 长度通过匹配真实生产中的离散聚类大小进行采样；对于推理大模型，系统进行多轮对话感知建模（遵循约 100 秒的轮际时间 ITT 限制），并对思考和回答 Token 比例进行双峰分布采样 [页码：7, 9, 10, 11]。最终输出包含了完整请求元数据的负载轨迹 [页码：11]。
- **预期技术优势**：[基于文中逻辑的推断] 能够精准复现多模态图像/视频的前置预处理耗时（由于采用了物理大小离散采样），并复现推理模型特有的长思考带来的大计算量和解码显存占用，从而精确反应系统队列中的队头阻塞情况。
- **与前后模块的连接**：[基于文中逻辑的推断] 接收**时间戳采样器**生成的请求时间序列，并最终输出生成的文件供推理服务系统（Serving Systems）读取执行。

7. 为什么它可能有效

[基于文中逻辑的推断] ServeGen 能够有效生成逼真负载并指导系统优化的内在因果机制包括：

1. **客户端异构倾斜生成机制**

- **预期收益**：通过在 Client Generator 中保留少数头部客户端贡献大部分流量的重尾分布特征，能够在合成负载中精确复现全局流量在短时间窗口内的突发峰值，避免因采用均匀随机分布而低估资源配置需求 [页码：6, 11]。
 - **需要的条件**：生产环境中实际服务的主力客户端分布确实存在显著的头部倾斜，且 Client Pool 中的统计画像具有足够的行业代表性 [页码：6]。
2. **客户端独立时间戳生成与多路合并机制**
- **预期收益**：由于把含时间参数的变异速率解耦到独立的客户端并为各客户端匹配最佳到达分布（如 Gamma 或 Weibull），合并后的全局请求到达时间序列能够自然涌现出宏观上的日夜交替与局部高突发状态，极大提升到达速率建模的拟合优度 [页码：5, 11]。
 - **需要的条件**：每个客户端 of 内部到达规律在中短期内是相对平稳的，且系统在合并时间戳时具有高并发的处理效率 [页码：6, 11]。
3. **输入输出长度独立漂移与多模态/推理特殊分布建模机制**
- **预期收益**：在 Request Data Sampler 中引入了输入和输出长度随时间独立的均值偏移，并针对性地对多模态的离散 Token 长度以及推理大模型的思考-回答双峰比例进行采样。这能使生成的负载在执行时，精准复现由于多模态前置处理引起的“预处理排队阻塞”和长思考造成的“解码时段显存过载”，从而测试出真实的系统延迟瓶颈 [页码：8, 9, 11]。
 - **需要的条件**：下游推理引擎（如 SGLang、vLLM）必须部署有对应的物理前置处理组件和自回归解码逻辑，以使得 Token 长度特征能被真实转化为计算和 IO 延迟 [页码：12]。

8. 实验与指标：证据是否支撑主张

[作者明确陈述] 本文的研究通过对真实生产日志的特征刻画与系统级运行测试，论证了 ServeGen 负载生成框架的有效性 [页码：4, 12]。

- **研究问题**：合成工作负载是否能完美拟合生产环境在时间戳到达、Token 长度及特殊模型行为上的多维统计特征？在真实的资源规划和推理系统架构评测中，ServeGen 能否克服 NAIVE 方法的失真问题，输出正确的性能决策？ [页码：11, 12]
- **数据集与划分**：数据集源自阿里云百炼平台 12 种模型、横跨 4 个月的真实生产日志，包含 35.4 亿次请求 [页码：4]。具体的训练集、验证集或测试集划分细节在文中未说明。
- **对比基线**：以传统的 **NAIVE Workload Generation** 方法（使用静态 Poisson 过程与 ShareGPT 数据集进行拼接）作为主要对比基线 [页码：11]。
- **指标含义**：
 - **TTFT (首字响应时间)**：指从请求发出到模型吐出第一个字之间的总时间，包含前置下载、特征编码和预填充阶段 [页码：3]；
 - **TBT (字间延迟)**：自回归生成过程中相邻两个 Token 之间的平均生成延迟 [页码：12]；
 - **SLO (服务等级目标) 达成率**：在满足指定延迟门槛（如 $TTFT \leq 2.25\text{ s}$, $TBT \leq 0.5\text{ s}$ ）的请求所占的比例 [页码：12]；
 - **CV (变异系数)**：用于刻画到达率或长度波动的剧烈程度，其公式为标准差除以均值 [页码：5]；
 - **过度/不足备货百分比 (Over/Under Provisioning)**：评估资源配置与真实需求之间的偏差比例 [页码：12]。
- **实现设置**：
 - 实例资源规划实验：在 vLLM 推理引擎上运行 Qwen2.5-14B 模型 [页码：12]；
 - 前填充与解码分离架构评测：在 SGLang 高性能引擎上运行 Qwen2.5-72B 模型 [页码：12]。
- **主结果**：
 - [实验支持] 在实例规划中，NAIVE 负载评估出的最佳实例数仅为 12 个（低估了 50% 资源），会导致实际服务崩溃；而 ServeGen 建议配置 25 个实例，相比实际需求仅有 4% 的安全冗余，更为逼真可靠 [页码：12]。
 - [实验支持] 在 PD 分离架构中，NAIVE 负载将 2P6D（2 预填充，6 解码实例）评测为性能最差的配置之一；而在 ServeGen 负载下，2P6D 反而是多项指标下的最佳配置。这证明 ServeGen 成功复现了由于长尾大请求引发解码过载的真实场景，防止了架构的错误设计倾向 [页码：12, 13]。
- **消融/敏感性实验**：关于核心模块（Client Generator、Timestamp Sampler、Request Data Sampler）的消融与参数敏感性分析的具体细节，在文中未说明。

比较工作与被批判限制的呼应

比较工作/基线	它试图解决的问题或优势	本文指出的具体 limit/失效条件	本文的对应模块	实际比较实验、指标和结果	仍未验证的边界
BurstGPT [46]	刻画大模型推理的突发特性，提出 Gamma 过程建模到达波动 [页码：4, 13]。	样本量与模型类型少；未捕捉长度动态漂移与多轮对话平缓效应；不支持多模态与推理大模型 [页码：4, 13]。	Request Data Sampler 与 Client Generator [页码：11]。	表 2 规模对比；图 19 中多模态与推理负载的生成准确度对比 [页码：4, 12]。	比较结果仅限于论文的实验设置内，未在其他大模型版本上测试 [基于文中逻辑的推断]。

LMM Serving Characterization [38]	多模态大模型服务的工作负载特征分析 [页码：4, 13]。	数据采样跨度极短 (仅 2 天)；忽略了多模态非文本数据特殊的离散大小聚类分布 [页码：4, 13]。	Request Data Sampler 的多模态非规则 Token 长度采样 [页码：11]。	表 2 的 Characterization Scale 对比；图 19 中多模态生成的散点图拟合优度 [页码：4, 12]。	未针对高吞吐离线多模态批处理任务进行对比测试 [基于文中逻辑的推断]。
NAIVE Workload Generation	使用 Poisson 到达与 ShareGPT 快速产生基准测试负载 [页码：2, 11]。	抹平客户端异构倾斜；低估 50% 的资源需求；得出相反的 PD 分离架构最优配比结论 [页码：2, 12, 13]。	Client Generator 与 Timestamp Sampler [页码：11]。	实例规划过度/不足备货百分比 (图 20)；PD 架构不同配比下的 SLO 达成率 (图 21) [页码：12, 13]。	无法模拟包含具体文本语义的前缀缓存命中率变化 [页码：13]。

主张地图与证据计划

主张	对应实验/表图	直接证据	证据强度	尚未覆盖的条件
1. 真实请求到达具有短期突发性且无单一经典随机过程能完美建模	Figure 2 (图片 1) [页码：5]	真实负载的 $CV > 1$ ；KS 检验中无任一分布在所有负载中一致获得最高 p-value [页码：5]。	强 (基于百炼平台真实日志大样本的假设检验) [页码：4, 5]	缺乏在其他云厂商或更长/短采样窗口下的 KS 检验 [基于文中逻辑的推断]。
2. 输入长度服从混合分布,输出符合指数分布,且均值随时间独立漂移	Figure 3 & 4 (图片 2) [页码：5, 6]	混合分布在尾部重合良好,输出适合指数拟合；不同时段的输入与输出长度均值呈独立反向位移 [页码：5, 6]。	强 (有明确的时变特征拟合优度曲线支持) [页码：5, 6]	缺乏在特定系统提示词或输出格式约束 (如 JSON) 下的测试 [基于文中逻辑的推断]。
3. 宏观负载的突发性与漂移可完全解耦为极少数头部客户端速率的起落	Finding 5 [页码：6]	头部 1.2% 的高频客户端贡献了 90% 的请求,且速率起落决定全局特征 [页码：6]。	中 (仅有正文 Finding 结论,缺乏其他大流量规格负载的 CDF 曲线) [基于文中逻辑的推断]	仅在 M-small 负载下进行了具体分析,尚未覆盖其他规模负载 [基于文中逻辑的推断]。
4. 多模态请求的前置下载和特征编码构成了严重的 TTFT 长尾延迟	Finding 6 & 7 [页码：8]	mm-image 负载中,50% 的请求在进入预填充前已消耗了 75% 的 TTFT 用于前置预处理 [页码：8]。	强 (有具体的预处理延迟开销比重数据支持) [页码：8, 9]	未测试在不同网络带宽和不同图像编码器规格下的延迟变化 [基于文中逻辑的推断]。
5. 推理大模型思考-回答呈双峰分布,且到达速率突发度偏低	Finding 9 & 10 [页码：9, 10]	思考 token 是回答的 4 倍且比例呈双峰；多轮对话占比 10% 且存在轮际时间 ITT 限制,使 $CV \leq 1$ [页码：9, 10]。	强 (有明确的 ITT 概率分布及思考占比双峰统计) [页码：9, 10]	仅测试了特定模型 (DeepSeek-R1), 未涉及其他推理模型 (如 o1) [基于文中逻辑的推断]。
6. ServeGen 能比 NAIVE 更准确地指导资源配置和 PD 架构最优配比	Figure 20 & 21 [页码：12, 13]	NAIVE 低估 50% 资源,且误判最优架构配比；ServeGen 与实际需求仅偏差 4% 并成功预测 2P6D 的优势 [页码：12, 13]。	强 (在主流引擎 vLLM 和 SGLang 上运行 Qwen2.5 进行了实测) [页码：12, 13]	尚未在 TensorRT-LLM 等其他主流推理引擎上进行验证 [基于文中逻辑的推断]。

9. 图表解读与论证关系




Figure 1. Inter-arrival time characterization.

来源：OCR 第 5 页。

图像解读 验证问题：不同大语言模型推理工作负载中，短期请求到达是否表现出明显的突发性（变异系数 $CV > 1$ ）？是否存在能统一适配所有工作负载的单一经典随机分布？

直接结论：所有工作负载的变异系数均大于 1（M-large 为 1.29，M-small 为 1.12，M-mid 为 1.07），实际请求流量短期内均具突发性；实际到达间隔频率曲线在极小到达间隔处偏高，指数分布与其存在明显偏离，而 Gamma 和 Weibull 贴合度更好；在 KS 假设检验中，没有任何一个分布能够在所有三个工作负载中一致地获得最高的 p-value。

设计含义：不能简单采用传统基准测试中单一的泊松过程（指数分布）或固定某种分布来生成所有请求到达时间，这直接支撑了 ServeGen 中的 Timestamp Sampler 设计，必须允许为各个客户端或工作负载灵活配置不同的随机分布。

如何阅读：在 Panel 1-3 中，对比 Actual（绿色实线）与各拟合曲线（Expon, Gamma, Weibull）的重合度，并查看图中的 cv 数值；在 Panel 4 中，通过比较不同工作负载下各分布柱状条的高度（p-value 大小）来评估拟合优度，p-value 越大表示拟合越好。

适用范围与证据缺口：无额外证据缺口。




Figure 2. Long-term rate and CV shifts.

来源：OCR 第 5 页。

图像解读 验证问题：真实生产环境下不同模型的工作负载在长短周期内是否存在剧烈且不一致的速率与 CV 波动，以说明系统设计和负载生成器必须具备时变自适应建模能力。

直接结论：M-small 和 M-large 呈现明显的周内日夜周期波动，M-small 峰值接近 1000 req/s；M-code 在日内波动极度剧烈，下午出现双峰（峰值破 1000 req/s），而 M-rp 速率极低且平缓；M-large 的 CV 存在阶段性漂移，在周一至周二期间处于 1.3 至 1.6 的高突发状态，而周四至周五回落至约 1.0；M-code 一日之内 CV 在 17 时左右突现约 1.3 的局部尖峰，而 M-rp 几乎恒等于 1.0。

设计含义：日夜速率的剧烈波动证明推理系统必须设计有自动扩缩容（Auto-scaling）机制；CV 的时变漂移表明需要开发对突发度自适应的请求调度算法；这促使 ServeGen 将客户端速率和总到达率建模为时间 t 的参数化函数，并通过 Client Pool 采样保留不同类型客户端的异构偏斜。

如何阅读：左侧两子图 x 轴为星期（Mon. 到 Sun.，每格代表一天）；右侧两子图 x 轴为一天的小时（0 - 24）。第一行子图 y 轴为 Rate (req/s)；第二行子图 y 轴为 CV。通过上方图例，对比左列的 M-small（蓝）与 M-large（红）的周级日夜周期变化，以及右列 M-code（橙）与 M-rp（紫）的日内波动差异。

适用范围与证据缺口：本证据覆盖对阿里云生产集群收集的 M-large、M-small、M-code 与 M-rp 工作负载计算速率和变异系数（CV）的分析。具体数据对应的具体日历日期在正文与图表中均未给出。




Figure 3. Input and output length distribution. x-axis: # tokens; y-axis: frequency. Each subfigure corresponds to a specific workload and time period, split to two consecutive x-scales to show both the shift in average lengths (left) as well as the tail distribution (right).

来源：OCR 第 6 页。

图像解读 验证问题：大模型请求的输入长度和输出长度分别服从什么统计分布？它们之间是否具有相关性？输入和输出长度的分布随时间（日夜变化）如何漂移，是否是独立的？

直接结论：输入长度分布曲线呈现长尾，Pareto 与 Log-normal 混合拟合曲线在尾部与实际数据重合良好；大多数负载的输出长度分布能够由指数分布较好地拟合；输入和输出的长度均值在独立发生时变漂移（例如，M-mid 的输入均值从 990 增加到 1122，而输出均值从 235 下降到 192）；输入长度和输出长度之间的关联性较弱，中位数基本保持在较低水平且相对平缓。

设计含义：不能把输入输出长度作为静态常数，也不能把它们绑定为强相关的比率。这直接指导了 ServeGen 中的 Request Data Sampler 模块设计：该模块需要根据不同时间段 t 的概率分布分别采样输入和输出长度，并在多模态和推理模型中针对性地建立非文本 Token 分布及思考/回答双峰分布。

如何阅读：左侧 Figure 3 中，x 轴是 Token 数量，每图被垂直黑线划分为左右两个 x 轴刻度，左半显示平均长度分布，右半显示尾部长度分布；y 轴是频率（对数刻度）。蓝色/紫色为输入，橙色为输出。右侧 Figure 4 中，x 轴是输入长度，y 轴是输出长度，蓝色阴影为 90% 分位数区间，橙色虚线代表中位数。

适用范围与证据缺口：无额外证据缺口。

10. 完整因果推理树

- **根问题：**缺乏对真实生产环境下大模型推理服务工作负载的大规模、全维度特征刻画，导致性能评测负载失真并误导系统设计 [页码：2]。
 - **旧方法限制：**主流 NAIVE 方法使用静态 Poisson 过程并拼接开源数据集，抹平了客户端异构性，且无法模拟数据长度的独立漂移、多模态前置开销和推理模型长时思考，低估了 50% 的资源配置需求 [页码：2, 11]。
 - **核心洞见/假设：**虽然宏观流量无序多变，但解耦到独立租户后其行为高度稳定且可预测；全局的突发与漂移本质上是由少数极高流量的头部客户端的速率涨落所驱动的 [页码：6]。
 - **方法模块一：Client Generator (客户端生成器)**，根据偏斜的真实比例采样生成异构的客户端画像 [页码：11]。
 - **可验证预测：**生成的合成负载能够复现真实流量中各客户端的流量倾斜度和 CV 异构偏斜 [页码：11]。
 - **指标与实验：**客户端级流量占比与 CV 的 CDF 曲线对比实验 [页码：11]。
 - **图表证据：**文中未说明（未在已分析的图表中直接展示，由正文 Finding 5 支撑） [页码：6]。
 - **结论与适用边界：**能够还原多租户 SaaS 平台中的头部主导特征；但在缺乏客户端分级的单租户内网场景中收益有限 [基于文中逻辑的推断]。
 - **方法模块二：Timestamp Sampler (时间戳采样器)**，为各客户端选用专属的随机分布独立产生时间序列并多路合并 [页码：11]。
 - **可验证预测：**合并后的请求序列能够复现真实宏观流量中短时高突发 ($CV > 1$) 与长时日夜周期波动 [页码：11]。
 - **指标与实验：**生成负载与真实负载的总体到达速率及不同时间窗内 CV 的漂移趋势对比 [页码：11, 12]。
 - **图表证据：**图 19（生成负载与真实负载的总体速率散点图拟合） [页码：12]。
 - **结论与适用边界：**能高逼真地复现全局到达规律；但在遭遇突发社会热点导致客户端自身到达规律突变时会存在预测偏差 [基于文中逻辑的推断]。
 - **方法模块三：Request Data Sampler (请求数据采样器)**，对输入输出长度引入时变独立漂移，并针对多模态与推理模型的特征分别建立离散聚类和双峰思考-回答采样 [页码：11]。
 - **可验证预测：**生成的负载能在实际系统评测中引发与真实负载一致的排队阻塞和解码载荷，从而给出正确的部署和架构配置决策 [页码：12]。
 - **指标与实验：**在 vLLM（运行 Qwen2.5-72B）上测试不同 SLO 门槛下的资源规划；在 SGLang（运行 Qwen2.5-72B）上评估 PD 分离架构在不同 prefill/decoding 配比下的 SLO 达成率 [页码：12]。
 - **图表证据：**图 20（资源规划热力图）与图 21（PD 架构配比性能图） [页码：12, 13]。
 - **结论与适用边界：**在 vLLM 上将资源低估误差从 NAIVE 方法的 50% 降低至 ServeGen 的 4%，在 SGLang 上准确挑选出 2P6D 的最优配置 [页码：12, 13]；适用边界为脱敏日志导致生成的负载无法直接用于测试依赖前缀缓存（Prefix Caching）的技术 [页码：13]。

11. 结论、贡献与边界

贡献总结

1. **全维度的生产级工作负载特征刻画**：基于阿里云百炼平台跨越 4 个月、总计 35.4 亿次请求的生产日志，首次对大模型推理服务中涵盖纯文本、新兴多模态以及推理模型的整体流量进行了系统分析 [页码：4]；
2. **因果建模生成框架 ServeGen**：首次提出了通过“客户端分解”方法将复杂全局流量拆解为独立稳定客户端画像进行建模的负载生成框架，并开源了代码 [页码：2, 3]；
3. **真实推理系统的有效性验证**：在 vLLM 与 SGLang 高性能模型推理引擎上进行实测，证明该框架在配置服务器实例资源和优化前填充-解码分离架构配比方面的显著评测收益 [页码：12, 13]。

证据充分的结论

- 真实大模型的短期请求到达表现出明显的突发性 ($CV > 1$)，单一的指数、Gamma 或 Weibull 随机分布无法一致、完美地对其进行拟合 [页码：5]；
- 请求的输入长度符合 Pareto 与 Log-normal 的混合分布，输出长度除极少例外符合指数分布，且两者的均值随时间段独立漂移，彼此相关性微弱 [页码：5, 6]；
- 阿里云百炼平台具有显著的客户端流量倾斜，仅 1.2% 的头部客户端贡献了 90% 的全局请求，头部客户端的速率起落决定了全局流量特征 [页码：6]；
- 多模态前置预处理（下载与特征编码）是导致首字响应延迟（TTFT）延长的主要元凶（消耗了 mm-image 负载中 50% 请求的 75% 的 TTFT 时间） [页码：8]；
- 在资源规划评测中，ServeGen 给出的配置推荐（25 个实例）相比传统 NAIVE 方法（12 个实例）避免了低估 50% 资源导致系统崩溃的严重失真 [页码：12]。

尚属推断的意义

- [基于文中逻辑的推断] 采用基于客户端异构特征的负载生成方案，能够大幅提高云计算服务商对大模型推理服务节点进行动态扩容（Auto-scaling）和精细化资源调度的准确度，长远来看能够有效减少数据中心的能源浪费并提升系统吞吐量。

适用条件

- 适用于多租户 SaaS 平台、并发量大且对请求响应延迟（如 TTFT 和 TBT）有严苛服务水平协议（SLO）约束的大模型在线推理服务系统的基准评测 [基于文中逻辑的推断][页码：2, 12]。

局限

- **无文本语义细节**：由于商业隐私脱敏，日志去除了具体的文本字符，使得 ServeGen 无法统计公共提示词的重复率，因而不支持对前缀缓存（Prefix Caching）技术的大范围评测 [页码：13]；
- **缺乏长周期演进分析**：数据跨度仅 4 个月，对长达数年的租户行为变迁、技术更迭等长期纵向演进趋势表征不足 [页码：13]；
- **未刻画复杂的代理生命周期**：未模拟包含插件调用（Plugin Calls）等复杂控制流的大模型代理（Agent）生命周期 [页码：13]。

下一步验证

- 在负载生成器中增加脱敏语义的概率模拟，以支持对前缀缓存性能的间接评测 [页码：13]；
- 扩展日志数据采集的时间尺度至一年以上，以捕捉长期纵向演进规律 [页码：13]；
- 在 TensorRT-LLM 等更多主流引擎上验证该负载在不同并行机制下的适配表现 [基于文中逻辑的推断]。

审稿式风险检查

- **贡献新意**：当前证据未显示该风险。论文在特征分析的广度（多模态与推理模型）以及生成方法上均属业内首次，显著突破了 BurstGPT 等仅考虑早期纯文本模型的研究限制 [页码：4]。
- **写作/可复现性**：存在中等风险。尽管代码开源，但由于研究核心所依赖的 35.4 亿次生产请求日志涉及阿里云的核心商业机密而无法公开，导致其他学术团队难以在相同的原始生产数据上进行实验复现与扩展研究 [页码：4, 13]。
- **效果大小**：当前证据未显示该风险。在 vLLM 上进行的实例资源规划实验中，ServeGen 实现了极大的精度改善（资源偏离度从 50% 纠正至 4%），其效果在系统工程层面上是非常显著且有实际指导意义的 [页码：12]。
- **实验覆盖**：存在轻微风险。论文的系统评测实验主要围绕 Qwen2.5 系列模型进行，未展示在其他流行开源模型（如 Llama 3）或不同显卡硬件架构下的泛化评测结果，且当前 OCR 内容缺失核心模块的细粒度消融实验数据 [页码：12]。
- **方法设计**：存在轻微风险。忽略请求的文本语义内容使其在面对高度依赖“前缀缓存（Prefix Caching）”优化的现代推理系统时会产生评估盲区，这限制了其在某些特定优化技术评测中的适用范围 [页码：13]。

12. 面向初学者的学习路径

1. **大语言模型在线推理服务 (Online Inference Serving)**：指将已经训练好的大模型部署在云端，并实时接收、响应用户聊天或提问请求的物理过程。它是理解大模型系统工作负载的起点。
2. **首字响应时间 (TTFT) 与字间延迟 (TBT)**：TTFT 表示从用户发送请求到模型在屏幕上吐出第一个字的耗时，TBT 表示后续生成中相邻两个字之间的平均间隔。它们是评估推理系统优劣最核心的两个延迟性能指标。
3. **变异系数 (CV)**：一种衡量数据离散和波动剧烈程度的统计学指标（标准差除以均值）。在流量分析中，它是衡量请求到达是否忽高忽低、具有高度突发性的核心工具。

4. **前填充与解码分离架构 (PD-Disaggregation)**：将推理的预填充阶段（算力密集型，一次算大量提示词）与解码阶段（显存带宽密集型，逐字自回归吐出）拆开，部署在不同硬件资源上运行的架构。它是本论文用于验证 ServeGen 能否指导新型复杂引擎部署的关键背景。
5. **客户端分解 (Client Deconstruction)**：把全局看似混乱的宏观流量，拆解到每一个具体上游租户或客户端维度进行属性画像剖析的思路。它是理解本论文如何利用因果建模高逼真度生成工作负载的核心钥匙。