

论文解构报告

ServeGen: Workload Characterization and Generation of Large Language Model Serving in Production

Yuxing Xiang, Xue Li, Kun Qian, Yan Zhang, Wenyan Yu, Ennan Zhai, Xin Jin, Jingren Zhou

23rd USENIX Symposium on Networked Systems Design and Implementation (NSDI '26) · 2026

LLM 推理服务

工作负载表征

工作负载生成

生产环境追踪

多模态与推理模型

代码: <https://github.com/alibaba/ServeGen>

生成时间: 2026-07-29

目录

摘要翻译	3
1. 一句话总览	3
2. 阅读范围与证据状态	3
3. 根问题：论文究竟要解决什么	3
4. 旧方法为何不够	5
5. 核心洞见与假设	5
6. 方法：从洞见到可执行系统	5
7. 为什么它可能有效	6
8. 实验与指标：证据是否支撑主张	6
9. 图表解读与论证关系	7
10. 完整因果推理树	11
11. 结论、贡献与边界	11
12. 术语与第一性原理学习路径	12

摘要翻译

随着大语言模型（LLM）的广泛采用，为 LLM 推理请求提供服务已成为一项日益重要的任务，吸引了大量研究进展。实际工作负载在这一过程中发挥着关键作用：它们对于激励和评测服务技术与系统至关重要。然而，由于缺乏全面的工作负载表征，业界对真实世界 LLM 服务工作负载的理解仍然有限。已有分析在规模和范围上均显不足，未能充分捕捉复杂的工作负载特征。本文通过对来自我们全球云 LLM 服务的工作负载进行深入表征来填补这一空白，不仅涵盖语言模型，还涵盖新兴的多模态和推理模型，在每种情形下都揭示了重要的新发现。此外，基于这些发现，我们提出了 ServeGen——一个通过按客户端组合来生成真实 LLM 服务工作负载的原则性框架。实际应用案例验证了，相较于朴素的工作负载生成方法，ServeGen 能够实现更准确的性能评测，并揭示出若干原本可能被忽视的新设计启示。ServeGen 已开源，地址为 <https://github.com/alibaba/ServeGen>。

1. 一句话总览

论文元数据

字段	内容
标题	ServeGen: Workload Characterization and Generation of Large Language Model Serving in Production
作者	Yuxing Xiang, Xue Li, Kun Qian, Yan Zhang, Wenyuan Yu, Ennan Zhai, Xin Jin, Jingren Zhou
发表场所 / 年份	23rd USENIX Symposium on Networked Systems Design and Implementation (NSDI '26), 2026
研究领域	计算机系统（LLM 推理服务）
关键词	LLM 推理服务, 工作负载表征, 工作负载生成, 生产环境追踪, 多模态与推理模型

资源链接

- 原始文件：本地上传文件（无外部链接）
- arXiv：文中未说明
- DOI：文中未说明
- 代码 / 数据集：<https://github.com/alibaba/ServeGen>

标签（3-5 个）： LLM 推理服务 · 工作负载刻画 · 负载生成 · 客户端因果建模 · PD 分离评测

本文基于阿里云 Model Studio 生产环境四个月、超 35 亿条请求的真实调用日志，对语言、多模态、推理三类大模型服务负载做了迄今规模最大的实证刻画，并提出以"客户端"为基本建模单位的负载生成框架 ServeGen，其在实例配置与 PD 分离评测中比朴素生成方法（NAIVE）更贴近真实系统表现 [作者明确陈述](#)。

2. 阅读范围与证据状态

OCR 文本覆盖论文第 2-13 页的正文论述，含 Findings 1-11 的文字表述及方法、实验、局限章节；图表证据分析覆盖第 5-9 页共约 12 组图片（部分图注文字或坐标刻度因像素/裁剪限制无法逐一核实精确数值），另有 8 张图片因超出处理上限未做视觉分析 [\[文中未说明, OCR 提示信息\]](#)。KS 检验 p 值、CV 计算公式等标准统计量的计算式，论文本身未显式列出，只标注了判定基准或方法名 [\[文中未说明\]](#)。以下论文事实均标注证据类型，区别于本文补充的背景知识（如 prefill/decoding、Zipf 分布等通识性解释）。

3. 根问题：论文究竟要解决什么

- **问题定义：** LLM 推理服务系统的设计、优化与评测都依赖"负载（workload，即请求的到达节奏与输入输出长度分布等统计特征）"，但业界对真实生产负载的理解严重不足，缺乏全面的规模化刻画 [作者明确陈述](#)。
- **为什么重要：** 负载理解不足会同时损害"研究动机来源"与"评测可信度"——新兴的多模态、推理模型场景的许多特性从未被刻画过，研究者可能错失创新方向；而对于研究较多的普通语言模型场景，使用不真实的负载评测系统（论文称为 NAIVE：泊松/伽马过程采样到达 + ShareGPT 等公开数据集），会导致"看起来很好用"的系统上线后表现骤降，论文引用了已有文献报道的这类真实劣化案例 [作者明确陈述](#)。
- **难点来源：** 真实生产负载规模巨大、跨客户端异质、随时间漂移，采集与规模化分析本身需要长期、大范围的生产环境访问权限，这是既有研究（多为局部、短期分析）难以做到的 [\[基于文中逻辑的推断, 依据 Table 2 对比结构\]](#)。
- **本文的 story：** 旧路线在"规模不足"与"把负载当整体随机过程建模"两个技术原因上失效，本文的转折点是发现真实负载的复杂性可归约为"少数头部客户端的行为波动"，并据此把生成负载的最小单元从"全局分布"下沉到"客户端"。




Figure 7. Characterization of multimodal inputs in mm-image, mm-audio, and mm-video (Rows). Columns: (a) #multimodal inputs per request; (b) length distribution of inputs; (c) correlation between text and multimodal tokens; (d) overall arrival rate of multimodal and text tokens.

图组解读

- **图组结论：**多模态输入长度呈多峰非幂律形态，且不同时段分布存在可见偏移。
- **论证关系：**支撑 Finding 6，说明模态负载无法用文本长度替代，需独立参数化。
- **适用范围：**覆盖三种多模态负载，个别子图时间段标签较模糊。




Figure 8. Characterization of omni-modal inputs in mm-omni. Left: number of multimodal inputs per request. Right: arrival rate of multimodal and text tokens, normalized by the total input rate.

图组解读

- **图组结论：**全模态请求单请求携带多模态输入数多，模态间到达速率呈现差异化时序漂移。
- **论证关系：**支撑 Finding 6，说明当请求混合多种模态时负载变异性进一步复杂化。
- **适用范围：**仅覆盖 mm-omni 工作负载，部分曲线图例缺失模糊。

4. 旧方法为何不够

这些旧方法的共同技术局限可归纳为：要么在"规模"（时长、请求数、模型数）上不足，要么在"范围"（多模态/推理/客户端异质性/时序漂移）上不足 **基于文中逻辑的推断**。

NAIVE ([33,49,50,55])

前提：在无真实负载或隐私限制下简便生成评测负载。假设到达可用泊松/伽马过程近似、数据可用公开对话数据集替代。

本文指出的失效点
生成负载变异性不足、无法体现速率与数据分布的相关性，产生"虚假易服务"假象。

→

本文对应模块
Client Generator + Timestamp/Request Data Sampler

检验：§ 6.2 生成精度对比、§ 6.3 实例配置案例

BurstGPT [46]

前提：用参数化 Gamma 过程刻画到达突发性。仅 2 个模型、529 万请求、仅语言模态。

本文指出的失效点
规模远小于本文，且不覆盖多模态/推理/客户端分解。

→

本文对应模块
本文整体三类负载刻画+客户端分解方法学

检验：无法从当前 OCR 内容确认具体对比实验，仅 Table 2 范围对比

LMM [38]

前提：刻画图文模型的图像数据分布。仅 2 天数据，单一模态维度。

本文指出的失效点
缺失到达模式、漂移、对话等维度。

→

本文对应模块
本文多模态刻画（§ 4）

检验：无法从当前 OCR 内容确认，仅范围对比

5. 核心洞见与假设

核心洞见/贡献：真实负载中看似复杂的非确定性模式（到达突发性波动、长度分布随时间漂移）并非"整体随机过程"的产物，而是由少数"头部客户端"的行为波动驱动；绝大多数客户端行为本身稳定、可预测 **作者明确陈述**。

- **为落地该洞见所需的实现组件：**Client Generator、Timestamp Sampler、Request Data Sampler 等（属于实现组成，不单独作为贡献声明）。
- **可行性依据：**
 1. M-small 中 2,412 个客户端，前 29 个（按速率降序）贡献 90% 请求 **实验支持**；
 2. 头部客户端在突发性、输入/输出长度上表现稳定（误差条窄），仅速率本身波动 **实验支持**；
 3. 该因果建模在多模态（mm-image, 1,036 客户端）与推理（deepseek-r1, 25,913 客户端）场景中被重复验证 **实验支持**。
- **前提可能不成立的场景：**该假设建立在阿里云 Model Studio 存在"大量 API 批量调用型头部客户端"这一客户结构上；若目标环境高度去中心化、无头部客户端，该因果建模的适用性尚待验证 **基于文中逻辑的推断**。

6. 方法：从洞见到可执行系统

ServeGen 的总体流程是：先由 Client Generator 依据真实速率/CV 分布采样出一组异质客户端，再由 Timestamp Sampler 为每个客户端生成时变到达时间戳，最后由 Request Data Sampler（含 conversation-aware mocking）为每个请求填充长度等数据特征，三者叠加输出可直接用于评测系统的完整负载 **作者明确陈述**。

1. **Client Generator（客户端生成器）**——动机：Finding 5/8/11 显示客户端速率高度倾斜，若不能生成同样倾斜的客户端集合就无法复现真实突发性 **作者明确陈述**；过程：从预置 Client Pool 中按真实速率/CV 分布采样，或使用用户自定义客户端；输出：带各自 trace/dataset 描述的客户端集合；技术优势：保留客户端异质性而非把整体当单一随机过程 **作者明确陈述**；其有效性未单独设消融，仅通过 § 6.2 整体生成精度间接验证 **[文中未说明单独验证]**。
2. **Timestamp Sampler（到达时间采样器）**——动机：Finding 1/2 要求到达模型能表达"时变"特性 **作者明确陈述**；过程：依据每客户端 trace 参数与总速率的时间函数"缩放客户端速率"，具体缩放算法文中未给出 **[文中未说明]**；输出：各客户端及汇总到达时间戳序列；技术优势：可生成随时间变化的速率与突发性 **作者明确陈述**。
3. **Request Data Sampler（含 conversation-aware mocking）**——动机：Finding 3/4/6/9 表明长度分布因客户端与时间而异，Finding 10 表明多轮对话会重塑到达节奏 **作者明确陈述**；过程：为客户端生成长度数据，并通过保留共享对

话历史维持多轮结构，具体隐私保护实现文中未说明；技术优势：对照图 16，Naive 上采样会产生过度突发，而遵循真实 ITT 分布的方法更接近真实稳定性 [实验支持](#)。

7. 为什么它可能有效

- **机制→收益**：以客户端为单位联合建模速率与数据分布，能保留"速率突变常伴随数据分布变化"这一真实关联，NAIVE 因缺乏该关联而系统性低估真实负载压力 [基于文中逻辑的推断](#)。
- **所需条件**：该机制生效的前提是 Client Pool 中的客户端参数（速率、CV、长度分布）能代表目标部署场景的真实客户端结构；若目标场景客户端结构与阿里云平台显著不同，效果需重新验证 [基于文中逻辑的推断](#)。
- **时变建模的收益**：允许 Timestamp/Request Data Sampler 按时间参数化，理论上能复现 Finding 2/4 中观测到的漂移现象，但缩放算法细节未公开，实际保真度依赖未披露的实现 [基于文中逻辑的推断](#)。

8. 实验与指标：证据是否支撑主张

8.1 实验问题与判定标准

- **效果**：真实到达是否具突发性、ServeGen 生成负载是否更贴近真实分布——对应图 1(d)拟合优度、§ 6.2 生成精度对比。
- **机制**：头部客户端速率波动是否是整体漂移的驱动因——对应 § 3.3 客户端分解（图 5、图 6）。
- **必要性**：ITT 保真、按客户端建模是否为负载真实感所必需——对应图 16 对比实验。
- **鲁棒性/适用范围**：ServeGen 优势能否推广到不同模型/负载规模——论文仅在单一模型/单一片段验证，未做跨规模鲁棒性实验 [\[文中未说明\]](#)。

8.2 数据、任务、对比与运行设置

- **数据来源**：阿里云 Model Studio 全球云 LLM 服务日志，四个月、超 35 亿条请求 [作者明确陈述](#)。
- **任务/模型版本**：覆盖 12 个语言/多模态/推理模型工作负载（如 M-large、M-small、mm-image、deepseek-r1 等），各自采样窗口从一天到一个月不等（Table 1）。
- **硬件/软件、重复次数、统计方式**：文中未说明。
- **基线**：NAIVE（Poisson/Gamma+ShareGPT）；对比系统案例中的基线为 vLLM 默认配置策略与不同 PD 配置。

8.3 指标字典与对应公式

- **指标与方向**：CV（变异系数）；测量到达间隔时间(IAT)离散程度，无量纲；CV=1 对应泊松过程，越大越突发。**定义与公式**：来源层级为无可核验公式——文中仅给出判定基准"CV=1 对应泊松"，未列出标准差/均值的具体计算式。**实验用途**：判定 Finding 1/2/10/11 中的突发性。**读数与边界**：M-large/M-small/M-mid 在图 2 中 CV 分别约 1.29/1.12/1.07，均大于 1，但精确统计方式不可验证 [实验支持](#)。
- **指标与方向**：过/欠配比例；测量实例配置数相对实际所需数的偏差，越接近 0 越好。**定义与公式**：来源层级为推导关系（非原文公式）——作者给出"ServeGen 多配 4%、NAIVE 少配 50%"的文字描述，推理依据：由此可凝练出 (配置数-实际所需数)/实际所需数×100% [基于文中逻辑的推断](#)。**实验用途**：评估图 20 热力图中两种方法的配置准确性。**读数与边界**：仅在 M-large 配 Qwen2.5-14B 的单一 10 分钟窗口验证，能否推广到其他模型文中未说明 [实验支持](#)。
- **指标与方向**：长度漂移倍数（如 1.63×）；测量一天内平均长度的最大/最小值之比，无固定方向。**定义与公式**：来源层级为推导关系（非原文公式）——作者文字定义"最大平均长度除以最小平均长度"，推理依据：可凝练为 $Shift = \frac{\max(L_t)}{\min(L_t)}$ [基于文中逻辑的推断](#)。**实验用途**：量化 Finding 4 的时变漂移幅度。**读数与边界**：具体数值仅描述性给出，未提供置信区间。
- **指标与方向**：P99 TTFT/TBT；测量首字延迟/逐字延迟的第 99 百分位，单位毫秒，越低越好。**定义与公式**：无可核验公式，作者仅描述用途未给出百分位计算式。**实验用途**：判定 § 6.3 SLO 是否达标。**读数与边界**：具体数值文中未在 OCR 文本给出，需图表核实。

8.4 主结果、消融与证据边界 比较工作与被批判限制的呼应

比较工作/基线	核心限制/失效条件	本文对应模块	直接实验与仍未验证的边界
NAIVE	变异性不足、无速率-数据分布关联、导致欠配假象	Client Generator+Sampler	§ 6.2/ § 6.3 已验证；能否推广到多模态/推理场景负载生成文中未说明
BurstGPT/LMM	规模/范围不足	三类负载整体刻画框架	无直接定量对比实验，仅 Table 2 范围对比
PD-disaggregation 相关工作	真实部署性能"难以充分刻画"	用 ServeGen 作更真实评测输入	§ 6.4 验证；因果解释用"likely"表述，非确定性结论

主张与证据强度

主张	直接证据	证据强度与边界
到达具超越单一随机过程的突发性	图 1(d) KS 检验	实验支持；无逐一 p 值数值表
头部客户端速率波动驱动整体漂移	§ 3.3 客户端分解、图 2/图 6 对应	作者明确陈述；时序精确重合度需视觉核实
ServeGen 比 NAIVE 更贴近真实统计特征	§ 6.2 文字描述、图 19	实验支持；无量化误差指标(如 MAE)
NAIVE 导致资源欠配假象	§ 6.3, "少配 50%"	实验支持；单一场景，非统计意义普适结论

- 论文未给出与 BurstGPT/LMM 的同数据集定量对比实验，属证据缺口而非补造 [文中未说明]。
- § 6.3、§ 6.4 案例均基于单一模型/单一负载片段，能否推广到多模态或推理场景中未说明 [文中未说明]。

9. 图表解读与论证关系

表格证据：Table 1. 适用边界 呼应：第 2 节：覆盖工作负载与模型版本

- 图组结论：汇总了语言、多模态、推理三大类 12 个生产级工作负载与采样窗口特征。
- 论证关系：确立本文实证刻画的覆盖范围，为各 Finding 提供数据支持背景。
- 适用范围：基于阿里云 Model Studio 日志，未包含插件与前缀缓存场景。

Category	Name	Model	Description	Workload Information
Language	M-large	General model (310B)	Largest, general-purpose	240M requests (one month)
	M-mid	General model (72B)	Balanced, general-purpose	2.1B requests (one month)
	M-small	General model (14B)	Cheapest, general-purpose	767M requests (one month)
	M-long	General model (72B, 10M context)	Long-document comprehension	48M requests (one week)
	M-rp	Domain-specific model	Role-playing	49M requests (one week)
	M-code	Domain-specific model	Code completion	276M requests (one week)
Multimodal	mm-image	Qwen2.5-VL-72B	Image & text input	28M requests (one month)
	mm-audio	Qwen2-Audio-7B	Audio & text input	420K requests (one month)
	mm-video	Qwen2.5-VL-72B	Video & text input	1.2M requests (one month)
	mm-omni	Qwen2.5-Omni-7B	Omni-modal input	8.7M requests (one week)
Reasoning	deepseek-r1	deepseek-r1-671B	Full reasoning model	14.0M requests (one week)
	deepqwen-r1	deepseek-r1-distill-qwen-32B	Distilled reasoning model	4.8M requests (one week)

表格证据：Table 2. Comparison between our work and prior characterizations of LLM serving workloads.

Dashes indicate unavailabl... 对比基线 呼应：第 4 节：既有刻画工作与本文对比

- 图组结论：本文在时长、请求规模、模型数及模态覆盖上显著超越 BurstGPT 和 LMM 等既有工作。
- 论证关系：突出旧路线在规模与范围上的局限，论证建立生产级全面刻画的必要性。
- 适用范围：特征维度对比，无同数据集定量实验。

	Ours	BurstGPT [46]	LMM [38]
Characterization > Scale			
Duration	4 months	4 months	2 days
#Models	12	2	-
#Requests	3.54B	5.29M	-
Characterization > Scope			
Workloads	Language, Multi-modal, Reasoning	Language	Image-modal
Patterns	Variant burstiness	Variant burstiness	Image data distribution
	Distribution shifts		
	Conversations		
Workload Generation			
Approach	Parameterized clients	Parameterized burstiness	NAIVE




Figure 1. Inter-arrival time characterization.

图组解读 实验结论 呼应：第 8 节：到达间隔时间突发性与拟合优度

- **图组结论**：三个工作负载 CV 均大于 1，且无统一参数化分布在所有负载上普遍最优。
- **论证关系**：支撑 Finding 1，为到达时间采样器允许每客户端灵活选择分布提供直接依据。
- **适用范围**：覆盖 M-large/small/mid 单一 20 分钟窗口，不证明分布异质的因果机制。




Figure 2. Long-term rate and CV shifts.

图组解读 实验结论 呼应：第 8 节：到达速率与突发性随时间漂移

- **图组结论**：M-large 持续突发两日后转稳定，M-rp 全程平稳，M-code 仅日内特定时刻剧烈尖峰。
- **论证关系**：支撑 Finding 2 速率与突发性随时间多样化漂移，为动态调度设计提供依据。
- **适用范围**：仅覆盖四个语言模型负载，不含 M-mid，不解释漂移成因。




Figure 3. Input and output length distribution. x-axis: # tokens; y-axis: frequency. Each subfigure corresponds to a specific workload and time period, split to two consecutive x-scales to show both the shift in average lengths (left) as well as the tail distribution (right).

图组解读 实验结论 呼应：第 8 节：输入输出长度分布与漂移

- **图组结论**：各模型长度直方图形态差异显著，不同时段存在明显位移，输入输出长度相关性弱。
- **论证关系**：支撑 Finding 3 和 Finding 4，说明请求数据采样器需按时间参数化数据分布。
- **适用范围**：无法读出精确漂移倍数，不证明漂移由客户端行为驱动。




Figure 5. Client heterogeneity in terms of rate, etc.
All CDFs are weighted by client rates.

图组解读 **消融验证** 呼应：第 5 节：客户端异质性与头部集中

- **图组结论**：客户端速率呈高度倾斜分布，CV 与平均长度在客户端间呈现显著异质性。
- **论证关系**：直接支撑 Finding 5 客户端异质性主张，证实整体漂移源于头部客户端速率波动。
- **适用范围**：覆盖 M-small 工作负载，无法证明该机制自动延伸至多模态或推理场景。




Figure 6. Characterization of the top four clients in the M-small workload in isolation, using the first 48-hour data from Figure 2. Vertical lines in the last-row subfigures indicate average input/output lengths, and error bars show the range of average lengths in 1-hour windows.

图组解读 **消融验证** 呼应：第 8 节：客户端速率倾斜与稳定性

- **图组结论**：前 29 个客户端贡献约 90% 请求，头部客户端 A/D 长度分布误差条窄、表现稳定。
- **论证关系**：支撑核心洞见 Finding 5，为客户端生成器按真实速率/CV 异质采样提供实验依据。
- **适用范围**：基于 M-small 前 48 小时数据，Client B/C 长度稳定性未在图中标出。




Figure 9. Ratio of multimodal input tokens per request in mm-image, mm-audio, and mm-video. Numbers indicate the average ratio.

图组解读 **实验结论** 呼应：第 8 节：多模态请求异质性

- **图组结论**：mm-image/audio/video 三种模态输入占比呈全区间连续分布而非单峰集中。
- **论证关系**：支撑 Finding 7，说明多模态请求存在结构异质性，是导致 TTFT 延长的原因。
- **适用范围**：覆盖三个多模态负载，纵轴未标绝对频数刻度。




Figure 10. Breakdown of first-token time when serving requests with image or video inputs (mm-image and mm-video).

图组解读 **实验结论** 呼应：第 8 节：多模态首 token 延迟分解

- **图组结论**：视频请求下载/归一化/编码耗时中位数显著高于图像，编码开销为主要瓶颈。
- **论证关系**：支撑 Finding 7 机制，为编码器解耦与弹性扩容提供必要性依据。
- **适用范围**：基于采样请求预处理耗时，未验证具体调度优化算法效果。




Figure 11. Clients in mm-image. CDFs are weighted by rates.

图组解读 **消融验证** 呼应：第 5 节：多模态客户端异质性

- **图组结论**：mm-image 中 35 个客户端即贡献 90% 加权累计请求，头部集中效应极显著。
- **论证关系**：支撑 Finding 8，将客户端分解因果建模从语言模型扩展至多模态场景。
- **适用范围**：覆盖 mm-image 工作负载，未证明泛化至去中心化客户结构。




Figure 12. Behavior of top clients in mm-image. Vertical lines in the last-row subfigures indicate average lengths, and error bars show the range of average lengths within a day.

图组解读 **消融验证** 呼应：第 5 节：多模态头部客户端行为分解

- **图组结论**：mm-image 头部客户端图像长度与图文占比分布高度集中、误差条窄。
- **论证关系**：支撑 Finding 8，证实头部客户端速率波动而非速率维度稳定的因果建模成立。
- **适用范围**：覆盖 mm-image 单一客户端快照，不证明适用于其他多模态负载。




Figure 13 characterizes request lengths in the deepseek-r1 workload, depicting also the reason and answer parts of outputs. In the upper part of Figure 13(a), we observe similar power-law distributions and shifting patterns (Finding 3 and 4) in terms of input and output lengths, as indicated by the fitting

图组解读 **实验结论** 呼应：第 8 节：推理负载 Reason 与 Answer 长度与比值

- **图组结论**：Reason 长度整体更长且跨度更大，Answer/Output 占比呈显著双峰分布。
- **论证关系**：支撑 Finding 9，为推理负载包含两种主导任务模式的推断提供分布证据。
- **适用范围**：基于 deepseek-r1 单日数据，未做任务细分验证。

10. 完整因果推理树

- 根问题：真实生产 LLM 服务负载缺乏全面刻画，导致新场景研究动机不足、评测系统不可信
 - 旧方法限制：局部/短期分析规模范围不足（BurstGPT/LMM）；NAIVE 生成方法产生"虚假易服务"负载
 - 核心洞见/假设：负载复杂性可归约为少数头部客户端的行为波动（Finding 5/8/11）
 - 方法模块：Client Generator（按真实速率/CV 异质采样）
 - 可验证预测：以客户端为单位生成的负载在速率-数据分布关联上优于 NAIVE
 - 指标与实验：§ 6.2 生成精度对比（图 19）
 - 图表证据：图 19 定性显示"匹配更好"，无量化误差指标 **实验支持**
 - 结论与适用边界：仅定性验证，缺 MAE/RMSE 等量化读数，未覆盖多模态/推理场景生成
 - 方法模块：Timestamp Sampler（时变到达建模）
 - 可验证预测：时变速率函数可复现 Finding 1/2 的漂移与突发特征
 - 指标与实验：CV、拟合优度（KS 检验）对比
 - 图表证据：图 1、图 2 显示原始负载存在多样化漂移与非统一最优分布
 - 结论与适用边界：Timestamp Sampler 具体缩放算法未公开，保真度未被当前证据直接验证 **[文中未说明]**
 - 方法模块：Request Data Sampler + conversation-aware mocking
 - 可验证预测：ITT 保真的数据采样比 Naive 上采样更接近真实突发性
 - 指标与实验：§ 5.2 图 16 对比
 - 图表证据：图 16 显示遵循真实 ITT 分布方法更稳定 **实验支持**
 - 结论与适用边界：仅在 deepseek-r1 单一工作负载验证，其他推理模型适用性文中未说明
 - 应用验证：ServeGen 在实例配置（§ 6.3）与 PD 分离（§ 6.4）案例中暴露 NAIVE 导致的欠配与配置分歧
 - 图表证据：图 20 热力图（欠配 50% vs 多配 4%）、图 21 SLO 对比
 - 结论与适用边界：单一模型/单一负载片段验证，跨模型/跨规模的鲁棒性未被当前证据直接验证 **[文中未说明]**

11. 结论、贡献与边界

- **贡献总结**：(1) 迄今规模最大范围最全的生产级 LLM 服务负载刻画；(2) 发现客户端分解揭示的因果建模；(3) 开源 ServeGen 负载生成框架 **作者明确陈述**。
- **证据充分的结论**：真实负载短期到达具突发性且无统一最优分布（图 1、图 2 实验支持）；客户端速率高度倾斜且头部客户端可解释整体漂移（图 5、图 6 实验支持）；NAIVE 生成负载会导致资源欠配（§ 6.3 实验支持）。
- **尚属推断的意义**：长尾请求导致 PD 分离性能不均衡是作者用"likely"表述的推断，非确定性因果证明 **基于文中逻辑的推断**；Answer/Output 比值双峰源于两类任务模式也是推断，未做任务细分验证 **基于文中逻辑的推断**。

- **适用条件与局限**（作者自述）：未覆盖插件调用场景；因保密义务未覆盖前缀缓存特性；纵向研究时长不足以支持跨月度趋势分析。
- **审稿式风险检查**：
 - 贡献新意：核心发现（客户端分解因果建模）建立在特定平台客户结构上，泛化性依赖未验证的前提，当前证据未覆盖去中心化客户结构场景。
 - 写作/可复现性：Timestamp Sampler 具体缩放算法、conversation-aware mocking 实现细节均未公开，复现存在障碍 [文中未说明]。
 - 效果大小：ServeGen 对 NAIVE 的优势多为定性描述 ("匹配更好")，缺少统一的量化误差指标，效果幅度不易独立核实。
 - 实验覆盖：§ 6.3/ § 6.4 案例均为单一模型/单一时间片段，未做跨模型跨规模重复实验，当前证据未显示鲁棒性风险已被排除或已被证实存在。
 - 方法设计：与 BurstGPT/LMM 无同数据集定量对比，仅特征范围对比，当前证据未显示该省略导致结论错误，但确属证据缺口。

12. 术语与第一性原理学习路径

12.1 核心术语

- **术语**：到达间隔时间(IAT)与变异系数(CV)。**第一性原理角色**：IAT 是相邻两请求到达时间差这一基本状态量，CV=标准差/均值，是连接"到达随机性"与"系统突发压力"的因果桥梁。**本文位置**：贯穿 Finding 1/2/10/11 判定突发性。
- **术语**：客户端(client)。**第一性原理角色**：本文的基本建模单位，是"请求生成主体"这一基本对象，其速率、CV、长度分布构成负载异质性的资源约束来源。**本文位置**：Finding 5 核心洞见及 Client Generator 设计基础。
- **术语**：Pareto+Log-normal 混合分布/指数分布。**第一性原理角色**：描述输入/输出长度这一状态量的统计约束形态，决定了负载生成时应采样何种分布族。**本文位置**：Finding 3。
- **术语**：prefill 与 decoding 阶段。**第一性原理角色**：LLM 推理的两种基本计算机制，分别受并行计算能力与内存带宽约束，是 TTFT/TBT 等指标的物理成因。**本文位置**：贯穿全文延迟相关讨论。
- **术语**：PD 分离(PD-disaggregation)。**第一性原理角色**：一种资源分配机制，将两种不同资源约束（计算密集 vs 带宽受限）的阶段物理隔离，以避免相互抢占。**本文位置**：§ 6.4 案例研究。
- **术语**：conversation-aware mocking。**第一性原理角色**：在生成数据时保留多轮对话历史结构这一约束，以维持 ITT 分布不被破坏。**本文位置**：Request Data Sampler 模块。
- **术语**：SLO/TTFT/TBT/P99。**第一性原理角色**：延迟类可观测指标，P99 作为尾部统计量刻画最坏情况约束。**本文位置**：§ 6.3 实例配置 SLO 判定。

12.2 学习路径

1. 先理解"请求"这一基本对象及其属性（到达时刻、输入/输出长度）——这是负载刻画的最小单元。
2. 再理解 prefill/decoding 两阶段的计算资源约束——这是延迟指标（TTFT/TBT）产生的物理根源。
3. 掌握 IAT/CV 与常见分布族（泊松、Gamma、Pareto、指数）的机制含义——这是判断"负载有多随机/多突发"的数学工具。
4. 理解"客户端"作为异质性来源的角色——这是本文核心洞见（头部客户端驱动漂移）的因果链起点。
5. 最后理解 SLO/P99 等系统行为指标如何把上述机制转化为可评测的系统表现——这是连接负载特征与工程决策（如 PD 配置）的桥梁。